


SVM: Support Vector Machine



En SVM se busca una línea de separación ℓ tal que se maximice el margen.

El margen $b = b^+ - b^-$ definido como la distancia perpendicular de la linea ℓ al punto más cercano de cada clase.

Definición de ℓ :

$$\ell: g(\underline{x}) = 0$$

donde

$$g(\underline{x}) = \alpha_1 x_1 + \alpha_2 x_2 + \alpha_0$$


La clasificación de un punto \underline{x} es:

$$\begin{cases} g(\underline{x}) > 0 & \rightarrow \text{clase } +1 \\ \leq 0 & \rightarrow \text{clase } -1 \end{cases}$$

¿Cómo rotular la recta ℓ ?

- ① → cálculo de distancia de un punto \underline{x}^* a una recta
- ② → planteamiento del problema
- ③ → planteamiento de cómo resolverlo
- ④ → solución

① Distancia de un punto \underline{x}^* a la recta:



VER DEMOSTRACIÓN
AL FINAL

$$\underline{x}^* = \underline{x}_p + \underline{r}$$

$$\underline{r} = r \hat{\underline{a}}$$

vector unitario $\perp l$
distancia a l

Se puede demostrar que

$$r = \frac{|g(\underline{x}^*)|}{\|\underline{a}\|}$$

donde $\underline{a} = [a_1, a_2]^T$

② Planteamiento del problema

Para encontrar b , se debe cumplir que las distancias de los puntos de entrenamiento \underline{x}_i a la recta l deban ser $\geq b$:

$$\frac{|g(\underline{x}_i)|}{\|\underline{a}\|} \geq b \text{ para } i=1\dots N \quad (1)$$

Se debe encontrar a_1, a_2, \dots, a_N tal que se cumpla la condición anterior.

Consideremos que $|g(\underline{x}_i)| = z_i g(\underline{x}_i)$

donde $z_i = \pm 1$ si \underline{x}_i pertenece a la clase ± 1 .

(1) se puede escribir como:

$$\frac{z_i g(\underline{x}_i)}{\|\underline{a}\|} \geq b \quad (2)$$

Es necesario imponer una restricción adicional a \underline{a} y a_0 para que no escape al infinito:

$$\text{suje to a } b\|\underline{a}\| = 1$$

Entonces (2) es:

$$z_i g(\underline{x}_i) \geq 1$$

o bien

$$\boxed{z_i g(\underline{x}_i) - 1 \geq 0} \quad (3)$$

Se permite entonces maximizar b , esto equivale a minimizar $\|\underline{a}\|$ tal que se cumpla (3).

PROBLEMA:

$$\text{Minimizar } \|\underline{a}\|$$

Sujeto a:

$$z_i (\underline{a} \underline{x}_i^\top + a_0) - 1 \geq 0 \text{ para } i \in [1, N]$$

3) Cómo resolver el problema de optimización?

El problema se traduce a:

$$J(\underline{a}, a_0, \lambda) = \frac{1}{2} \|\underline{a}\|^2 - \sum_{i=1}^n \lambda_i [z_i (\underline{a}^\top \underline{x}_i + a_0) - 1] \rightarrow \min \quad (4)$$

A B C

- A: Se persigue minimizar $\|\underline{a}\|$
 - B: Se persigue maximizar segundo término
 - C: Con $\lambda_i > 0$ se fuerza a encotrar una solución que clasifique correctamente ($z_i(\underline{a}\underline{x}_i^T + a_0) - 1 \geq 0$)

Segin Kuhn-Tucker, (4) re prede transfer

Mar 2015

$$J(\underline{\lambda}) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j} \lambda_i \lambda_j z_i z_j \underbrace{\underline{x}_i^\top \underline{x}_j}_{x_i^\top x_j} \rightarrow \max \quad (5)$$


Sugato a $\lambda_i > 0$

$$\langle x_i^\top, x_j \rangle$$

products punto

④ Solución

4) Al resolver (5), sólo los vectores de ∂P parte, i.e., los puntos x_i que tienen contacto con los bordes del margen tienen $\lambda_i \neq 0$. El resto son vectores irrelevantes:



Al resolver (5) la solución es λ_i .

Derivando (4), igualando a cero, y considerando λ_i :
se obtiene la solución para \underline{a} :

$$\boxed{\underline{a} = \sum_{i=1}^N \lambda_i z_i \underline{x}_i} \rightarrow \underline{a} = \sum_{k=1}^{N_{sv}} \lambda_k z_k \underline{x}_k$$

N_{sv} vectores de soporte

Usando los vectores de soporte se obtiene a_0
ya que para ellos se cumple

$$z_i (\underline{a}^\top \underline{x}_i + a_0) - 1 = 0 \quad (1/z_i = z_i)$$

$$\underline{a}^\top \underline{x}_i + a_0 = z_i$$

$$\boxed{a_0 = z_i - \underline{a}^\top \underline{x}_i}$$

\underline{x}_i es
vector de
soporte


El hiperplano queda definido como:

$$g(\underline{x}) = \underline{a}^\top \underline{x} + a_0$$

$$\boxed{g(\underline{x}) = \sum_{i=1}^N \lambda_i z_i \underline{x}_i^\top \underline{x} + a_0}$$

$\langle \underline{x}_i, \underline{x} \rangle$

⑤ Bonus : líneas de decisión no-lineales.



La línea de separación seña

$$g(\underline{x}) = g(h(\underline{x})) = \underline{a}^T h(\underline{x}) + a_0$$

$$g(\underline{x}) = \sum_{i=1}^N \lambda_i z_i \langle h(\underline{x}_i), h(\underline{x}) \rangle + a_0$$

IMPORTANTE: no interesa $h(\underline{x})$, sino sus
productos punto \rightarrow Función de Kernel

$$\langle h(\underline{x}_i), h(\underline{x}) \rangle = \underbrace{K(\underline{x}_i, \underline{x})}_{\downarrow}$$


Muy utilizadas:

Polinomio grado n : $(1 + \langle \underline{x}_i, \underline{x} \rangle)^n$

Radial Basis : $\exp(-\|\underline{x}_i - \underline{x}\|^2/c)$

Neural Network : $\tanh(k_1 \langle \underline{x}_i, \underline{x} \rangle + k_2)$

Demo DE ①



①

Sean los puntos

\underline{x}_A y \underline{x}_B que pertenezcan a l , entonces:

$$a_1 x_{A1} + a_2 x_{A2} + a_3 = 0$$

$$- a_1 x_{B1} + a_2 x_{B2} + a_3 = 0$$

$$[a_1 \ a_2] (\underline{x}_A - \underline{x}_B) = 0$$

$\Rightarrow \underline{a} = [a_1 \ a_2]^T$ es ortogonal a l .

② Se define:

\underline{x}_p : vector desde el origen a punto de l de donde nace la linea perpendicular a \underline{x}^*

\underline{r} : vector de \underline{x}_p a \underline{x}^*

$$\left. \begin{array}{l} \underline{x}^* = \underline{x}_p + \underline{r} \\ \underline{r} = r \hat{\underline{a}} \end{array} \right\} \begin{array}{l} \text{vector unitario} \\ \text{máximo de } r \end{array}$$

$$\hat{\underline{a}} = \underline{a} / \|\underline{a}\|$$

③

$$\begin{aligned} g(\underline{x}^*) &= a_1(x_{p1} + r_1) + a_2(x_{p2} + r_2) + a_3 \\ &= \underbrace{a_1 x_{p1} + a_2 x_{p2} + a_3}_{g(\underline{x}_p)} + \underbrace{a_1 r_1 + a_2 r_2}_{\underline{a}^T \underline{r}} \end{aligned}$$

$$g(\underline{x}^*) = \underline{a}^T \underline{r} = r \|\underline{a}\| \cos \theta$$

$$\Rightarrow \boxed{r = |g(\underline{x}^*)| / \|\underline{a}\|}$$

porque son colineales
(puede ser -1 de ahí que
 $|g(\underline{x}^*)| = r \|\underline{a}\|$)