

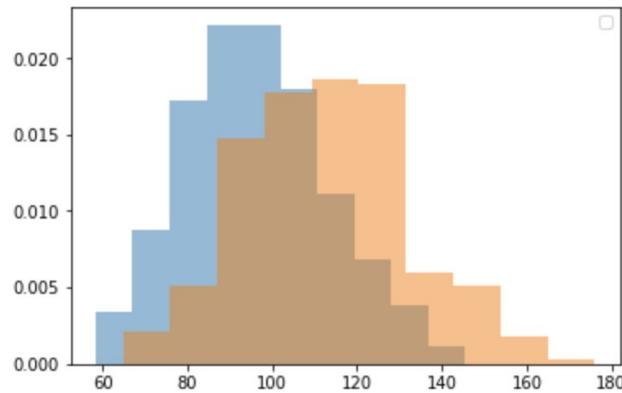
Avance Reconocimiento de Patrones

Italo Contreras
Julián Lires
Adriana Navarrete

Lo que llevamos

- Extracción de características mediante LBP.
- Alineación de rostros rotados.
- Filtro notch para eliminar patrones en fotos.

Resultados



$$d_{\text{prime}} = 0.04879$$

FNMR y FMR muy altos. Los histogramas están traslapados.

Lo que nos falta

- Incluir las imágenes pre-procesadas al clasificador y evaluar desempeño.
- Utilizar otro algoritmo para la extracción de características, como VGG.
- Comparar la similitud con varios algoritmos, como distancia euclidiana y cosine similarity.

Patron del Mal



Integrantes:

- Luis Felipe García
- Paula Navarrete
- Matías Sepulveda
- Frane Sazunic



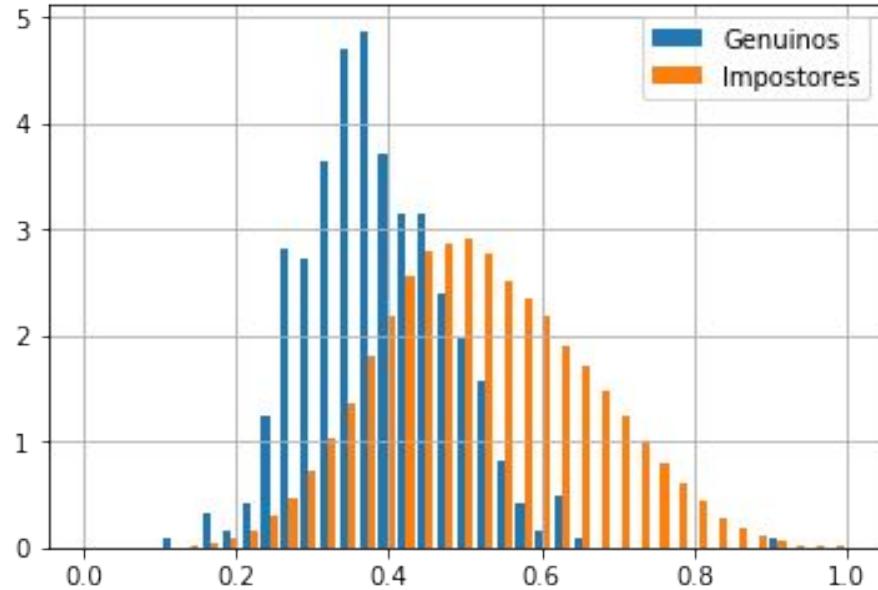
Avances

- **Data augmentation:** rotation, gaussian noise, flipping horizontal para las imágenes de niños y jóvenes.
- **Mantener el balance de clases** en el set de entrenamiento.
- **LBP & HOG** features en B&W imgs **no exhibe buen performance.**
- **VGG face** descriptor **no logra separar bien** los impostores de los genuinos



Métrica

- VGG-Face: $d'=1.17$
- Threshold: 0.455
- FPR: 0.3263
- FNR: 0.0004





Por hacer

- Realizar **más pruebas en pre-procesamiento**
- **Incrementar** variaciones en data **augmentation**.
- **Feature engineering** : realizar pruebas en extracción de características, diferentes combinaciones y mayor variedad de descriptores
- **Investigar** más **bibliografía** atingente:
 - Reconocimiento facial robusto
 - Reconocimiento invariante a la edad

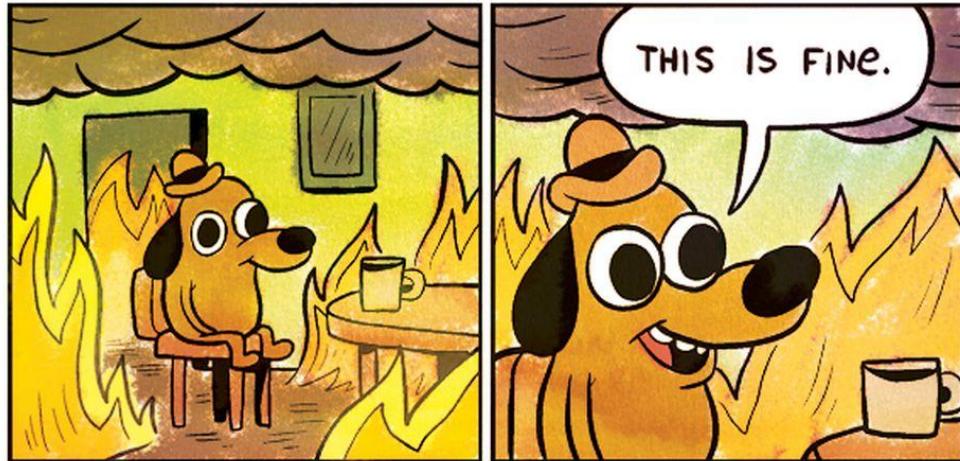
Age-gap face verification using Deep Learning

Integrantes:

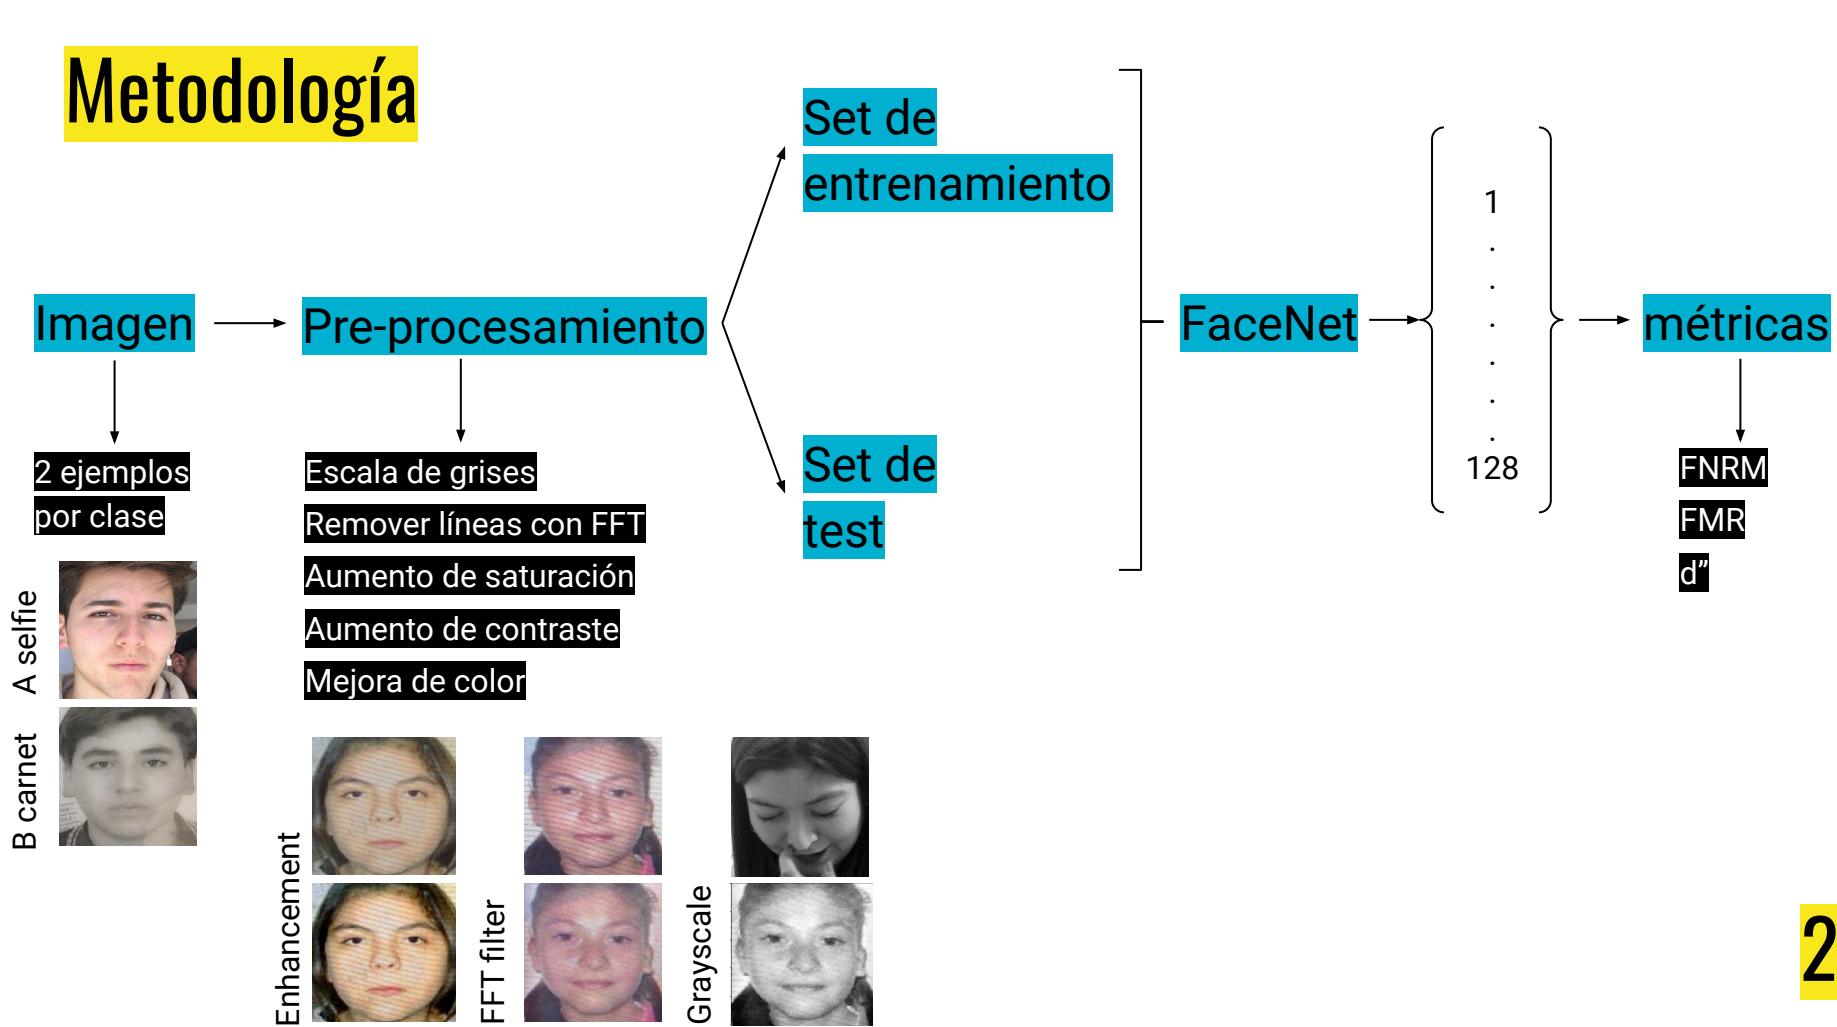
Francisca Cattan

Tanya Garrido

Ignacio Hermosilla



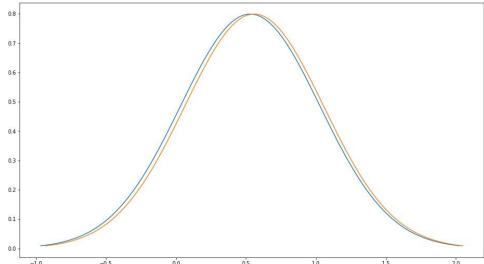
Metodología



Resultados

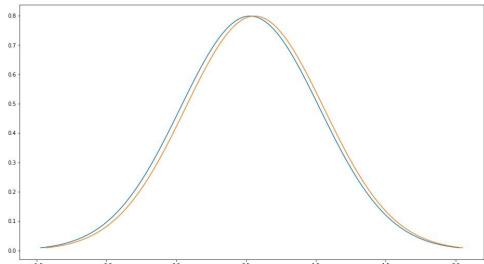
FNMR: 0,45
FMR: 0,54
D': 0,05

Enhanced



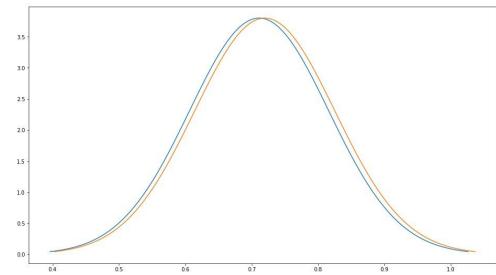
FNMR: 0,33
FMR: 0,62
D': 0,07

Sin líneas



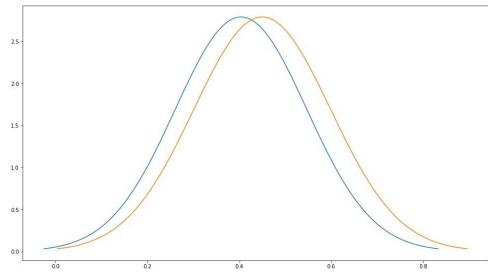
FNMR: 0,46
FMR: 0,54
D': 0,011

Default



FNMR: 0,5
FMR: 0,49
D': 0,31

Grayscale



Próximos pasos y mejoras

Entrenar FaceNet con dataset de entrenamiento para mejorar el rendimiento de la red.

Utilizar FaceNet para extraer características y probar una arquitectura siamesa para entrenar.

Mejorar la calidad de las imágenes a través de mejores algoritmos de pre-procesamiento.

Comparar estos resultados con aquellos obtenidos vía handcrafted descriptors.



Presentación de avances

IEE3724 - Reconocimiento de Patrones

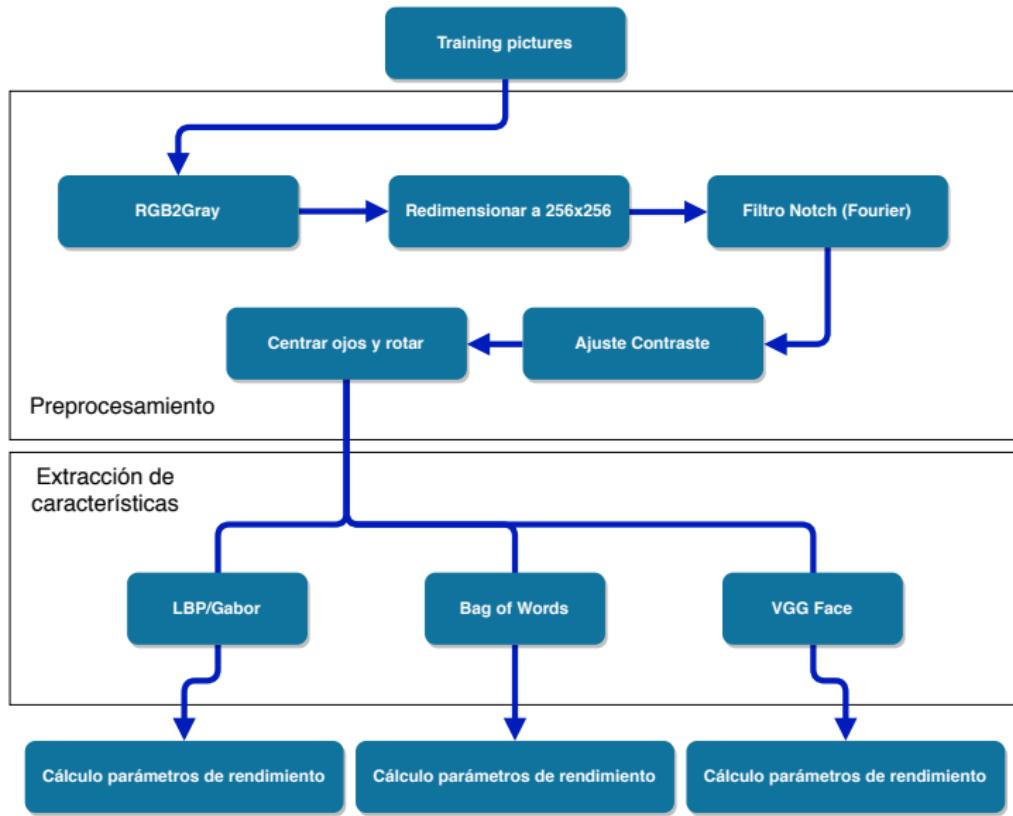
Grupo For2For

Carlos Carrasco
Matías Rojas
Juan Pablo Schnettler
August Wahlberg

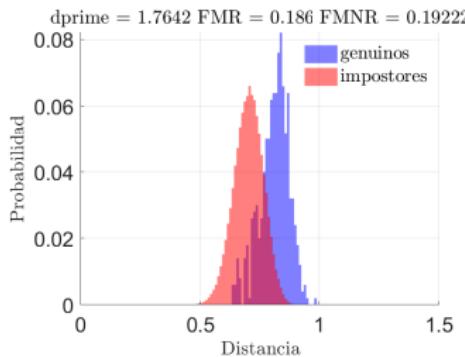
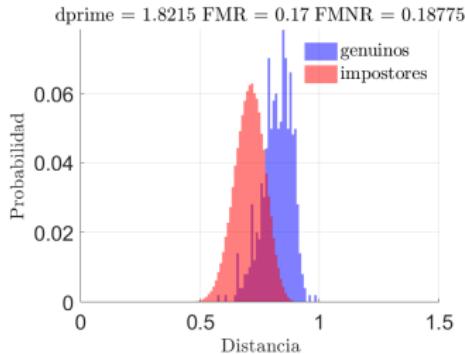
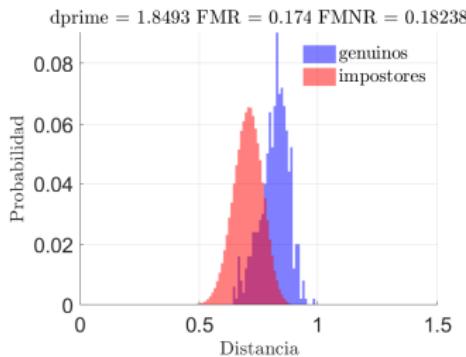
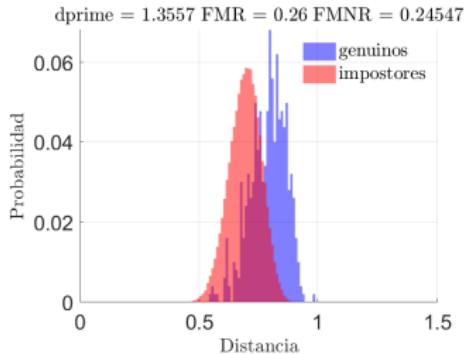
Escuela de Ingeniería
Pontificia Universidad Católica de Chile

18 de junio, 2019

Lo hecho hasta ahora



Desempeños



¿Qué se hará?

- Selección de características
- Metric Learning
- Histogram of Gradients (HoG)
- Reentrenar red neuronal
- Probar con otras redes

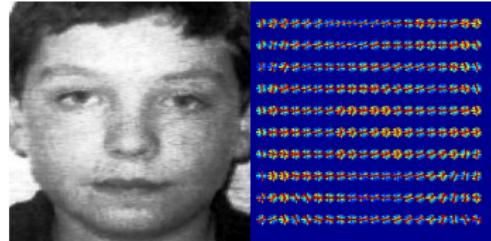


Figura: HoG

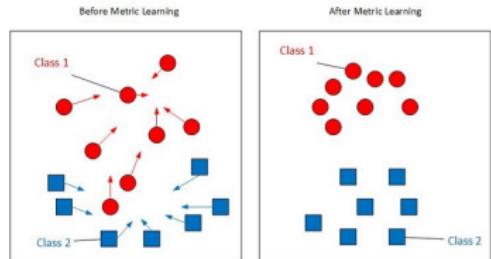
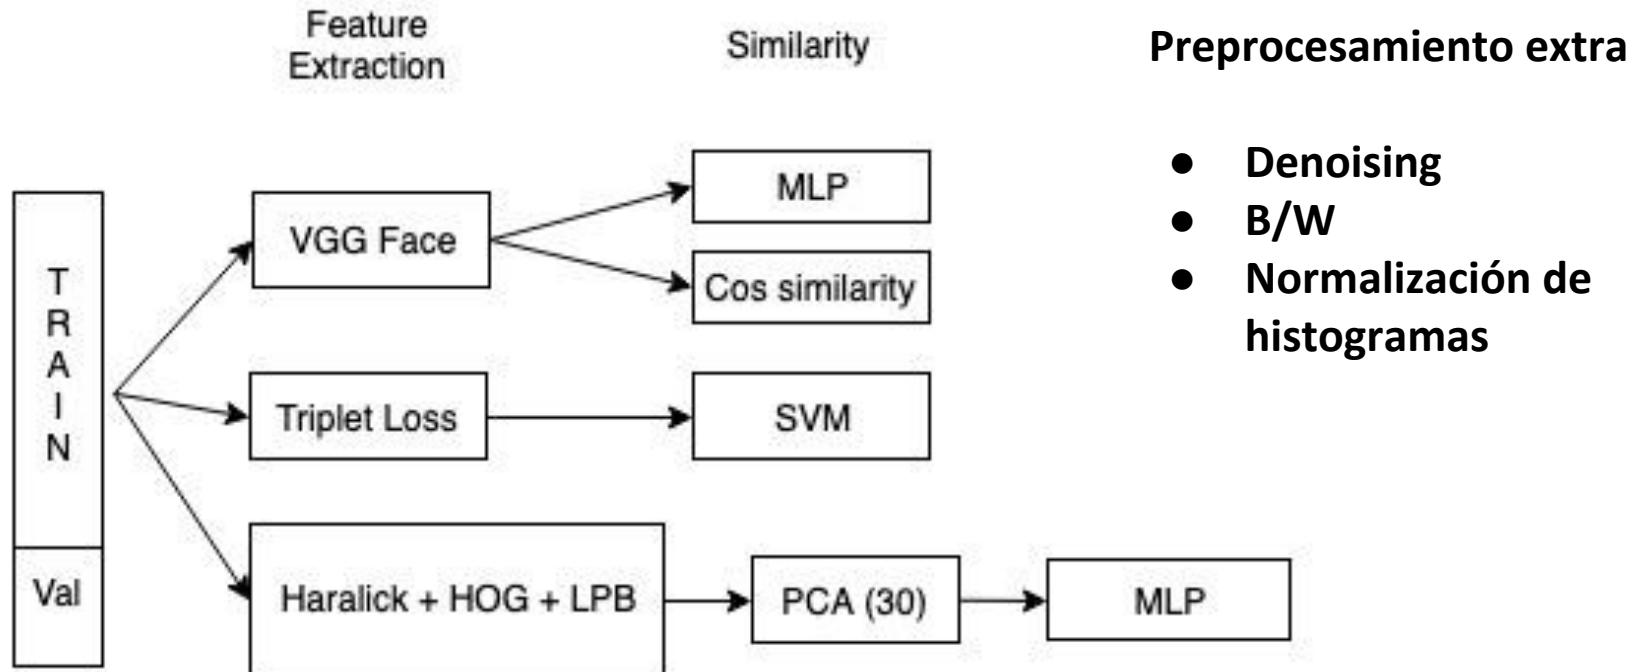


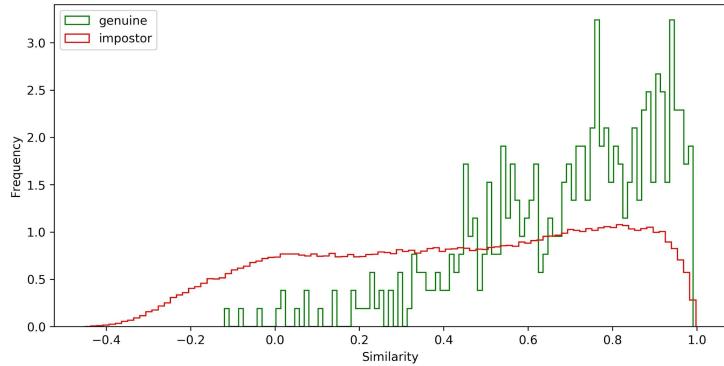
Figura: Metric Learning

Avance Proyecto Semestral

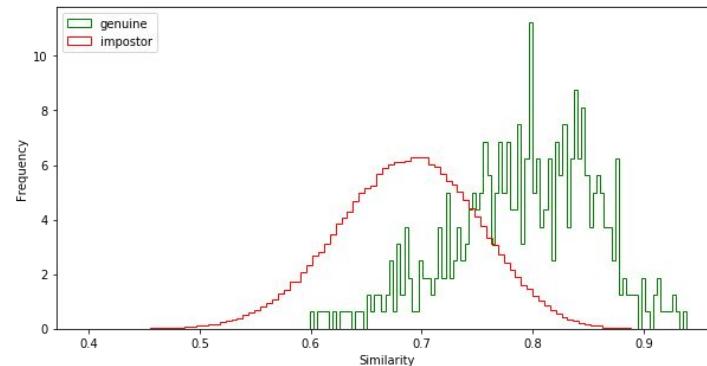
Integrantes:

- Benjamín Kramm P
- Christian Meléndez S
- Ignacio Tobar R
- Freddie Venegas A



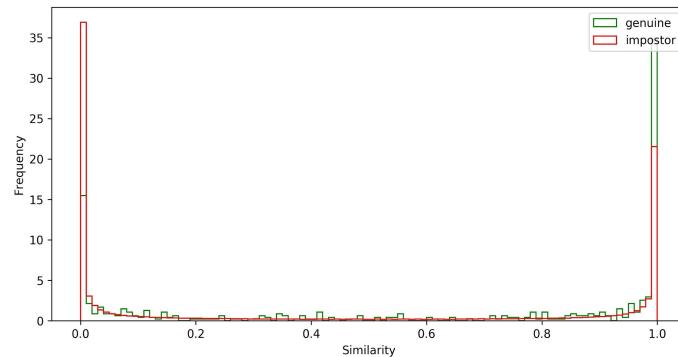


d' : 0.93 / FMR: 0.42 / FNMR: 0.17

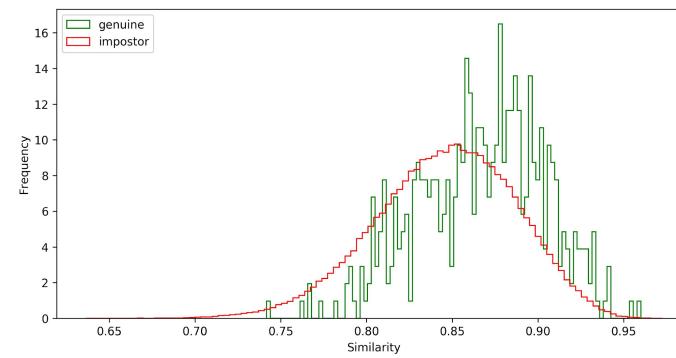


d' : 1.64 / FMR: 0.123 / FNMR: 0.296

(sin denoising) d' : 1.52 / FMR: 0.07 / FNMR: 0.44



d' : 0.48 / FMR: 0.3 / FNMR: 0.5



d' : 0.54 / FMR: 0.48 / FNMR: 0.31

Pasos próximos

- Hacer más análisis de sensibilidad.
- Combinar features de la red con features de imágenes (LBP, HOG, etc).

Presentación de Avance

Bastián Mavrakis

Nicolás Teare

Felipe Pezoa

Hugo Navarrete





Logrado

Pre-procesamiento:

- Eliminar ruido de las imágenes.
- Remover líneas de imágenes provenientes de carnet.

Extracción de características:

- LBP.
- HOG.
- Haralick texture features.

Métricas:

- D prime (d').
- False Non Match Rate (FNMR).
- False Match Rate (FMR).

Resultados obtenidos

D-prime:

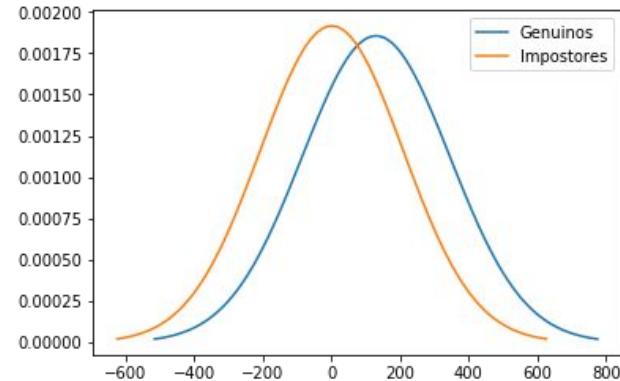
- LBP + Hog + Haralick: 0.03.
- LBP + Hog: 0.31.
- LBP: 0.62.

FNMR:

- LBP + Hog + Haralick: 0.61.
- LBP + Hog: 0.57.
- LBP: 0.51.

FMR:

- LBP + Hog + Haralick: 0.38.
- LBP + Hog: 0.41.
- LBP: 0.46.



D-prime:

- Eliminando líneas del carnet: 0.55.
- Sin eliminar líneas del carnet: 0.62.



Trabajo futuro

Pre-procesamiento:

- Alinear imágenes.
- Normalizar el brillo y color de las imágenes.
- Rotar imágenes.

Extracción de características:

- Ajustar cálculo de características existentes.
- Facenet.
- VGG.

Otros:

- Triplet loss.



Reconocedor de Caras en Jóvenes con Diferencia de Edad

Florencia Barrios

Juan Francisco Campos

Felipe Gómez

Maximiliano Friedl

Problema

- Verificación
- Pares de imágenes
- 1750 pares de *training*
- 472 pares de *testing*

Pre-procesamiento

- Resize imágenes a 256x256
- Transformación a blanco y negro (sólo para LBP)

Extracción de características

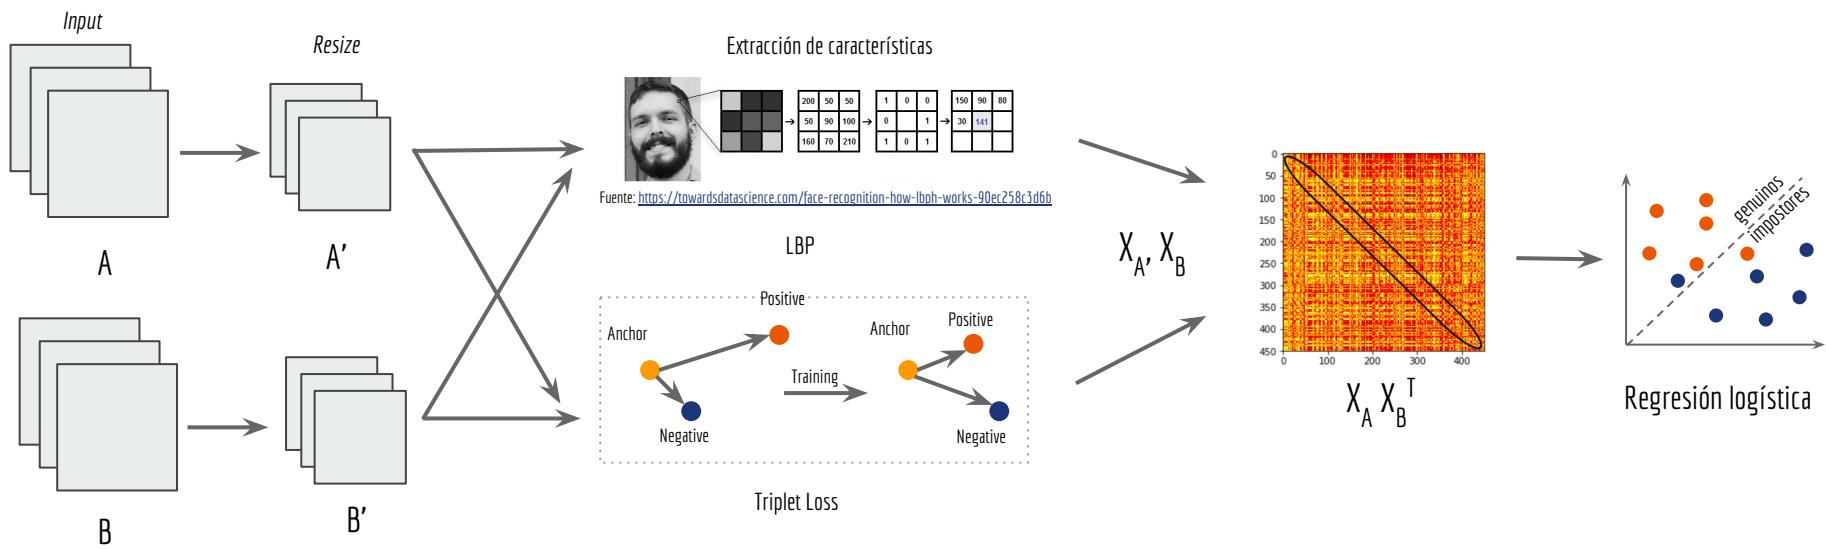
- Local binary patterns

- Focal Loss

$$\|f(x_i^a) - f(x_i^p)\|_2^2 + \alpha < \|f(x_i^a) - f(x_i^n)\|_2^2$$

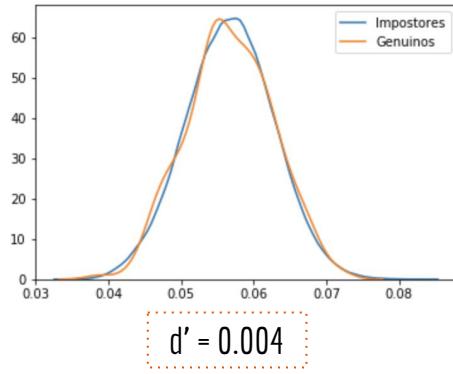
Métricas

- *D prime (d')*
- FNMR: falsos negativos
- FMR: falsos positivos

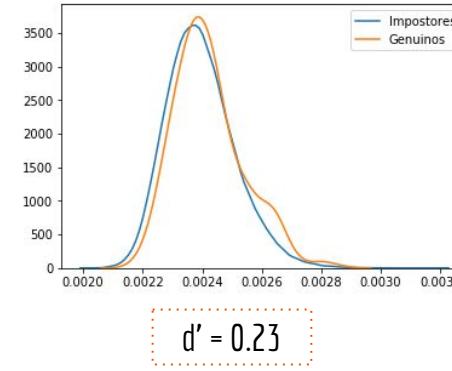


LBP

Caso base: *LBP* sin subdividir

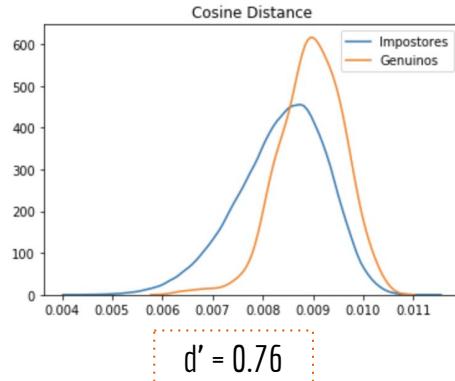


Mejora: *LBP* subdividiendo en 9

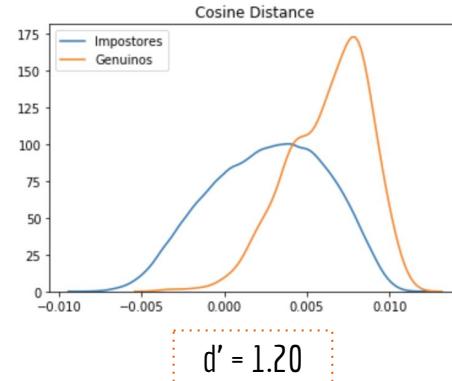


Triplet Loss

Caso base: *all triplets*



Mejora: *semi hard triplets*



Próximos pasos

- Ampliar el dataset con imágenes de datasets encontrados:
 - The IMDB-WIKI dataset: 523,051 imágenes de celebridades, con labels de edad, género, ubicación de la cara y id de celebridad. Fuente: <https://data.vision.ee.ethz.ch/cvl/rrothe/imdb-wiki/>
 - Cross-Age LFW (CALFW) Database: 12,174 imágenes con más de una imagen por persona, en diferentes edades. Fuente: <http://www.whdeng.cn/CALFW/index.html>
- Probar EigenFaces (Turk & Pentland):
 - Utilizar caras como filas de una matriz, calcular vectores propios.
 - Proyectar nuevas imágenes como una suma ponderada de vectores propios y comparar con “cara promedio” .

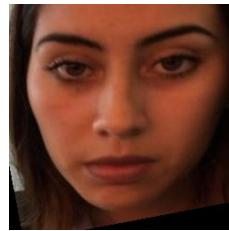
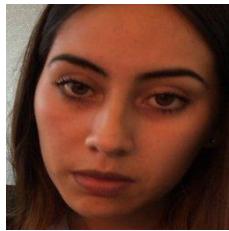
Fuente: <https://arxiv.org/pdf/1705.02782.pdf>

Presentación Avance

Cristóbal Ferrer, Raimundo Martinez, Yoav Navon, Felipe Neut

Trabajo Realizado

Alineamiento:



Filtrado:



Extracción de Features:

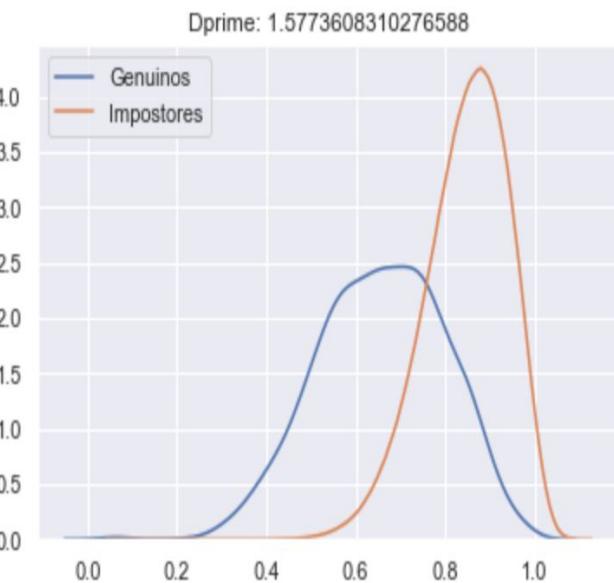
- LBP
- Vgg-Facenet
- Resnet-Facenet

Métricas:

- Cosine
- Euclidean
- Correlation
- Mahalanobis

Resultados obtenidos

D-prime	Métrica	NP	Ali.	Fil.	Ali. & Fil.
LBP	Cosine	0.149	0.105	0.135	0.102
Facenet-VGG	Cosine	0.634	0.954	0.618	0.618
LBP & VGG	Cosine	0.598	0.799	0.602	0.545
Facenet-Resnet	Correlation		1.57		
Facenet-Resnet	Cosine		1.49		



Trabajo futuro

- Mejorar preprocesamiento.
- Filtro de envejecimiento/rejuvenecimiento
- Vgg-Facenet
- Resnet-Facenet
- Definir umbral de clasificación
- Validar en testing
- ¿Otros métodos?

Avance proyecto: Reconocimiento de caras invariante a edad

Diego Alfaro
Lucas Álvarez
Julio Cortés
Francisco Pessot

Team Libcheese

Avances

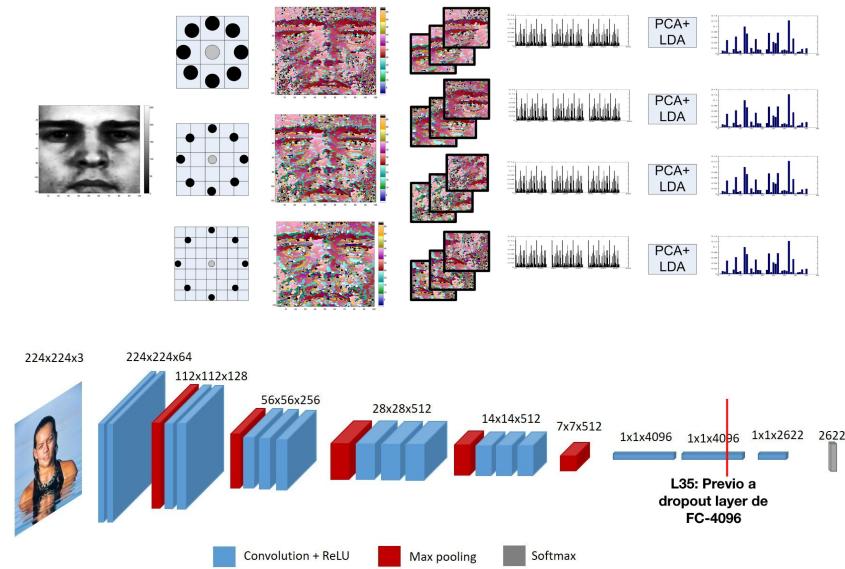
Preprocesamiento: Filtro Notch para
remover curvas sobre caras tipo A

Extraccion de caracteristicas: MLBP
(LBP a múltiples radios) y VGG-Face
CNN hasta capa 35 (4096 descriptores)

Métricas: Distancia euclidiana, similitud de cosenos ($\ell_2, S_c(A, B) = \frac{A \cdot B}{\|A\| \|B\|}$)

Fuentes:

- Chan, Chi-Ho & Kittler, Josef & Messer, Kieron. (2007). Multi-scale Local Binary Pattern Histograms for Face Recognition.
 - Deep Face Recognition with Keras: <https://sefiks.com/2018/08/06/deep-face-recognition-with-keras/>
 - PARKHI et al.: DEEP FACE RECOGNITION

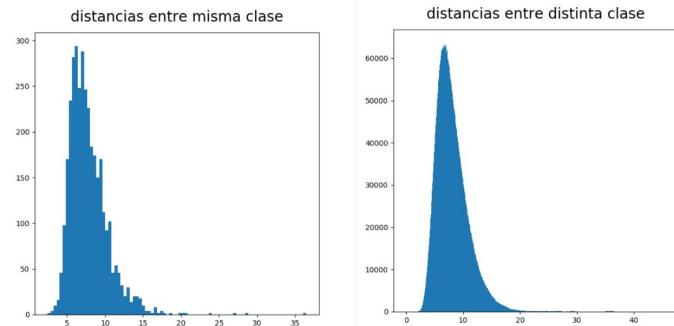


Resultados obtenidos

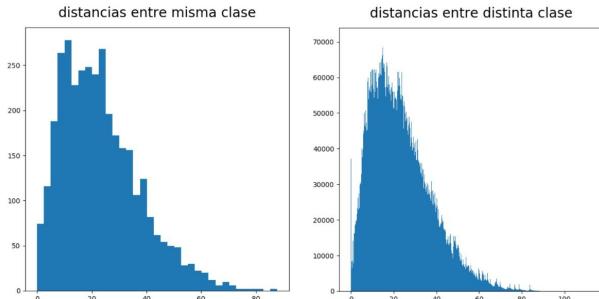
Experimentos realizados:

- LBP, Dist. Euclidiana
- VGG-Face, Dist. Euclidiana,
- VGG-Face, Sim. Coseno

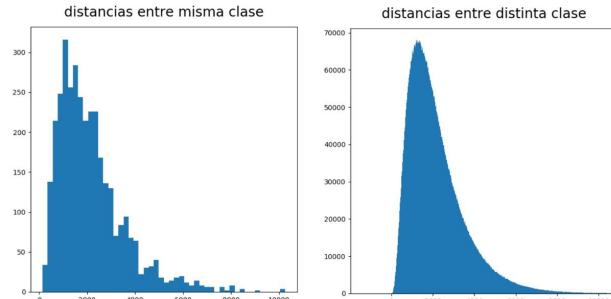
LBP



VGG-Face, distancia euclidiana



VGG-Face, distancia coseno



Mejoras a realizar

1. Selección y transformación de características MLBP mediante LDA (SFS) y PCA para reducir alta dimensionalidad (~20k caract. para 8x8, R={2,3}).
2. Metric Learning: $d_M(x, x') = \sqrt{(x - x')^T M (x - x')}$
Determinar un M óptimo para maximizar la distancia entre pares negativos $P_{ij}^- = \{x_i^A, x_j^B\}$ y minimizar la distancia entre pares positivos $P_{ii}^+ = \{x_i^A, x_i^B\}$.
Logrado mediante redes neuronales o algoritmos especializados (*weakly supervised metric learning* como MMC, RCA).

Fuentes:

- Tutorial on Metric Learning: http://researchers.lille.inria.fr/abellet/talks/metric_learning_tutorial_CIL.pdf
- metric-learn: <https://github.com/metric-learn/metric-learn>



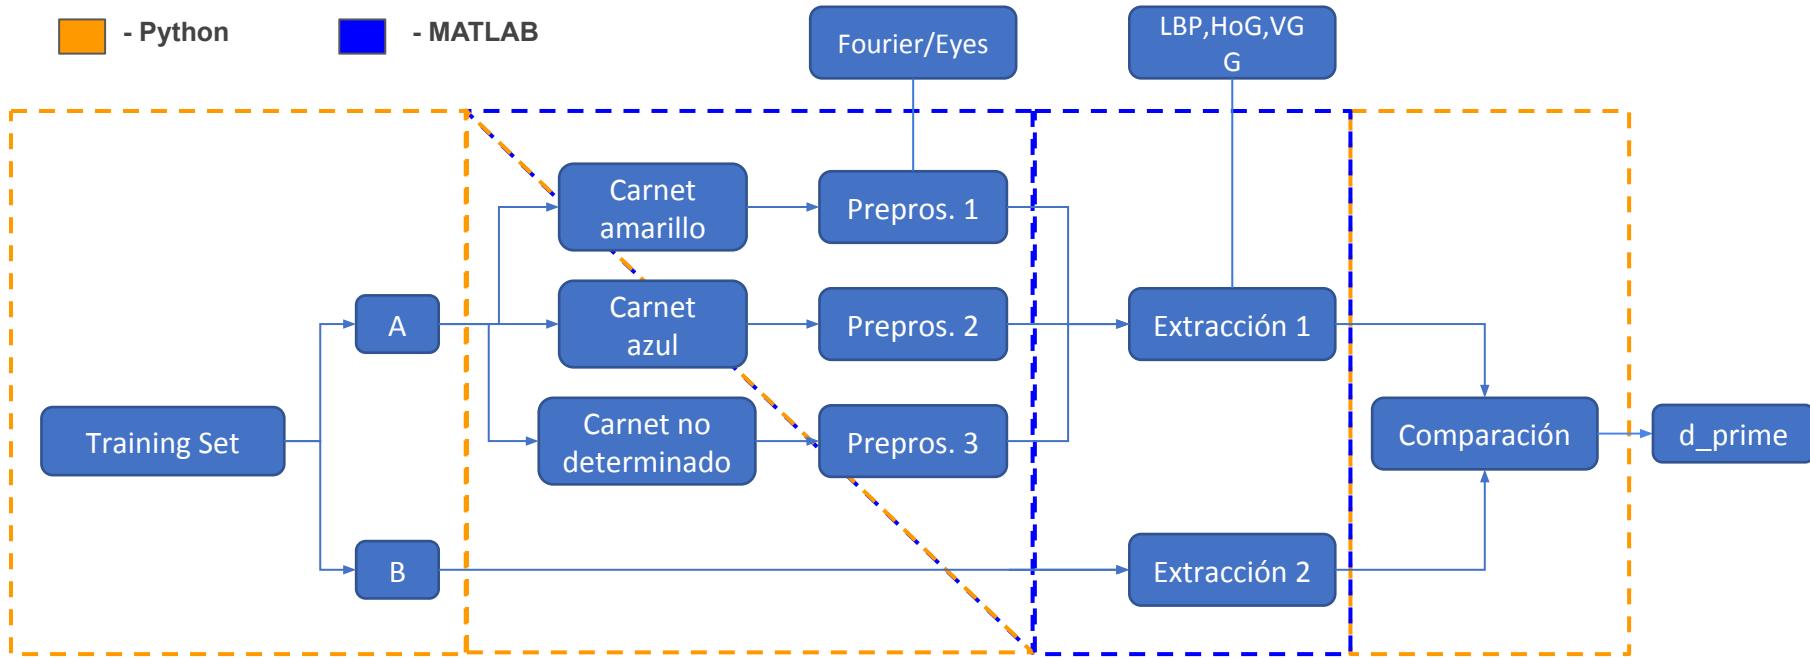
Proyecto de reconocimiento de patrones: *Face verification* de sujetos en infancia y adolescencia

Integrantes:

José Manuel Bustos
Nicolás Urrejola
Manuel Vial
Daniel Vives

¿Qué hemos hecho?

Primera planificación no sirve: este no es un problema habitual de extracción, selección y clasificación!

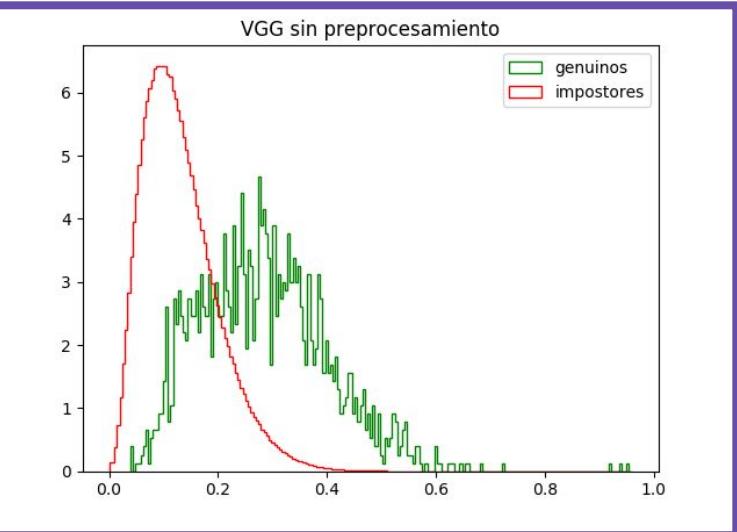
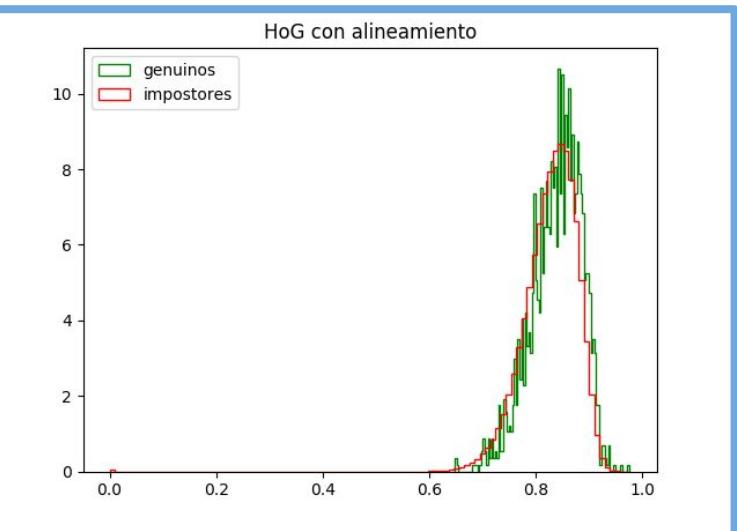


Experimentos y Resultados

d-prime	Sin pre-pros	Solo alineamiento	Alineamiento + filtrado
LBP (531)	0.108	0.096	0.065
HOG (1800)	0.187	0.189	0.189
VGG-face (4096)	1.205	1.346	1.534



Centrado de ojos y Eliminación de líneas



Pasos a seguir

- Explorar con otras alternativas de pre-procesamiento (ecualización y normalización de ojos).
- Utilizar otras redes pre-entrenadas para extracción de características, como GoogleNet.
- Utilizar estrategias híbridas de extracción sin NN, como HoG+LBP o LBP de mayor tamaño.
- Desarrollar una heurística para probar otros modelos de clasificación (mahalanobis, metric learning, etc).
- Determinar las otras métricas de desempeño, FNMR y FMR.

ALEJANDRO QUIÑONES
ALAIN ROCHETTE
PABLO ROJAS

AVANCE DE PROYECTO

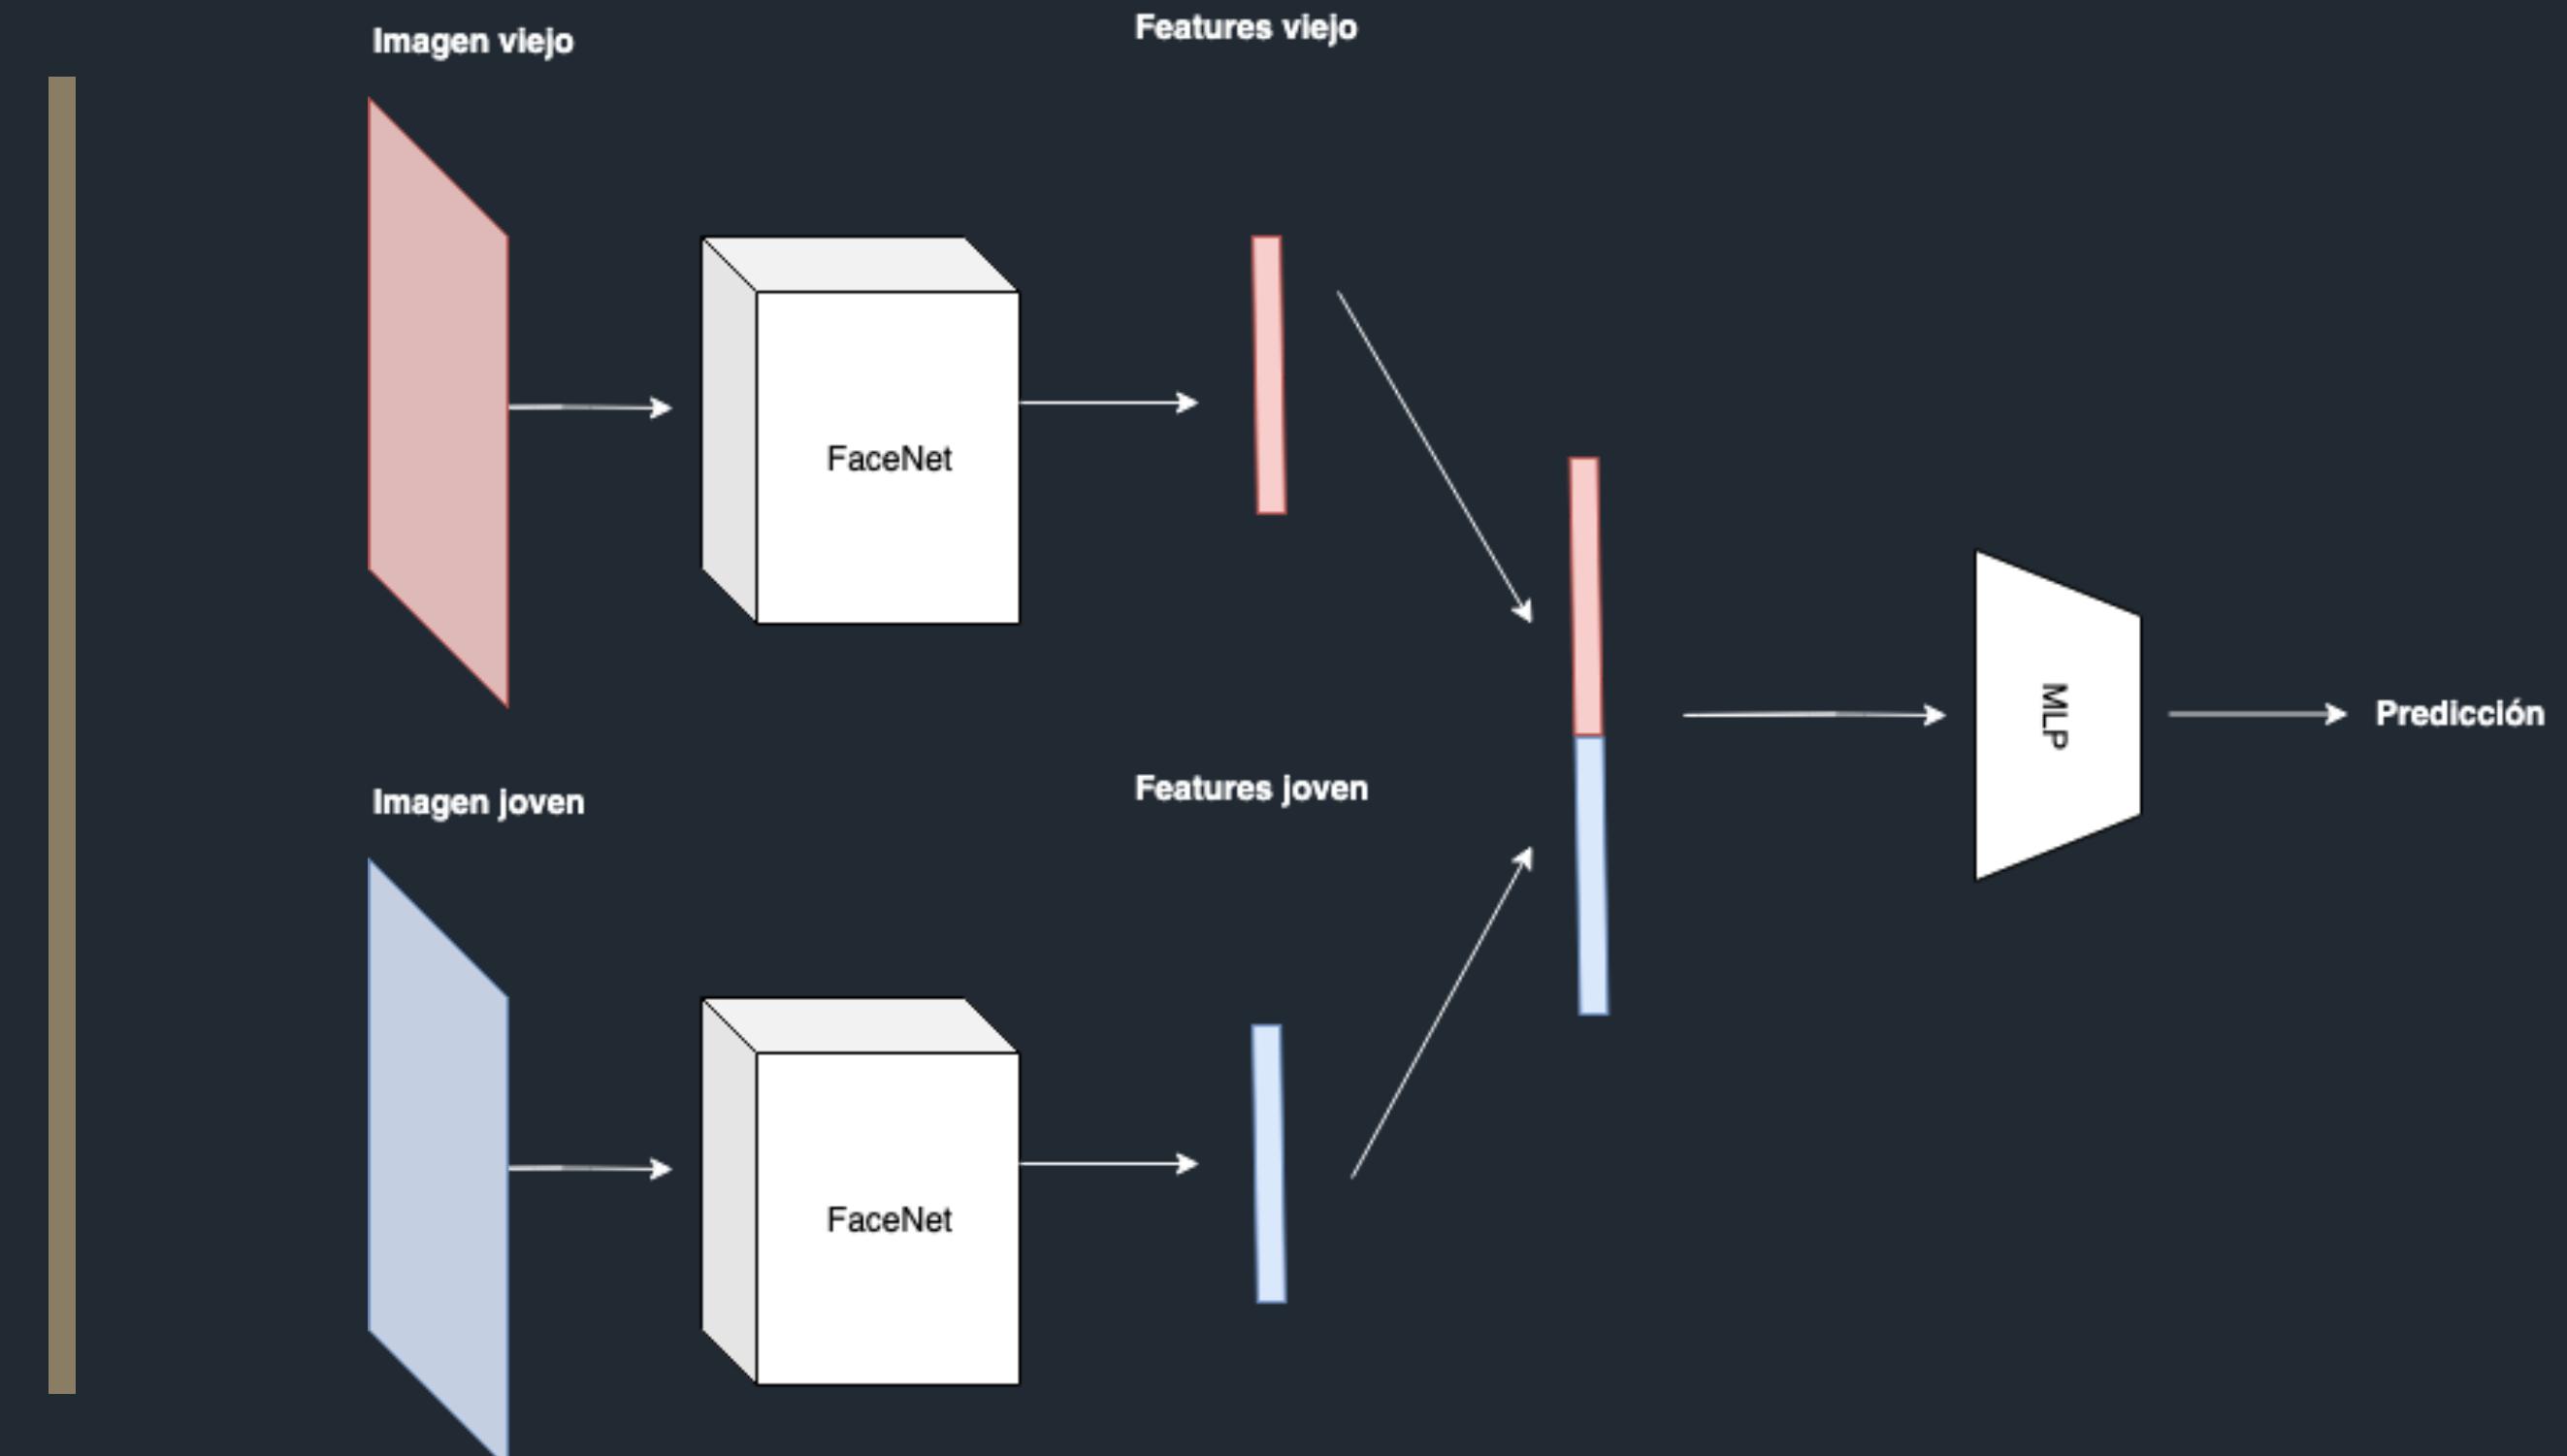
Reconocimiento de Patrones

Qué hemos hecho?

EXTRACCIÓN
FACENET

CLASIFICACIÓN
MLP

MÉTRICAS
FMR, FNMR
& D-PRIME



Resultados obtenidos

D-PRIME

0.00016

FNMR

86.0%

D-PRIME
+ GREYSCALE

0.00087

FMR

13.5%

Qué falta por hacer?

DATA AUGMENTATION

Aumentar número de fotos inputs con modificaciones de fotos originales (reflejo, rotación, stretch, etc.)

OTROS MODELOS

Probar otros modelos para extracciones de features. VGG-Face y Siamese Networks son opciones

AGE FILTER

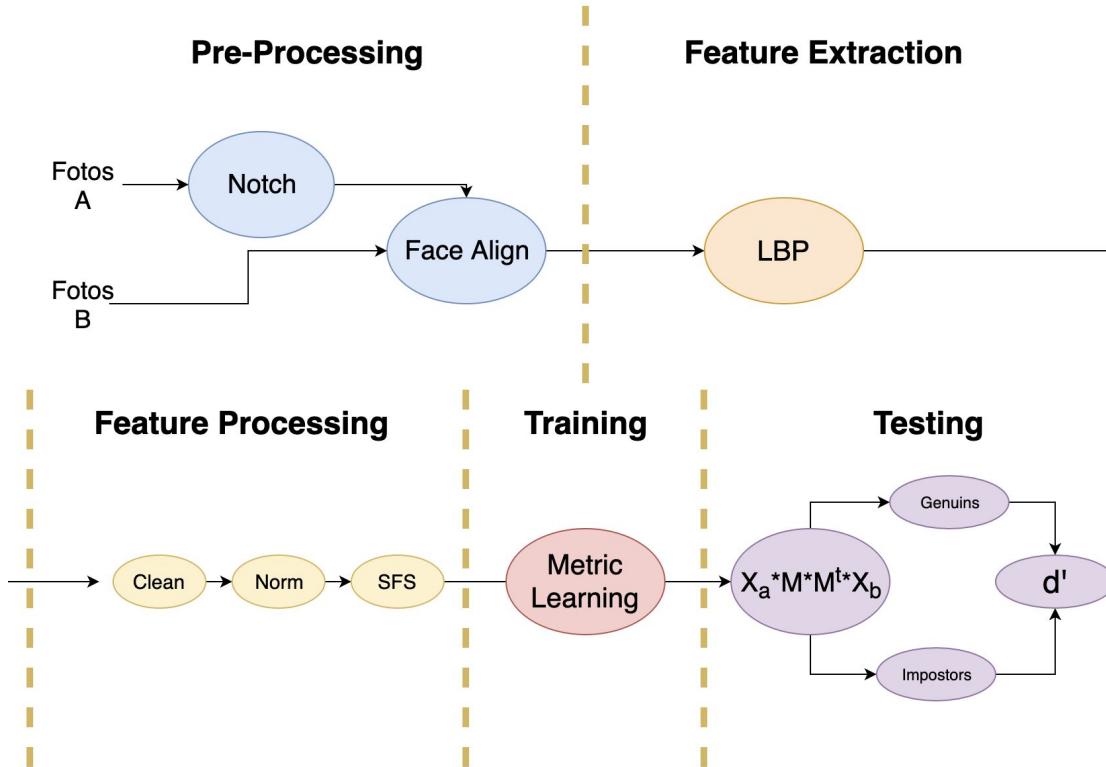
Preprocesamiento a la imagen joven, luego probar el modelo nuevamente.



Avance de Proyecto

Javier Bisbal - Enzo Buscaglia - Yair Doron - Max Valdés

Trabajo Realizado



Resultados

Sin Notch y Metric Learning:

- $d' = 0,38$
- $FMR = 0,42$
- $FNMR = 0,38$

Sin Notch y Sin Metric Learning:

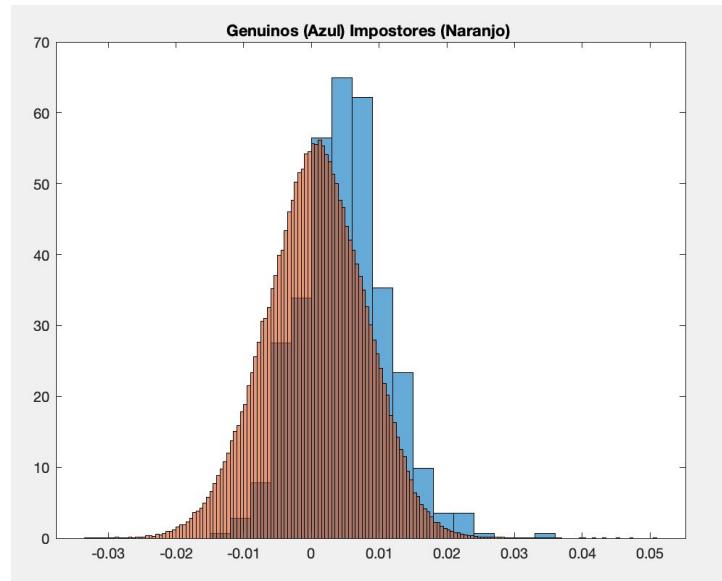
- $d' = 0,32$
- $FMR = 0,41$
- $FNMR = 0,43$

Con Notch y sin Metric Learning:

- $d' = 0,3736$
- $FMR = 0,389$
- $FNMR = 0,408$

Con Notch y Metric Learning:

- $d' = 0,43$
- $FMR = 0,368$
- $FNMR = 0,39$



Trabajo Futuro

- Utilizar VggFace, Facenet, entre otros.
- Mejorar Selección de características (PCA).
- Mejorar Contraste de las fotos.
- Probar más combinaciones! (Ejecución lenta).



Avance Proyecto

Reconocedor de Caras en Jóvenes con Diferencia de Edad

- Benjamín Arratia
- Matías Andrade
- Matías Eynaudi
- Esteban Villalobos

¿Qué hemos hecho?

Preprocesamiento

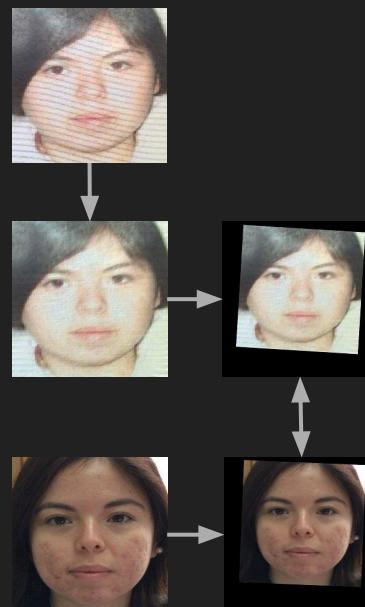
Notch Filter



Face Alignment



Extracción de Características



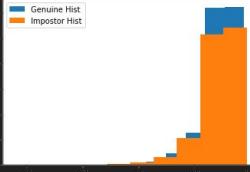
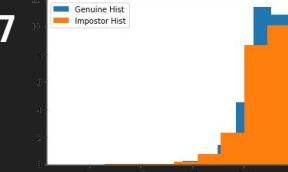
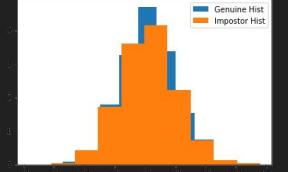
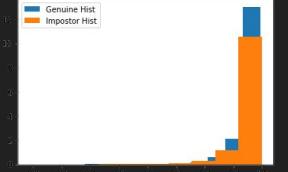
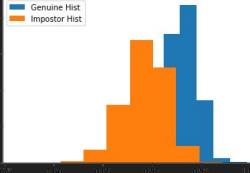
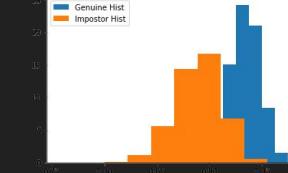
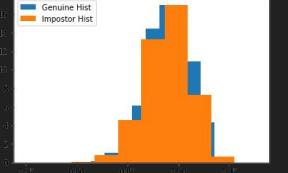
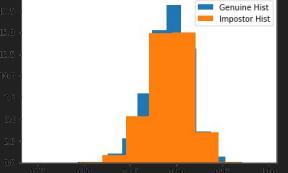
Métricas

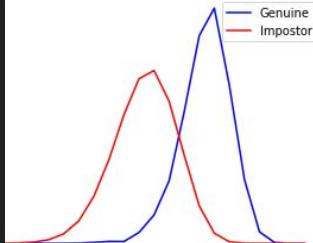
Cosine
Similarity

d-prime
FMR
FNRM

Resultados Obtenidos

D-Prime

Método	Original vs Original	Notch Filter vs Original	NF + FA vs Original	FA vs FA
LBP	0.097 	0.097 	0.012 	0.002 
dlib	1.88 	2.16 	0.047 	0.016 

Mejor método	d-prime	FMR	FNRM	
dlib Notch Filter vs Original	2.16	0.1337	0.1331	

To-do:

Próximos pasos

- Crop de caras alineadas para **eliminar marcos negros**.
- Probar **más combinaciones de preprocessamiento**, para estudiar el comportamiento de los clasificadores y escoger el más óptimo.
- Realizar **selección de características**

Posibles opciones:

- Buscar métodos de **reconstrucción de imágenes** para mejorar los carnet
- Buscar métodos que **modifiquen la edad**



Pontificia Universidad Católica de Chile
Facultad de Ingeniería
IIC3724 - Reconocimiento de Patrones
Profesor: Domingo Mery

Genuine-Impostor

Avances en el proyecto

Grupo CBM: Rodrigo Allende, Germán Contreras, Samuel Goldfarb, Lesly Reyes

Avances actuales

Preprocesamiento: Se utilizan cuatro datasets:

- Original
- Sin líneas en el carnet
- Alineamiento facial
- Sin líneas en el carnet + alineamiento facial

Extracción de características

- LBP
- *Embedding* de red convolucional
- *Eigenfaces*
- *Metric learning*

Métricas

- d'
- *Contrastive loss* (implementación con técnicas de *deep learning*)

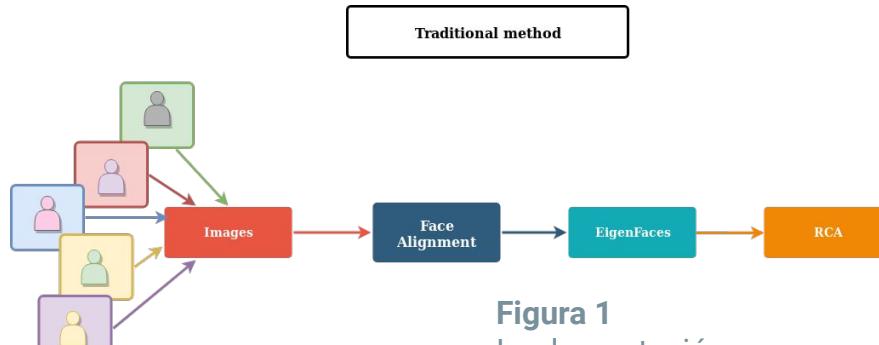


Figura 1
Implementación
técnicas del curso.

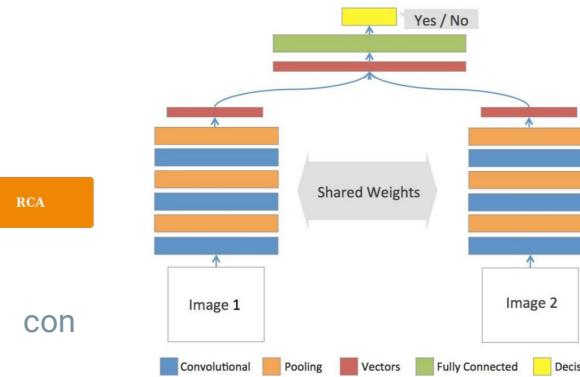


Figura 2
Implementación de
deep learning: **Siamese network**, donde se
recibe el par de
imágenes y se define si
es o no la misma
persona.

Resultados

Dataset con alineamiento facial

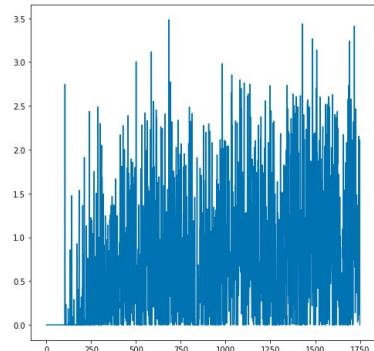
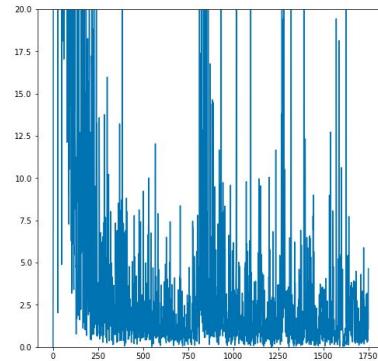
<i>Traditional Methods</i>	<i>d' values</i>
<i>Face alignment (FA)</i>	0.19
<i>FA + Local Binary Pattern (LBP)</i>	0.23
<i>FA + LBP + PCA</i>	0.23
<i>FA + Eigenfaces</i>	0.52
<i>FA + Eigenfaces + RCA</i>	0.65

<i>Traditional Methods</i>	<i>d' values</i>	<i>FMR</i>	<i>FNMR</i>
<i>FA+ Eigenfaces + RCA</i>	0.65	0.3	0.4

Dataset original

Training loss:

- Genuine
- Impostor



Trabajo pendiente

Modelo con técnicas del curso

- Probar con distintos clasificadores.
- Buscar distintas métricas para *metric learning*.
- Probar con más clasificadores.
- Quitar imperfecciones como las líneas en el rostro con opencv.

Modelo con técnicas de *deep learning*

- Ver resultados de los *embeddings* para el cálculo de d' .
- Generar un *embedding* para los *datasets* preprocesados.
- Probar con otras redes neuronales.

General

- Evaluar si se utilizarán más técnicas de preprocesamiento de datos.
- Comparar los resultados de ambos métodos y justificar sus desempeños en la tarea.

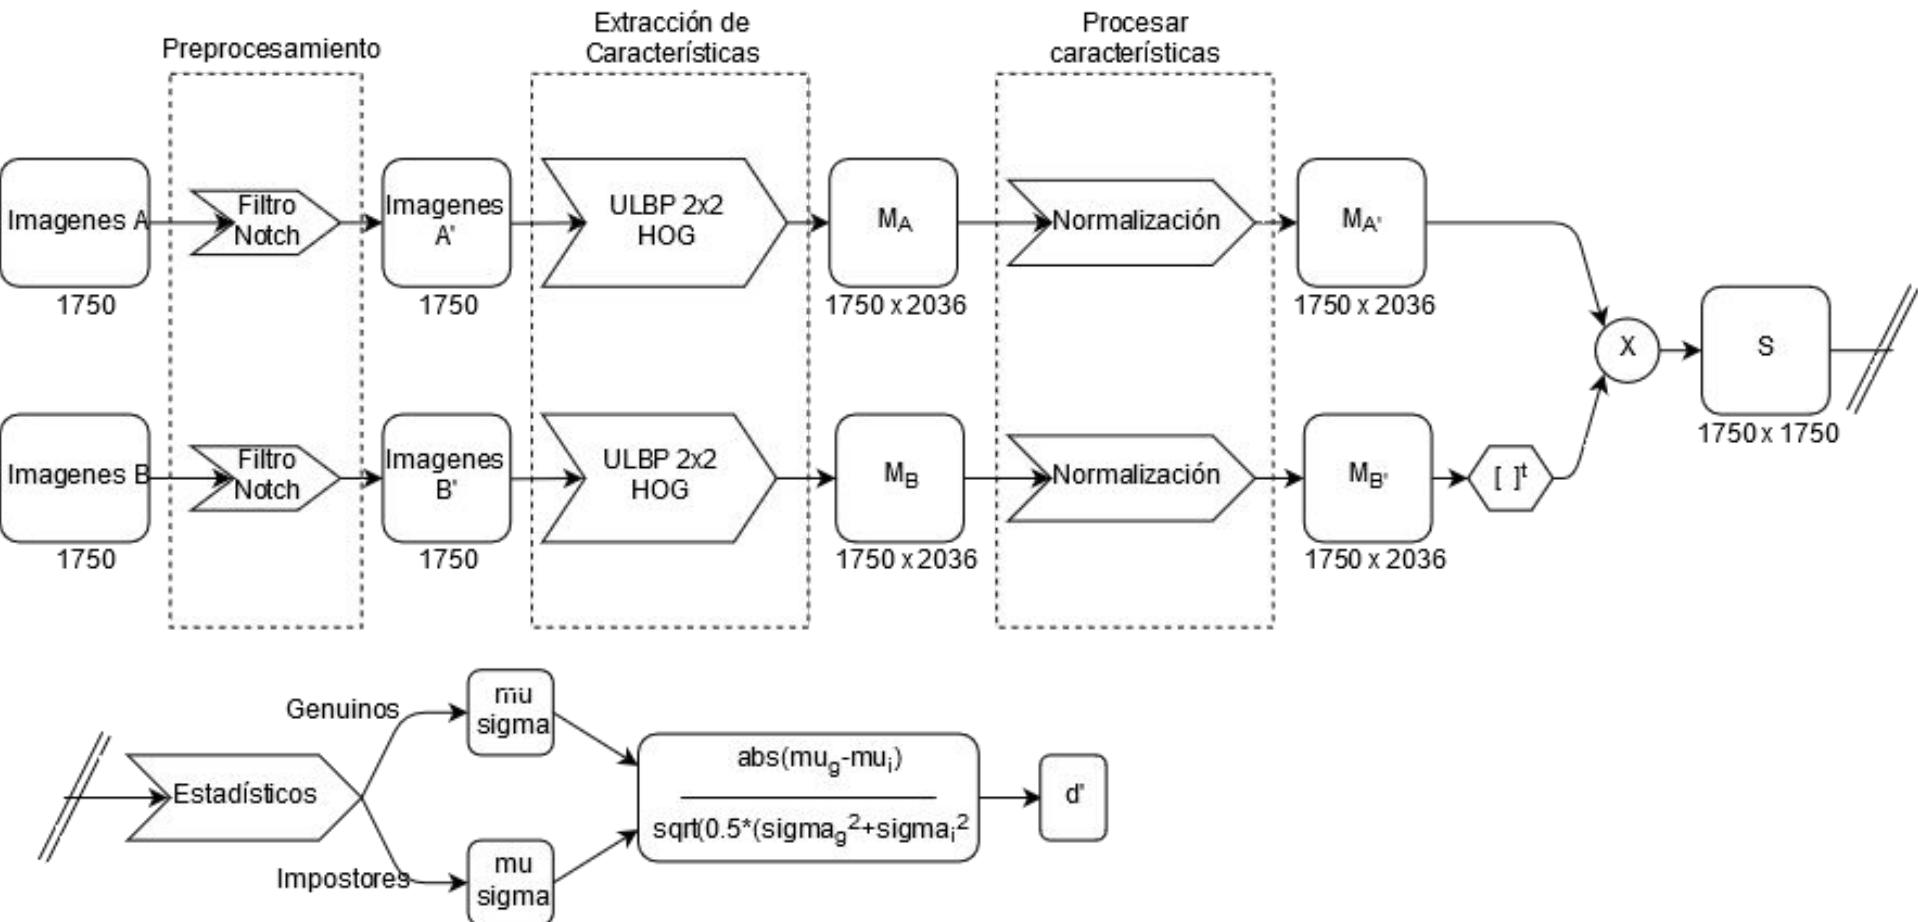
Proyecto

Reconocedor de Caras en Jóvenes con Diferencia de Edad

IIC3724 - Reconocimiento de Patrones

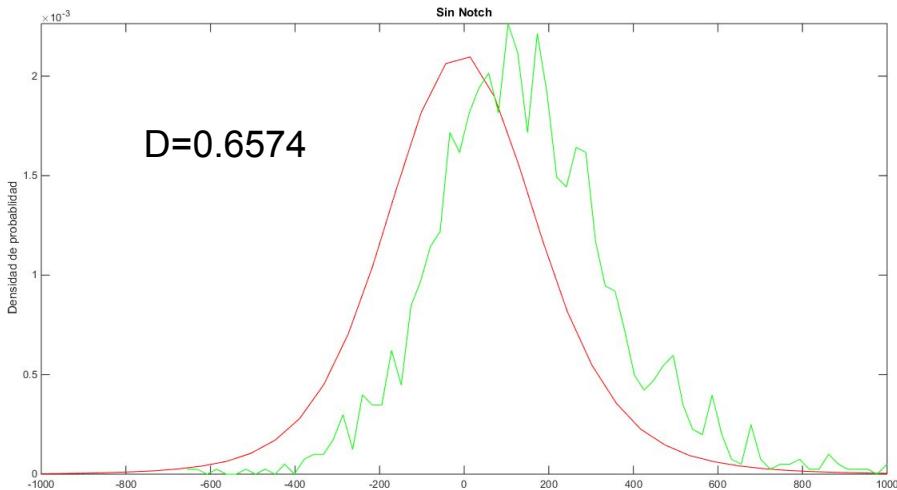
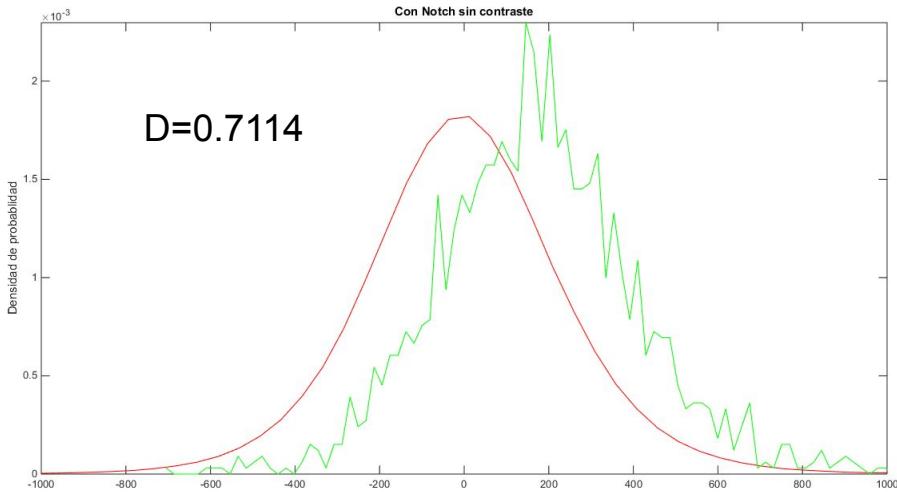
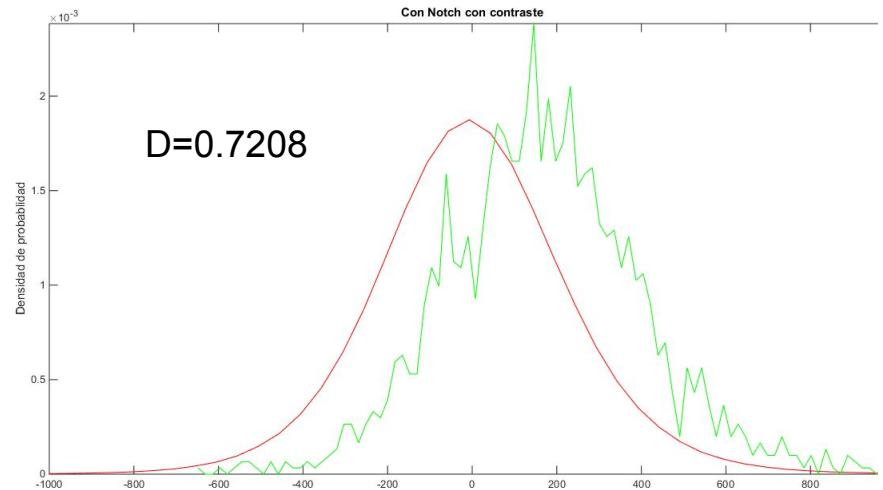
Felipe Calderara - Kevin Castillo - Christian Escobar - Simón Rodríguez

¿Que es lo que ya llevamos?



Resultados

- El resultado es mejor con filtro Notch
- La normalización de las características mejoró mucho el resultado
- Utilizar contraste mejoró el desempeño



Qué vamos a hacer

- Segmentación y
comparación de narices



- Aging
- Half-Face

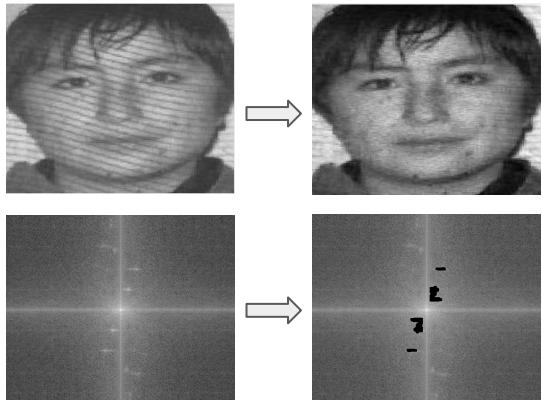


Avance Proyecto: Reconocedor de caras en jóvenes con diferencia de edad

Integrantes: Dan Berezin
Nicolás Gutiérrez
Octavio Herrera
Juan Diego Irarrázabal

Pre-Procesamiento

Filtro pasabandas para eliminar frecuencias indeseadas (notch filter)

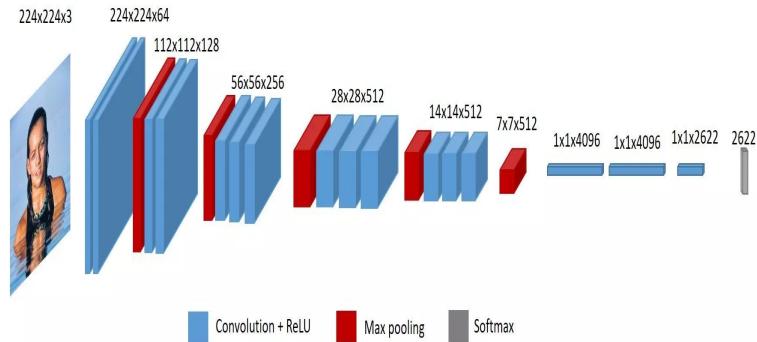


Alinear y centrar caras en función de nariz y ojos



Extracción de Características

VGG - Keras

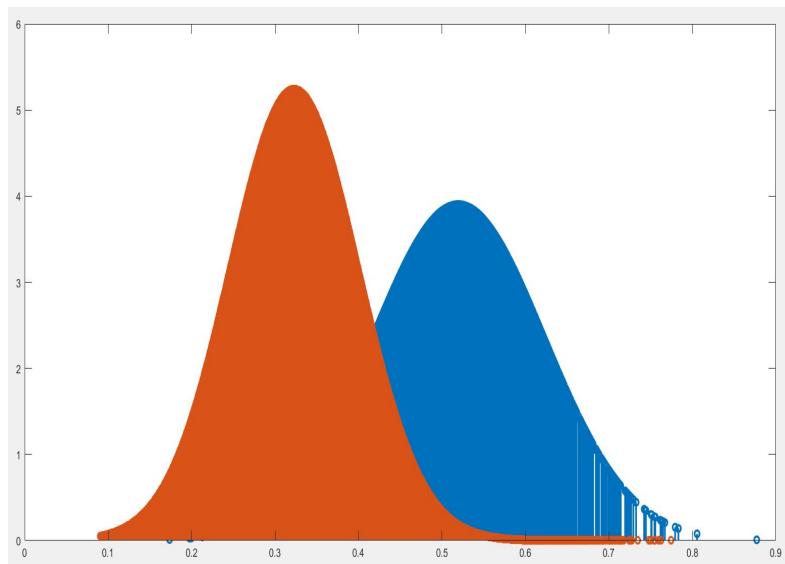


Resultados

$d' = 1.5427 \rightarrow$ Con
pre-procesamiento planteado

$d' = 1.354 \rightarrow$ Con face
alignment y filtro notch

$d' = 0.86 \rightarrow$ Sin
pre-procesamiento



$d' = 1.5427$

Trabajo Futuro

Pre-Procesamiento:

- Ecualizar imágenes
- Aplicar procesamiento dependiendo tipo de cédula de identidad

Extracción de Características:

- Probar con otras técnicas (clásicas y especializadas)
- Usar transformación de características PCA. Como la usada en:

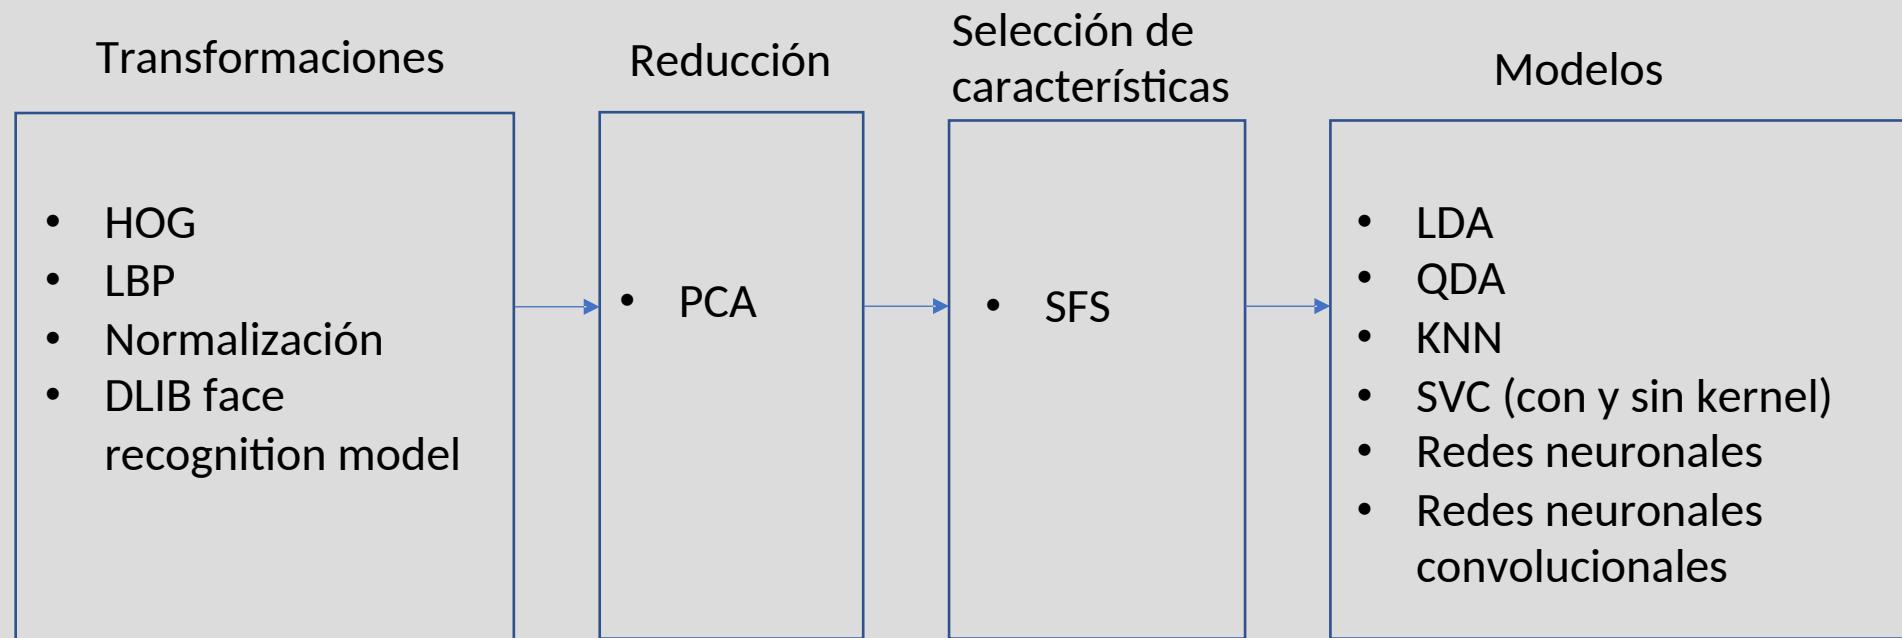
<https://www.youtube.com/watch?v=4VAkrUNLKSo&t=278s>

Reconocimiento de Patrones

Integrantes:

- Javier Dreves
- Matías Echeverría
- Guillermo Espinosa
- Constanza Ravanal

Experimentos realizados



Resultados

Transformación	d-prime	FNMR	FMR
HOG	0.28	0.49	0.4
LBP	0.21	0.325	0.58
DLIB	1.78	0.15	0.22

Pasos a seguir ...

- Usar el descriptor VGG-face para extraer mejores características de las imágenes.
- Investigar redes neuronales profundas o bayesianas.
- Buscar en la librería cv2 métodos que mejoren la calidad de la imagen.
- Lograr que DLIB face recognition model reconozca más caras.
- Buscar nuevos métodos que logran dividir las clases de mejor manera.

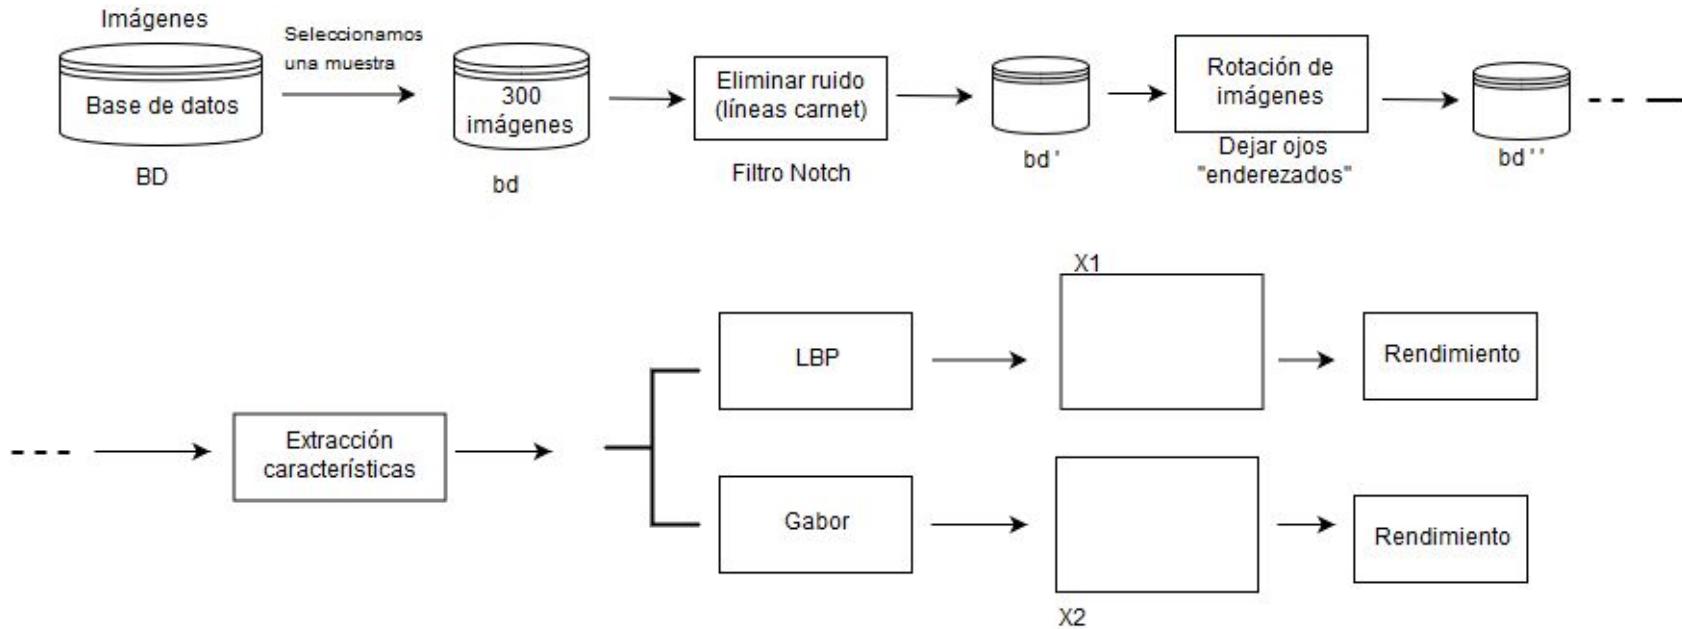
Avance Proyecto

Grupo: MeryXmas

Integrantes:

Nawel Cariman
Francisco Hevia
Mauricio Ortiz
Mónica Pérez

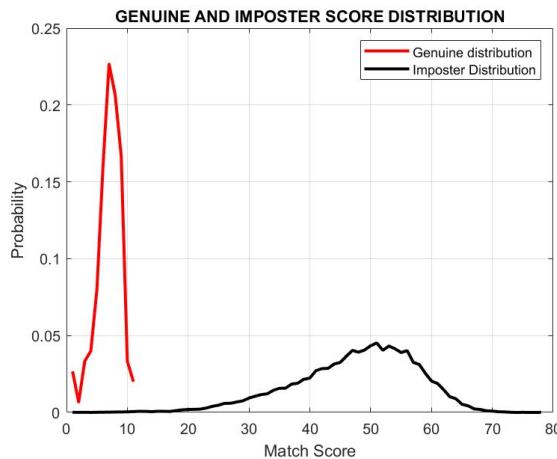
Lo realizado



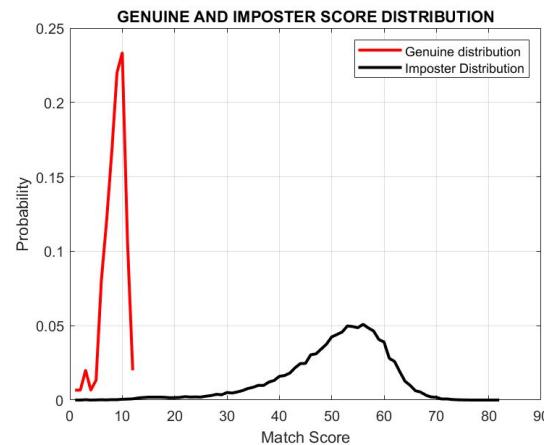
Resultados

Usando LBP para detectar las caras, obtenemos el siguiente resultado:

$$d = 1.3186$$



$$d = 1.1550$$



Por realizar

- Mejorar pre-procesamiento de las imágenes: detección de ojos tiene problemas, falta centrar por los ojos, mejorar eliminación de ruido

Avance 1 Proyecto

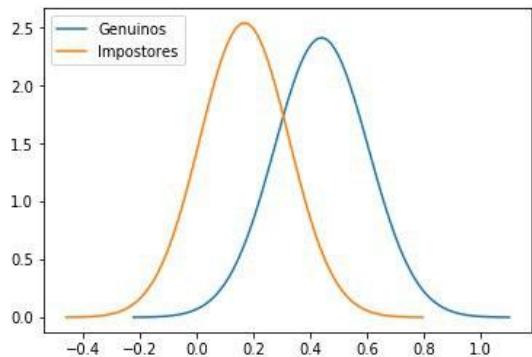
Andrés Espinosa, Raimundo Herrera,
Raimundo Manterola, Francisco Rencoret

Trabajo Realizado

- **Preprocesamiento:** Utilizamos transformadas de Fourier para eliminar líneas en fotos de carnet, junto con *Histogram Equalization* para brillo y contraste.
- **Extracción de Features:** Utilización de red preentrenada en caras para extraer features. Facenet (<https://arxiv.org/abs/1503.03832>)
- **Modelo:** Pasamos cada uno de estos embeddings por una transformación lineal (MLP) de manera de hacer *finetunning* sobre estos para optimizar el D prime.
- **Función de pérdida:** Probamos con *d-prime* y *CrossEntropy*.

Resultados

FaceNet

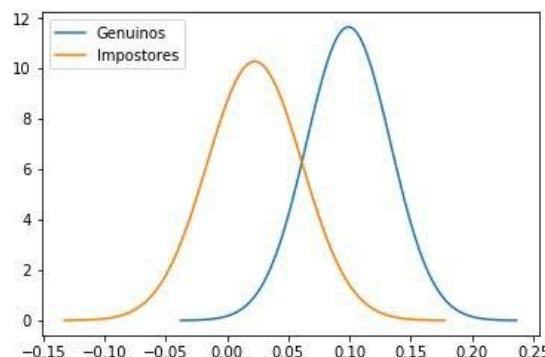


Genuinos: Mean 0.44; Std:0.15

Impostores: Mean 0.17; Std: 0.15

D-prime: 1.79

Modelo

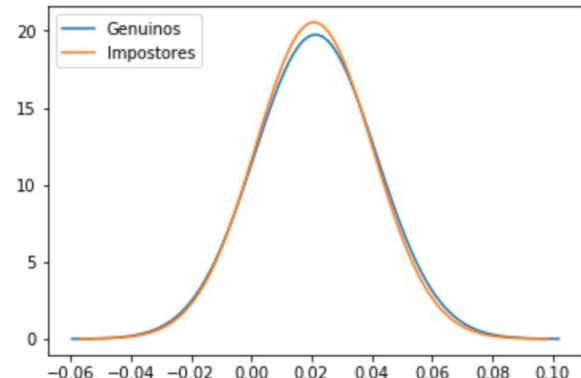


Genuinos: Mean 0.10; Std:0.03

Impostores: Mean 0.02; Std: 0.04

D-prime: 2.09

Modelo + preprocessamiento



Genuinos: Mean 0.02; Std:0.02

Impostores: Mean 0.02; Std: 0.02

D-prime: 0.03

Próximos Pasos

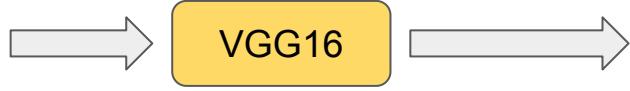
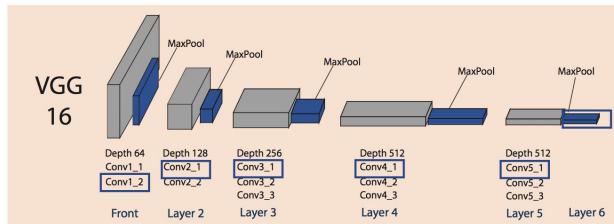
- Hacer *face alignment*.
- Mejorar la ecualización y los niveles de contraste/brillo.
- Intentar un método más complejo de *fine-tunning* de embeddings.
- Idea: Utilizar Transformer en vez de MLP para esto.
- Hacer data augmentation sobre set de entrenamiento.



Avance Proyecto

Integrantes:

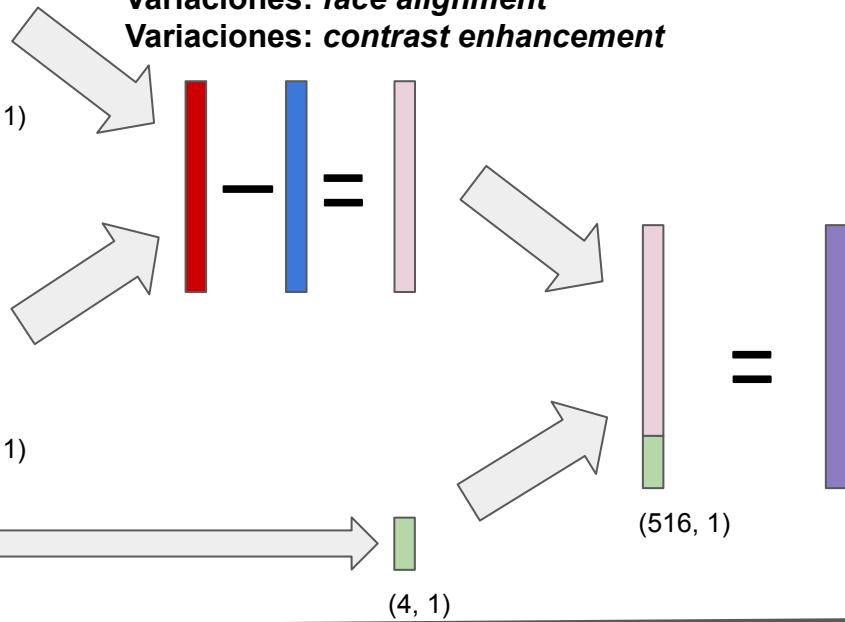
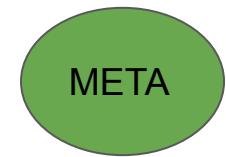
Juan Enrique Castro
Arturo del Real
Ignacio Jara
Martín De la Fuente



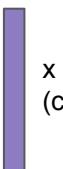
Extracción de imágenes con VGG
Extracción de vector de características para cada persona
Generación de personas falsas
Pruebas con múltiples clasificadores
Variaciones: face alignment
Variaciones: contrast enhancement

(512, 1)

(512, 1)



DATA AUGMENT

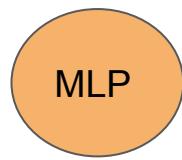


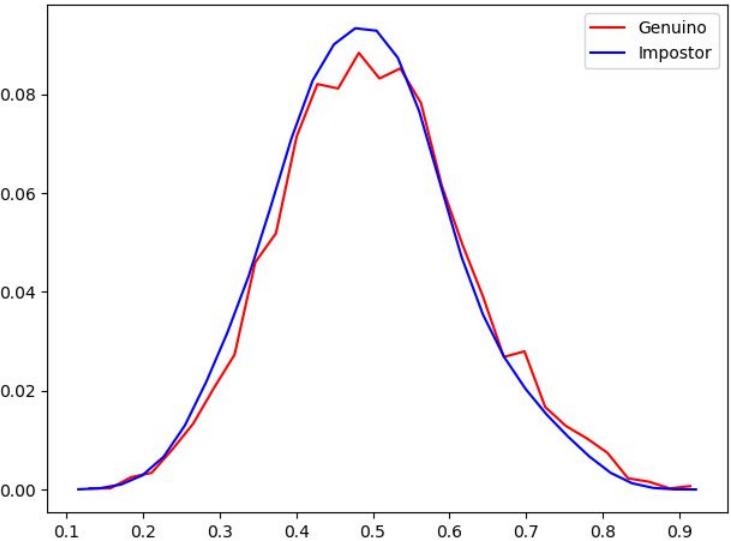
x 1750
(clase 1)



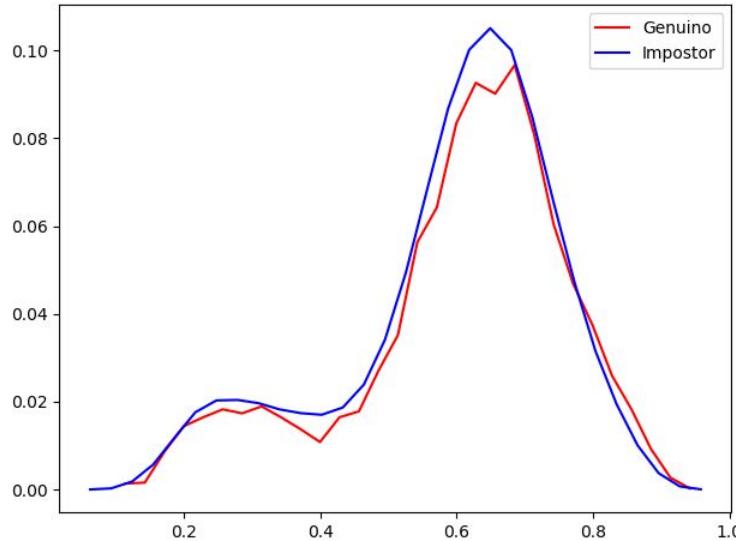
x 1750
(clase 1)
+
x 1750
(clase -1)

ENTRENAMIENTO





$D' = 0.07 | Acc = 0.5$



$D' = 0.05 | Acc = 0.5$

Posibles explicaciones a los resultados

- ❑ La red VGG16 no extrae buenas características en este set de datos.
- ❑ Tenemos muy pocos datos para entrenar. Si queremos entrenar una red neuronal que sea capaz de extraer patrones del vector diferencia y los metadatos se necesitan muchos ejemplos.
- ❑ Falta hacer más procesamiento en la imagen de carnet.
- ❑ Falta usar los metadatos de forma más ‘inteligente’.

Proyecciones

- ❑ Probar otros métodos de extracción (ej: facenet)
- ❑ Probar otros métodos de análisis (triplet loss)
- ❑ Quitar líneas en carnets amarillos
- ❑ Usar distintos criterios de clasificación según los metadatos (sexo, edad)



Pedro
Bahamondes



Javiera
Cortés



Felipe
Garrido



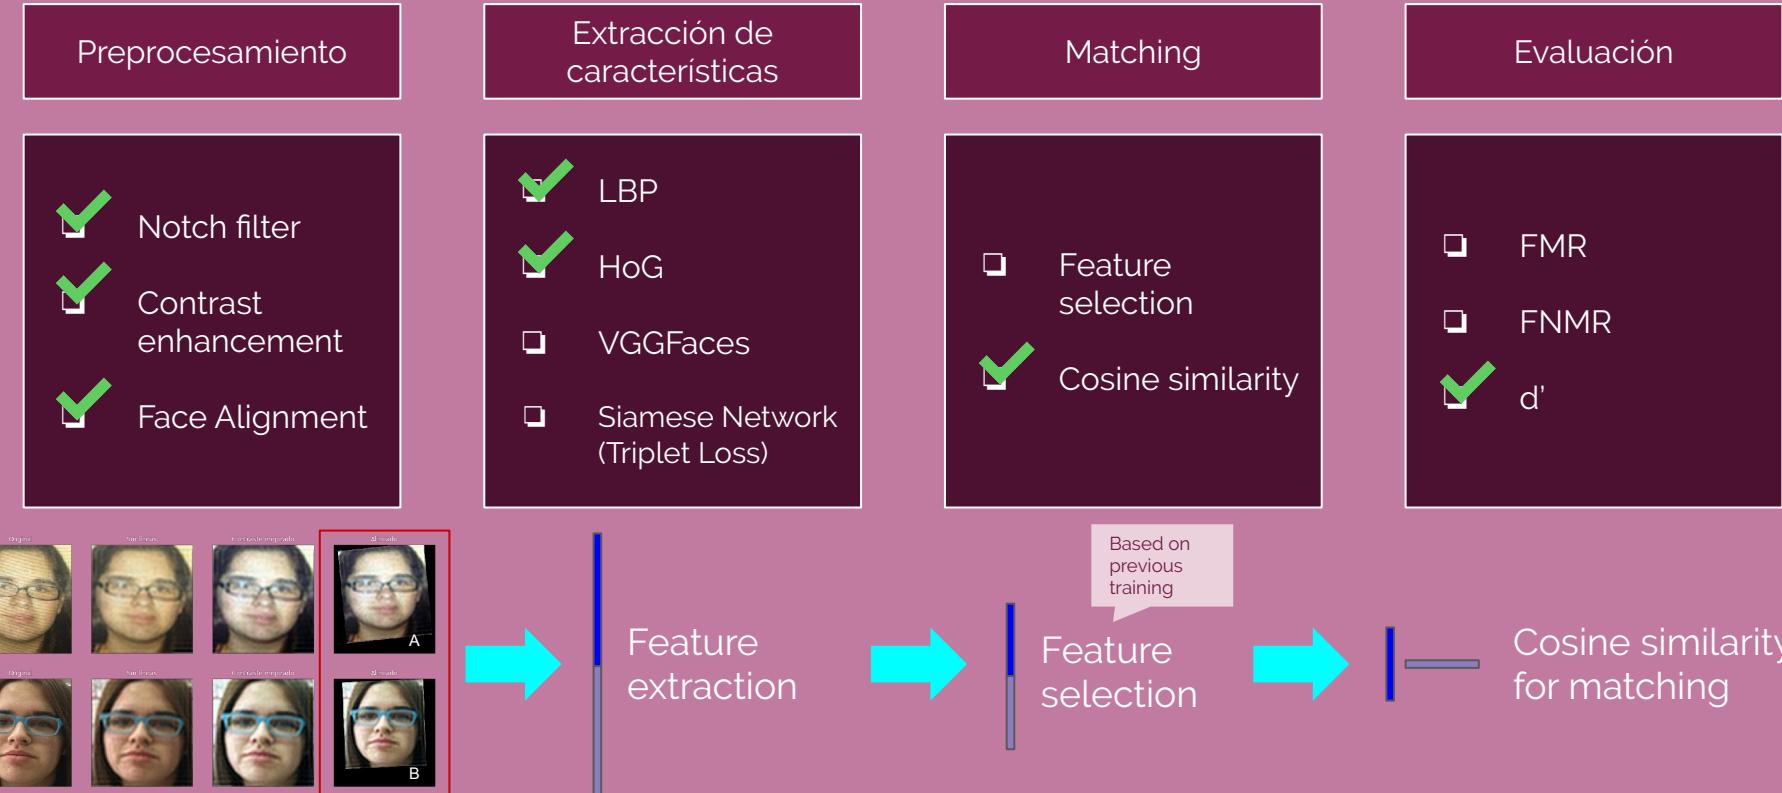
Guillermo
Yáñez

RecTitos

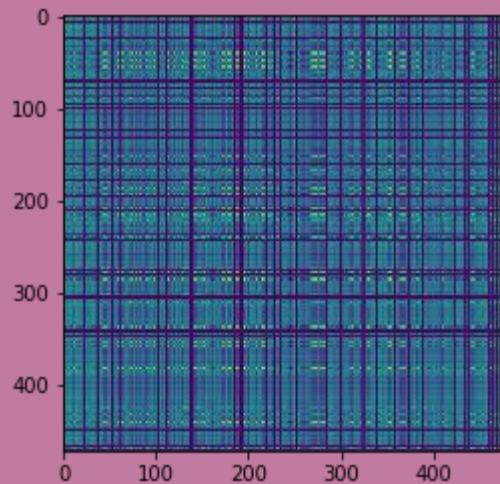
Reconocimiento de Patrones

Departamento de Ciencias de la Computación
Escuela de Ingeniería
Pontificia Universidad Católica de Chile

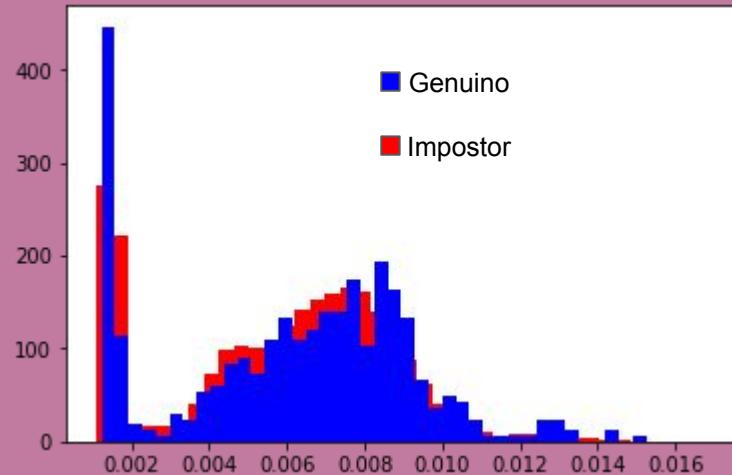
Estado de Avance del Proyecto



Resultados Obtenidos



$d' = 0.9422$



Trabajo pendiente

Preprocesamiento

- Notch filter
- Contrast enhancement
- Face Alignment

Extracción de características

- LBP
- HoG
- VGGFaces
- Siamese Network (Triplet Loss)

Matching

- Feature selection
- Cosine similarity

Evaluación

- FMR
- FNMR
- d'

Preprocesamiento

Pendiente

- Experimentos masivos, contrastes de resultados, determinación de factores relevantes, informe.