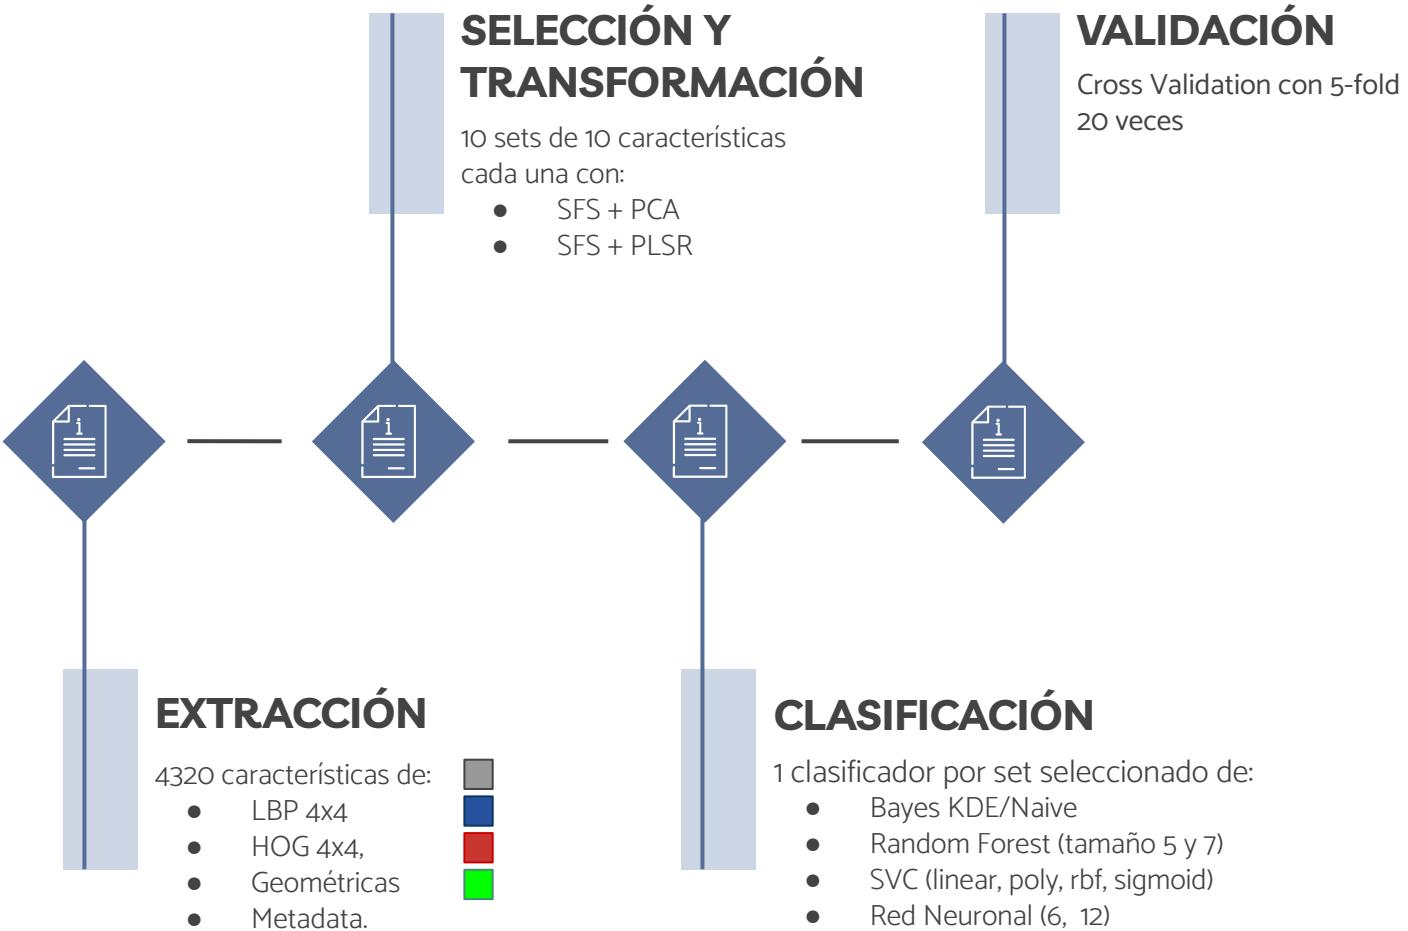


PRESENTACIÓN DE AVANCE

Grupo CFGMJ



ESTADO DE AVANCE



RESULTADOS

LBP (Gris y Rojo)
HOG (Gris y Rojo)
Geométricas
Metadata

Extracción características

**SFS + PCA : 10
componentes finales**

Selección de características

**Random Forest de
profundidad 7: 50.53+/-1%**

Clasificación

TRABAJO FUTURO

SELECCIÓN DE CARACTERÍSTICAS

Cantidad de parámetros a seleccionar usando SFS o PCA.

Probar distintas combinaciones de datos para usar.

HP-TUNING

Probar con nuevos hiperparámetros para los modelos que lo requieran

CNN

Según varios papers el uso de una CNN es sumamente efectivo para este problema.

Tenemos la intención de probarlo como un clasificador.

Reconocimiento de Patrones
Proyecto final
Clasificación de Lesiones de Piel

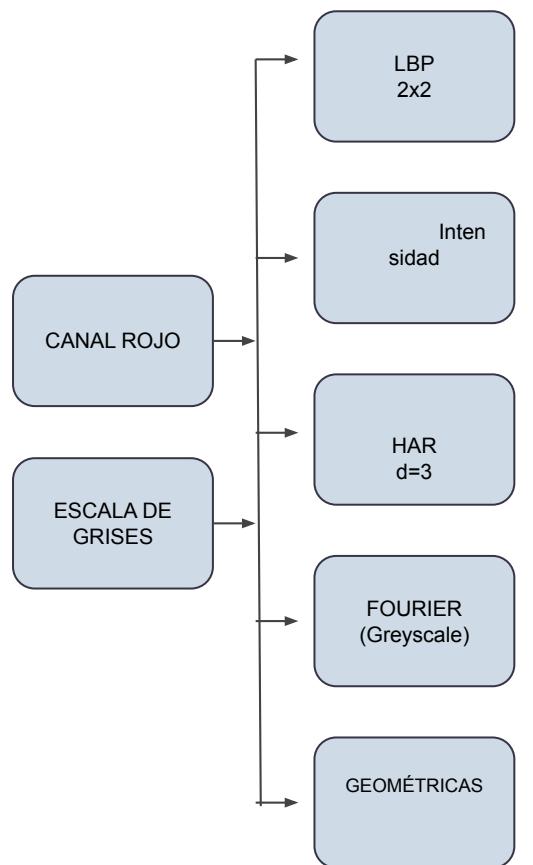
GRUPO “DRIMTIM-PATRON”

Nicole Briones
Franco Bruña
Juan Francisco Farren
Benjamín Martínez
Gonzalo Moraga



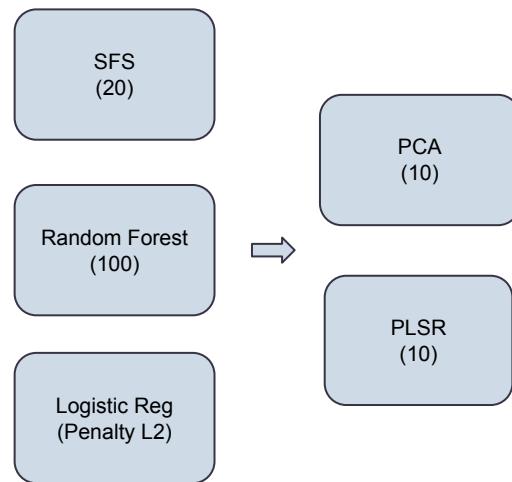
Pontificia Universidad Católica de Chile

BLOQUE 1
Extracción de características



Features:
Canal rojo: 288
Escala de grises : 304

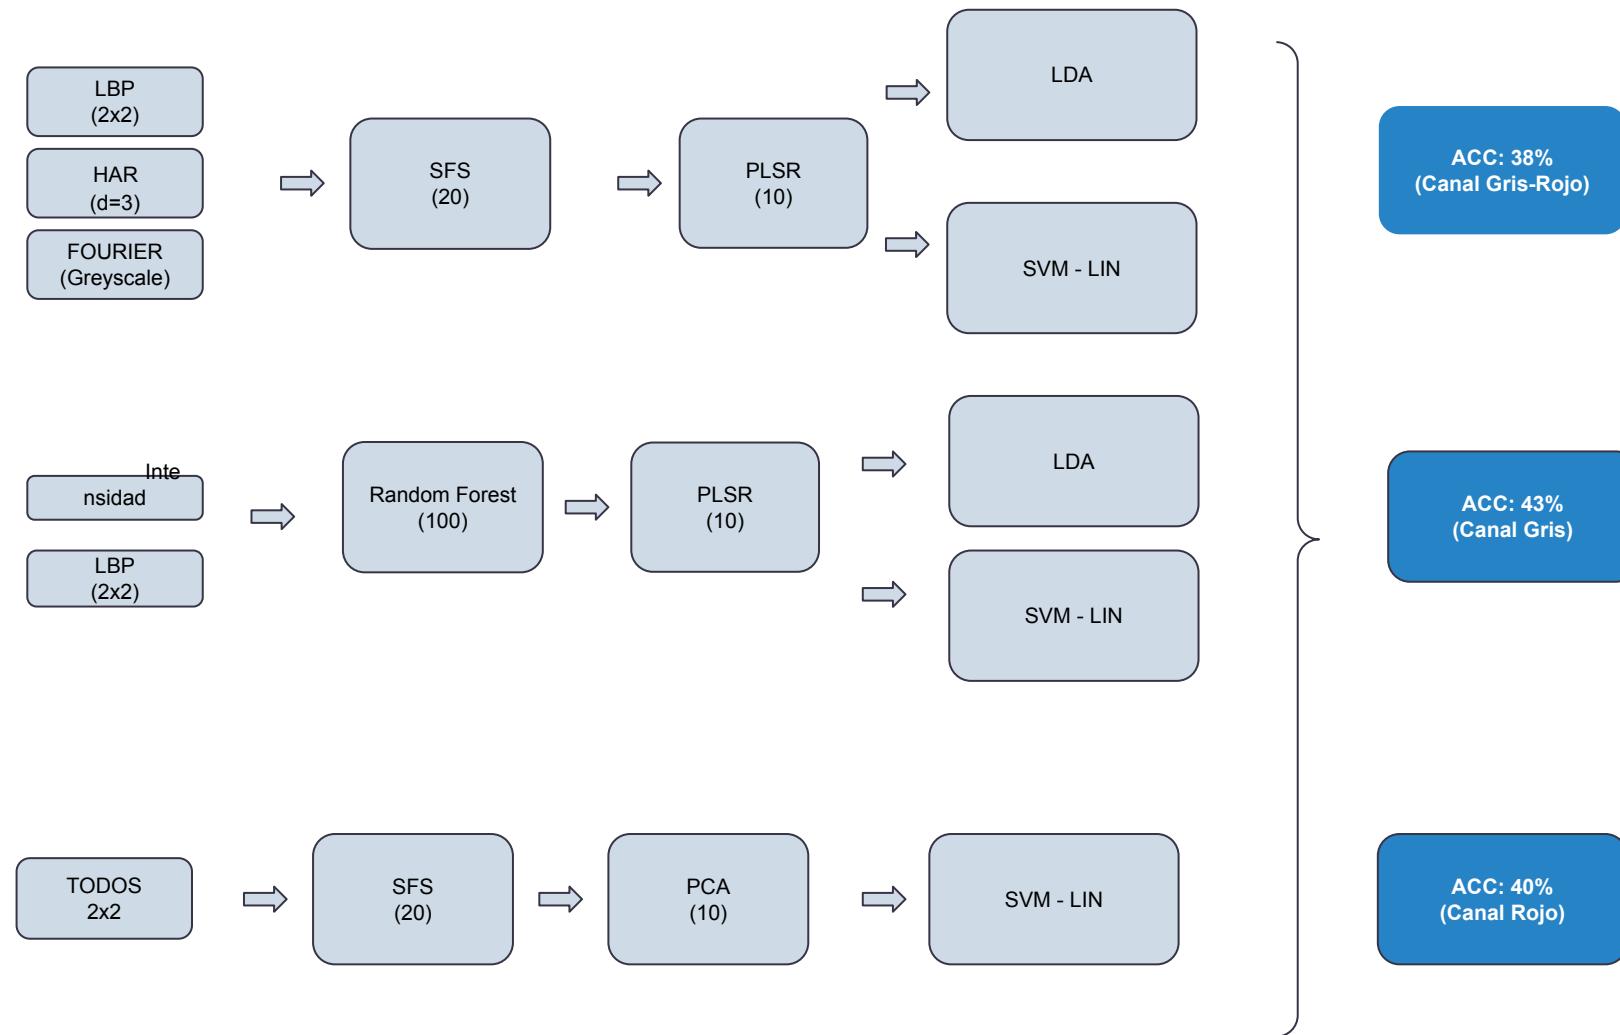
BLOQUE 2
Selección/Transformación



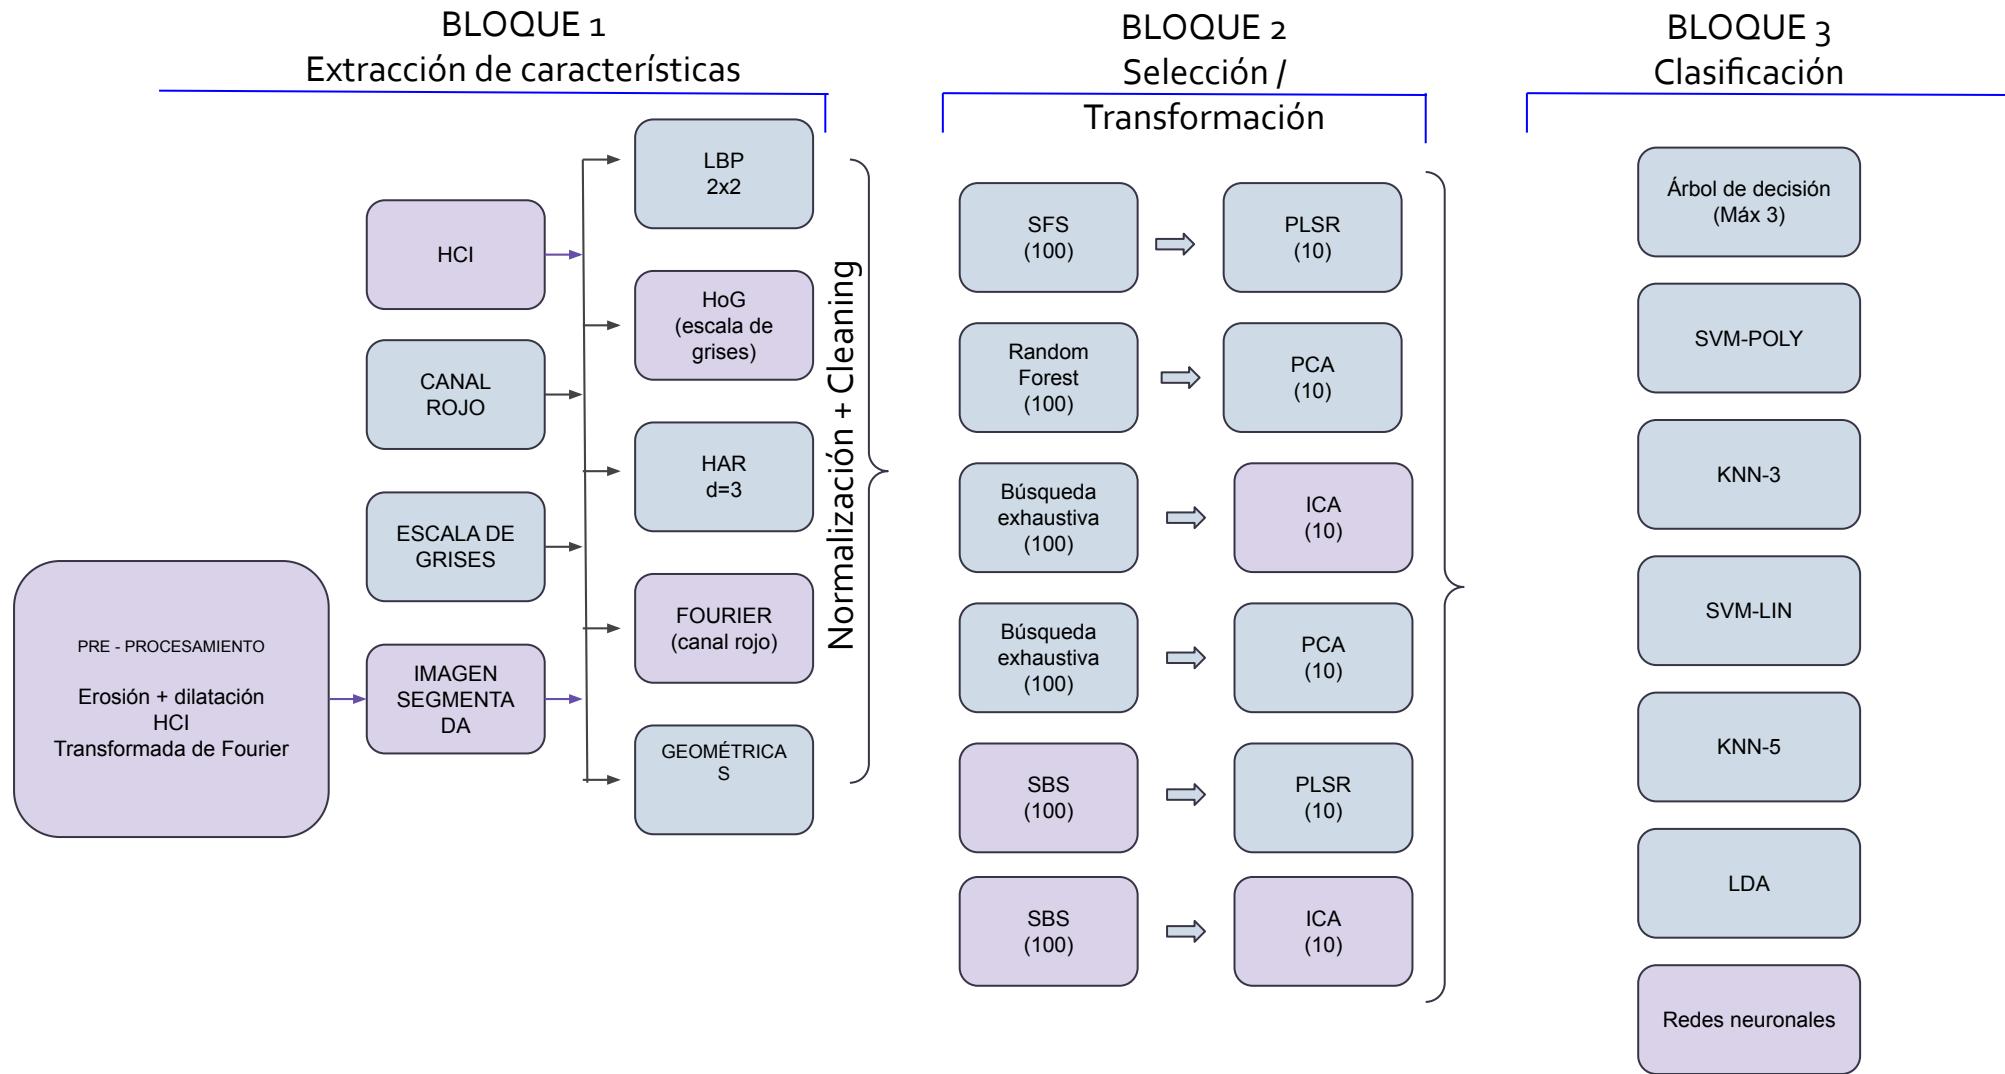
BLOQUE 3
Clasificación



Resultados Obtenidos



Trabajo futuro



Avance de proyecto

Grupo: TURKONES

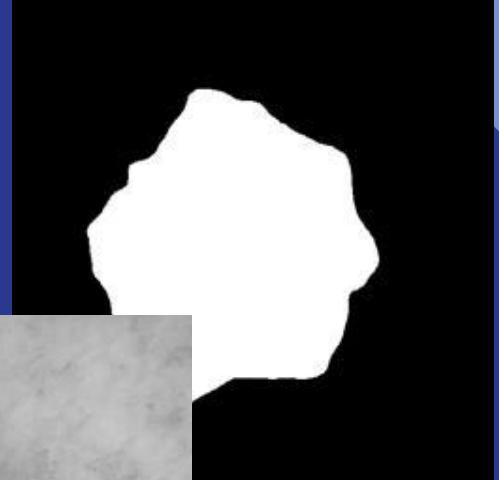
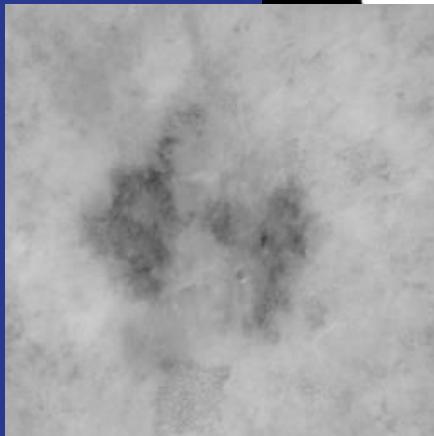
Sebastian Acuña

Mayron Barahona

Daniel Guzmán

Javier Díaz Toledo

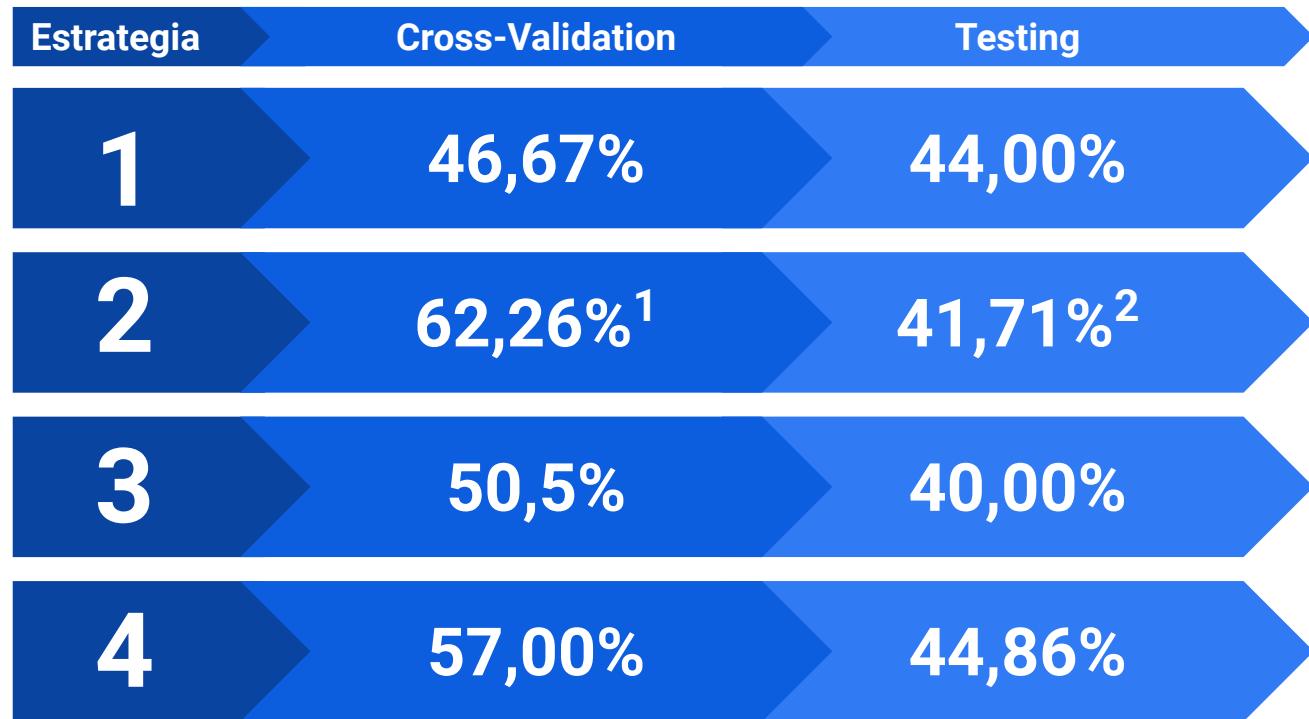
Pablo Orellana



Estrategias

	Características	Transformación/Selección	Clasificador
1	Canal rojo segmentado: HOG y LBP	PLSR (100) \mapsto SFS (30)	LDA
2	Canal rojo sin procesar: Haralick, LBP, HoG y Gabor	PCA (50) \mapsto SFS (30) \mapsto PCA (12)	Random Forest (8)
3	Características Geométricas + [2]	ICA(50) \mapsto SFS(25)	DMin
4	[1] + [3]	PCA (100) \mapsto SFS (30)	QDA

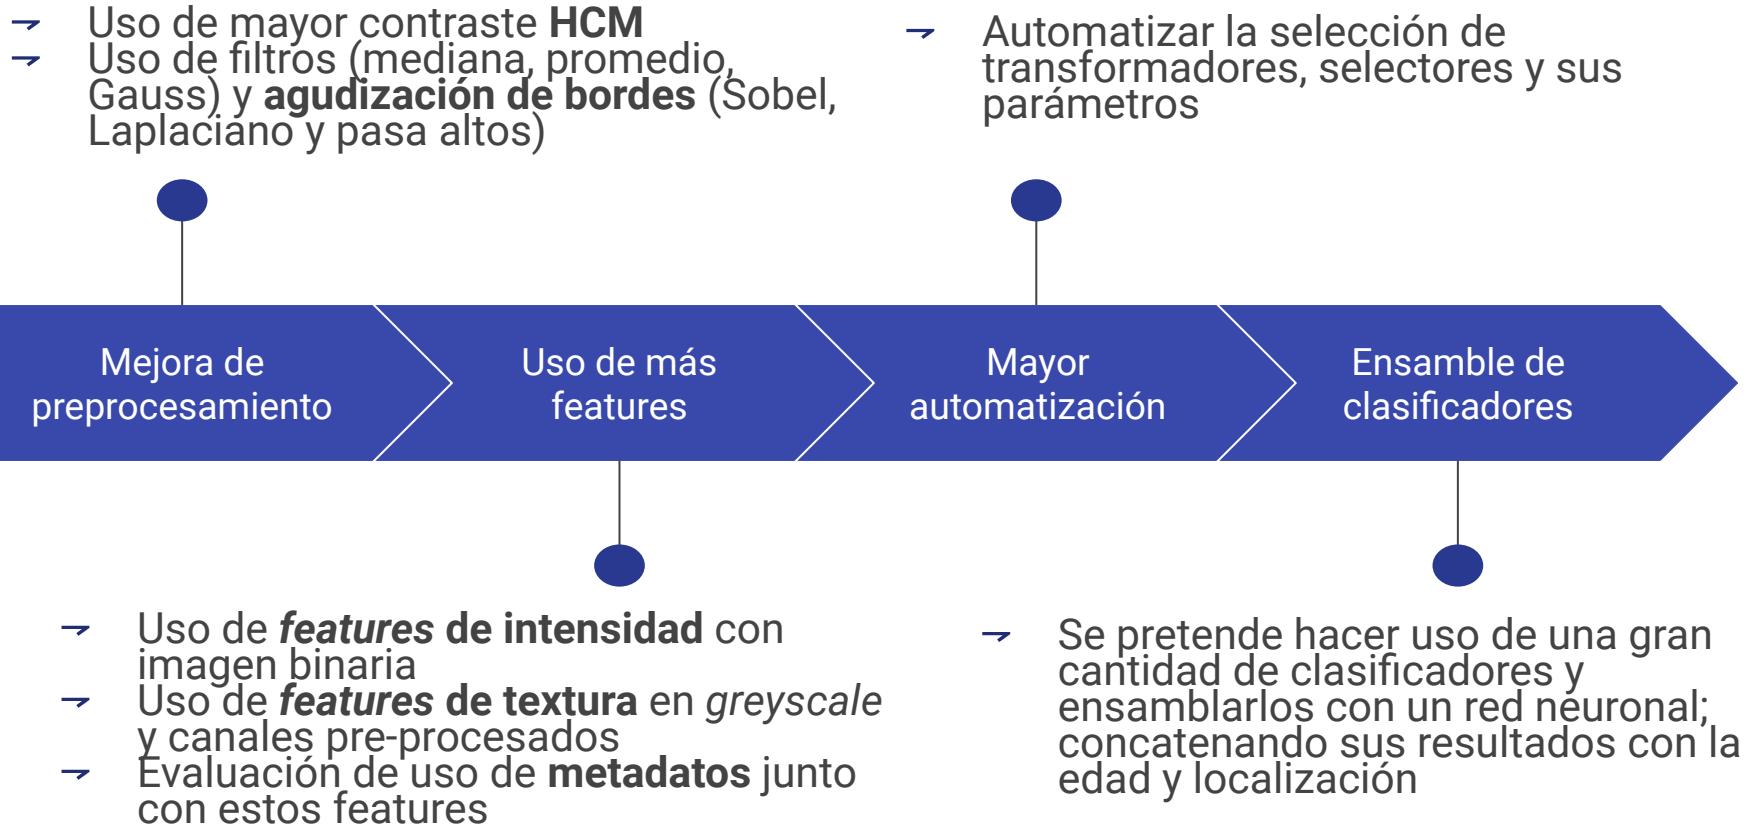
Resultados



¹ Osciló entre 61% y 63% de precisión

² Oscila entre 40% y 44% de precisión

Trabajo futuro



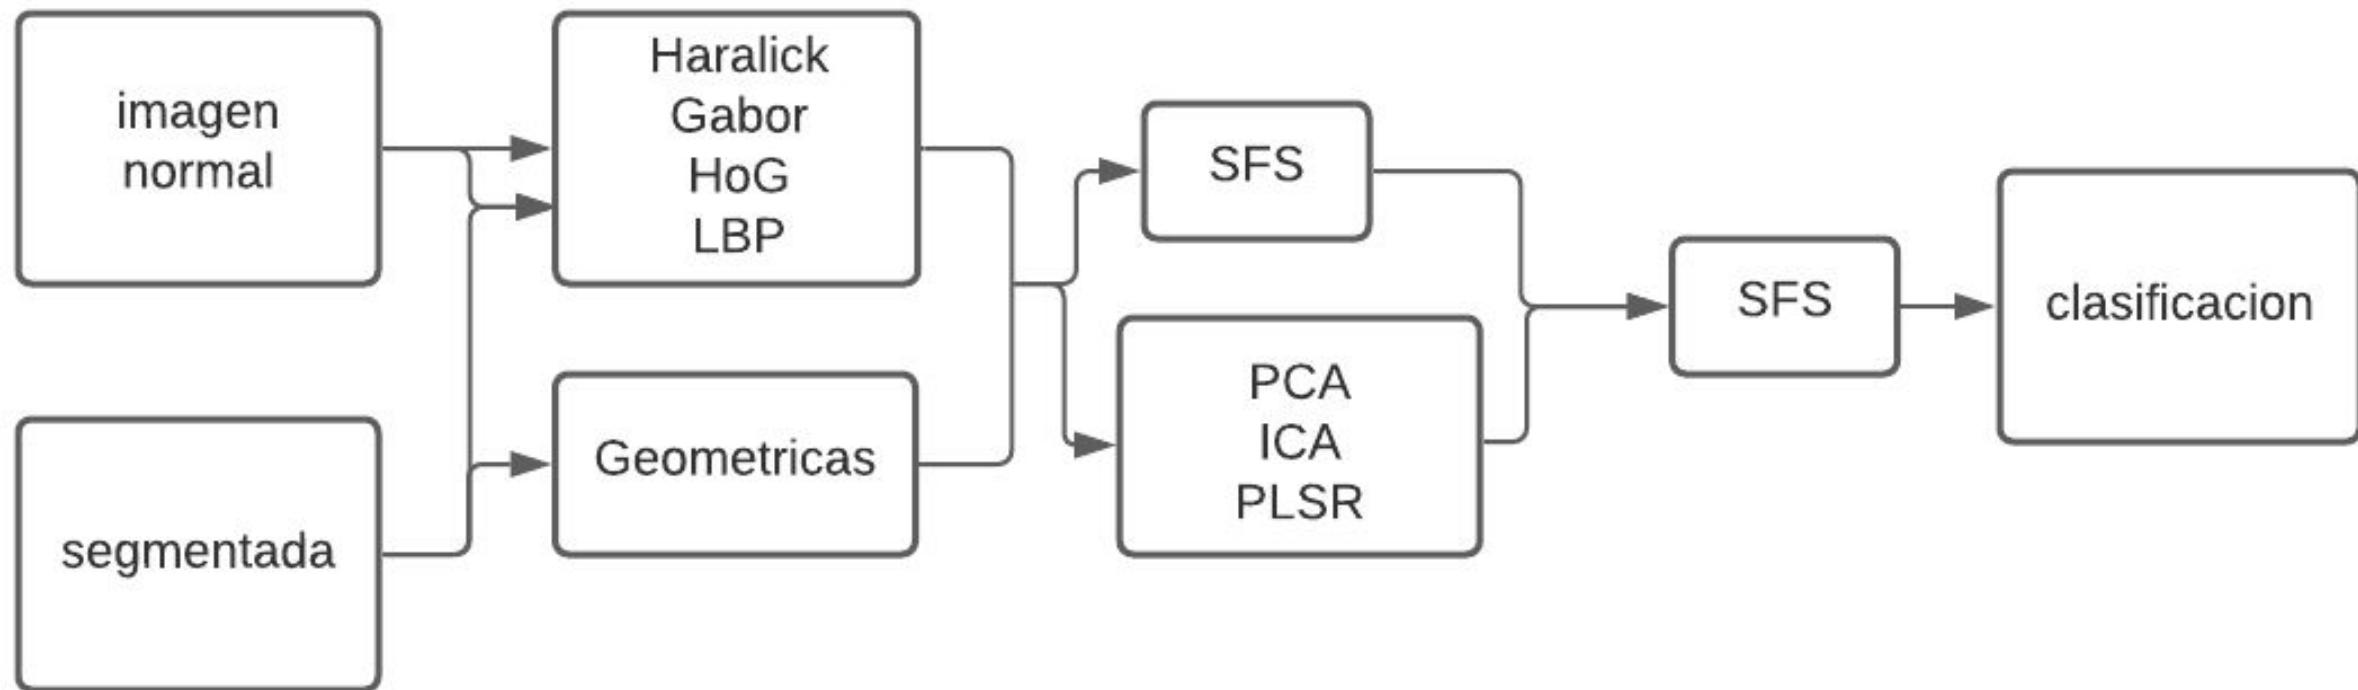
Grupo: SVM-PLUS

Integrantes:

Joaquín Hofmann

Matías Galetovic

Tomás Ladrix



Resultados Obtenidos

1. Método KNN

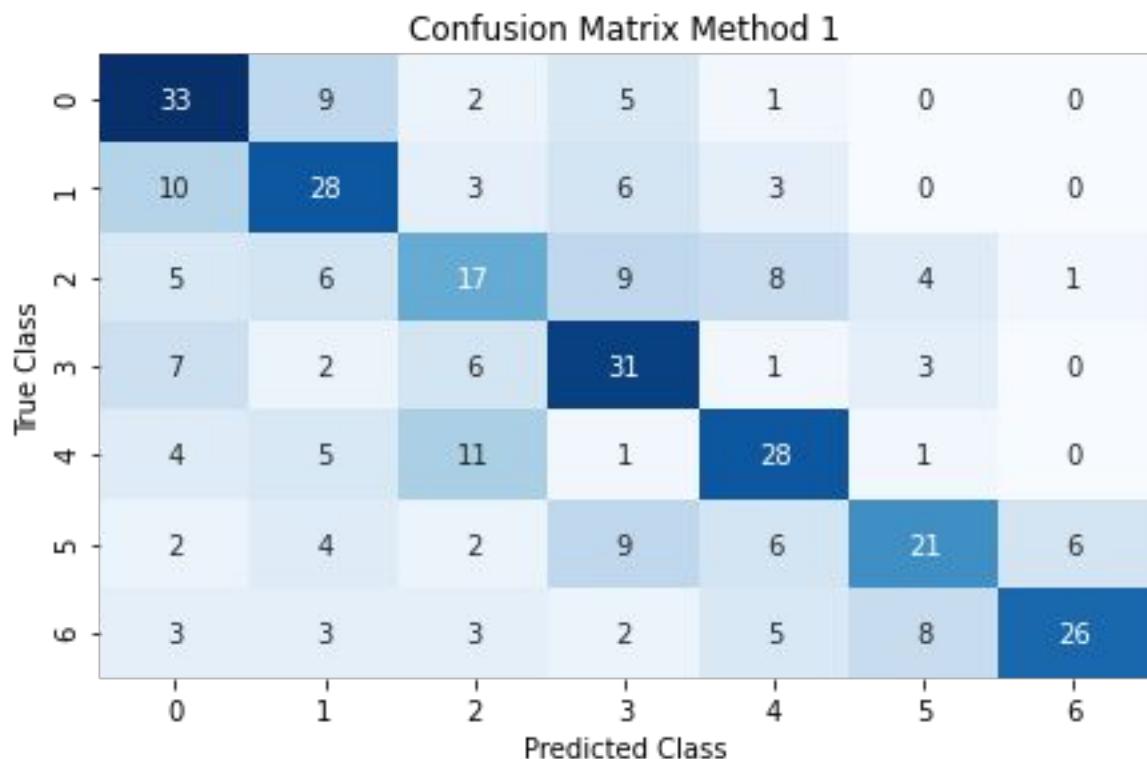
- Train: 76%
- Test: 52.5%

2. Red Neuronal

- Train: 76.8%
- Test: 35.4%

3. Transformaciones en Paralelo + SFS + Random Forest

- Train: 50.2%
- Test: 32.0%



Pasos Siguientes

- Probar con otros espacios de colores:
 - HSL, HSV, YUV, YPbPr, YCbCr, etc.
- Utilizar clasificación separada, primero clasificar benignos/malignos y después las 7 clases
- Enfocarse en disminuir diferencia del accuracy entre training y testing

8 de Julio de 2021

AVANCE PROYECTO SLC

MATLOVE

Javier Castro



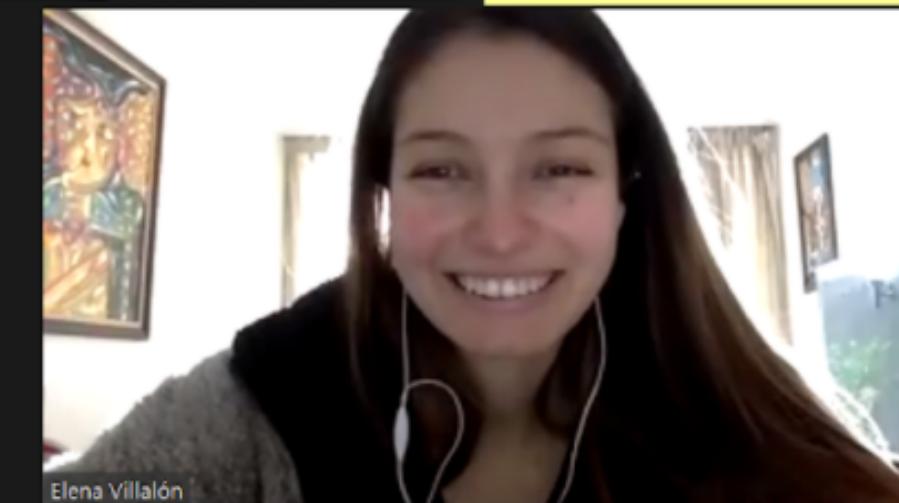
Bernardo Barías



Constanza Molina

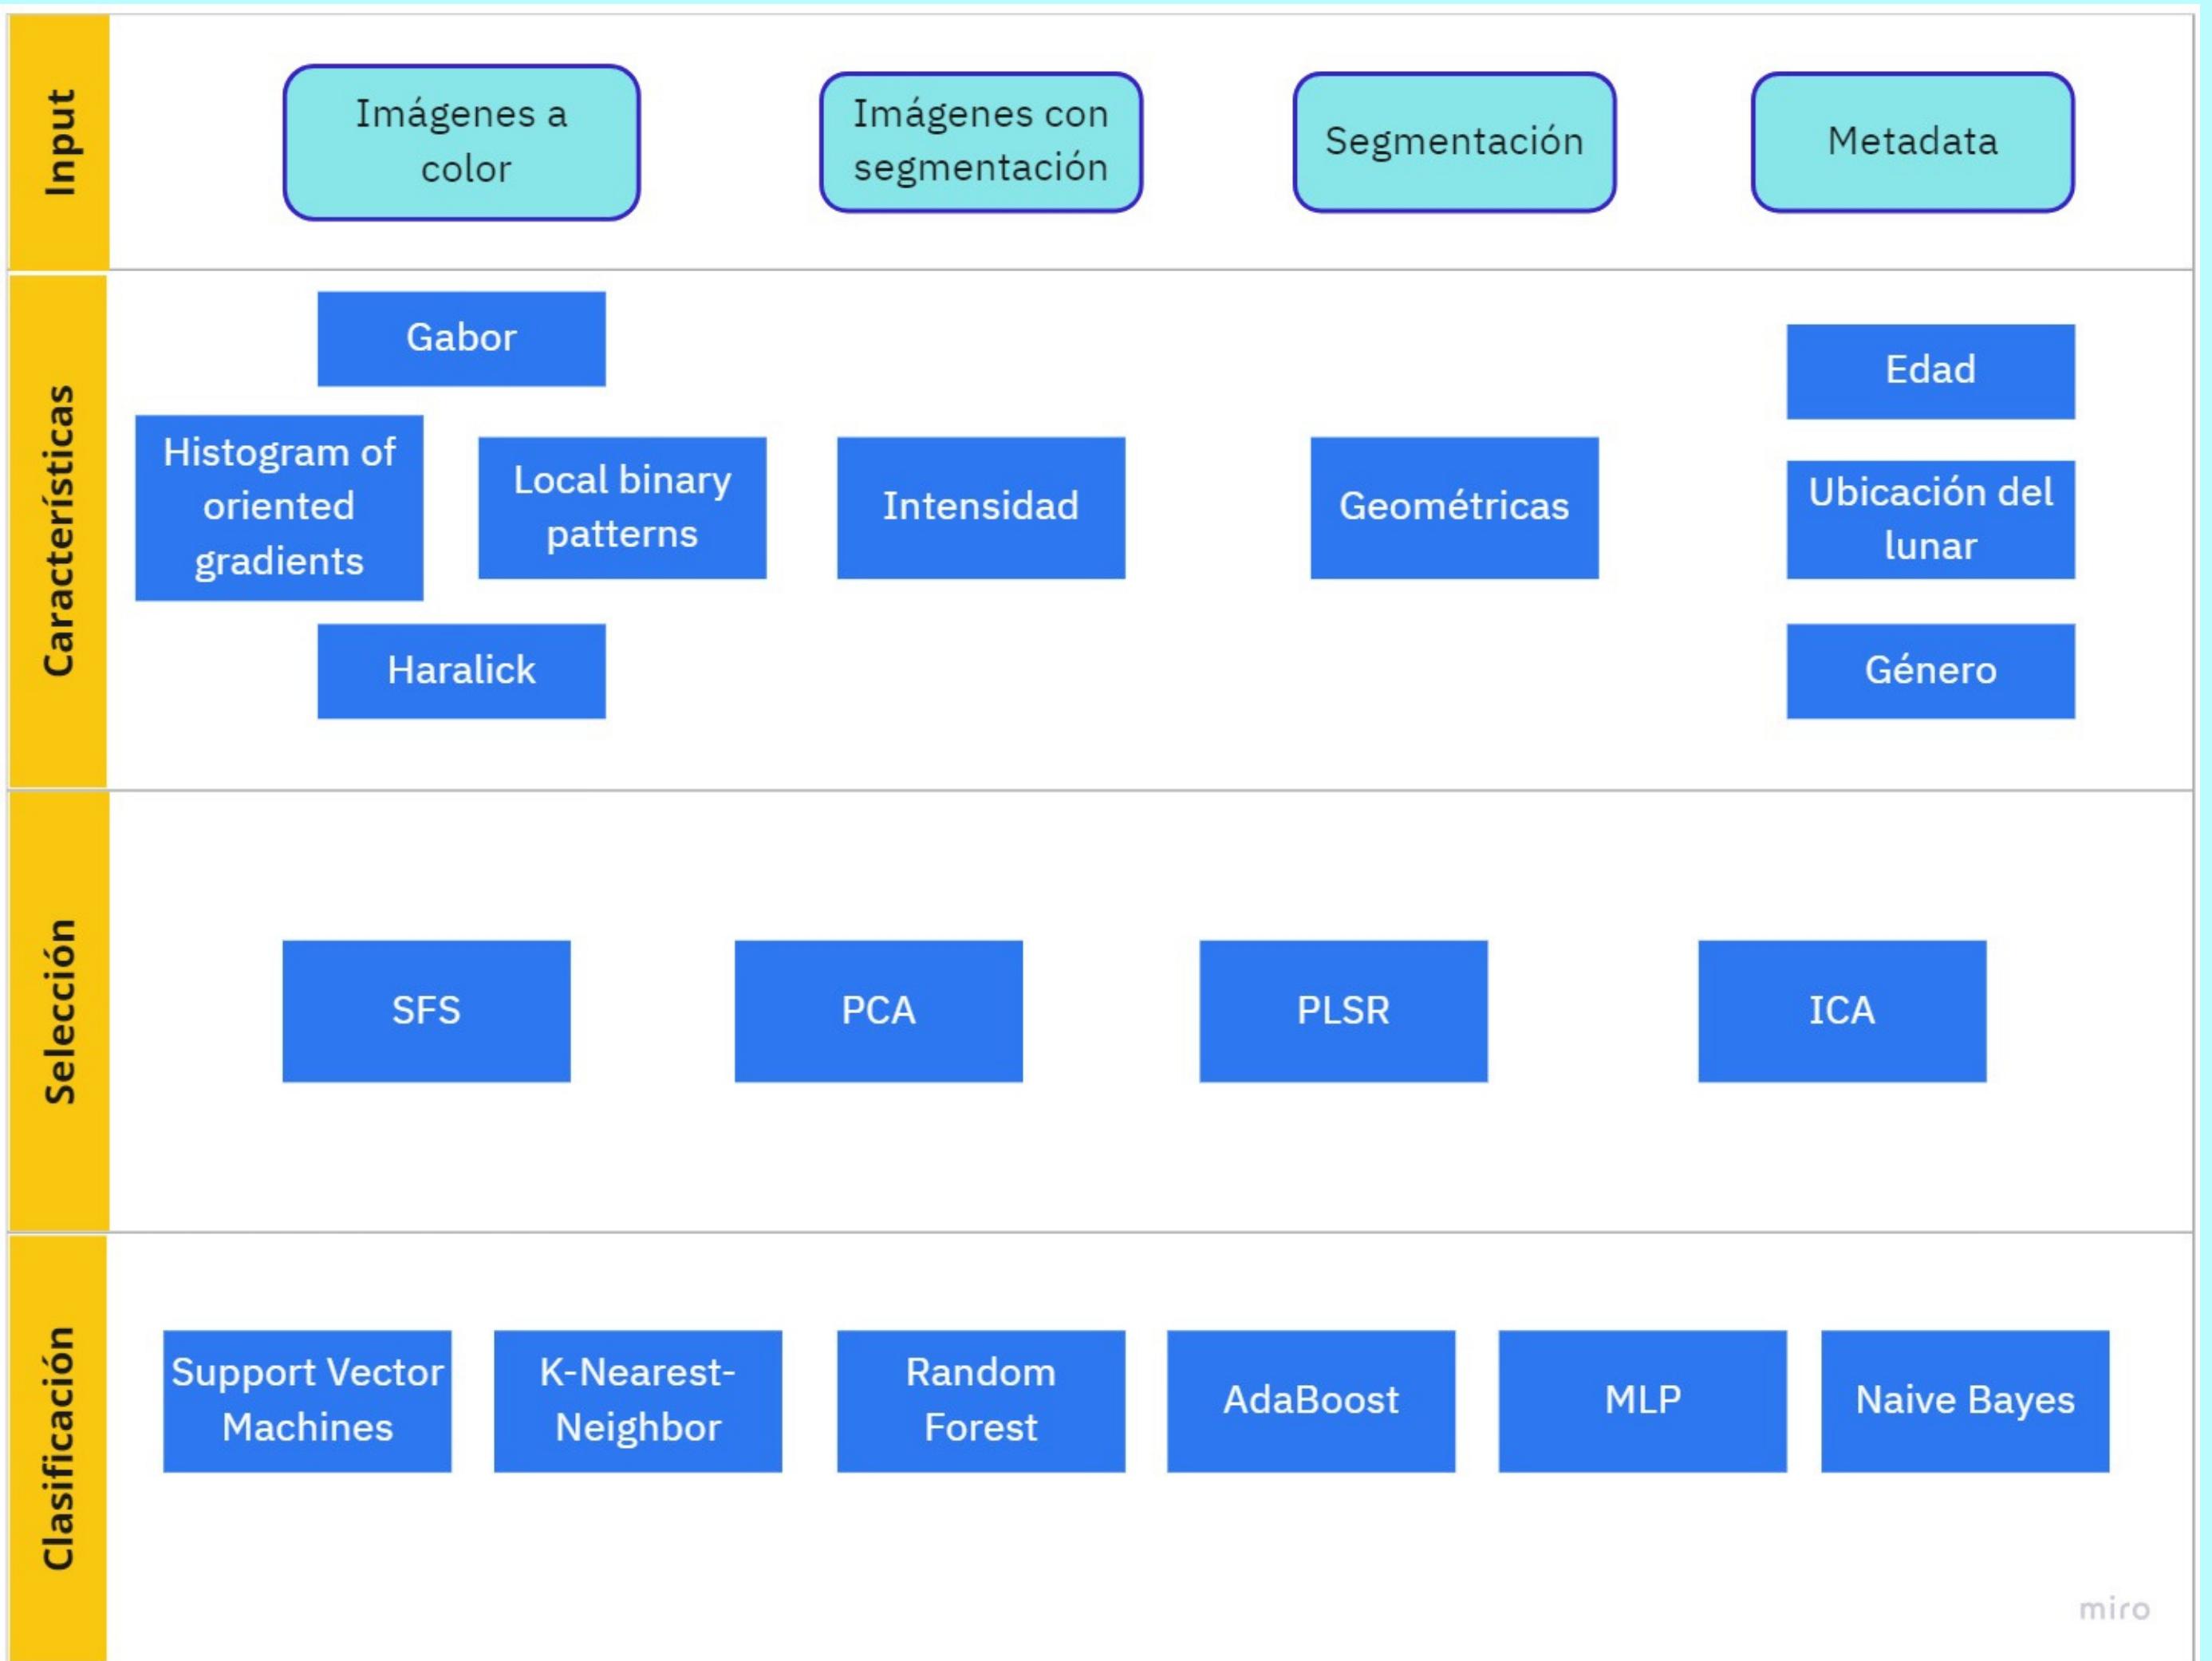


Elena Villalón



Lucas Suárez

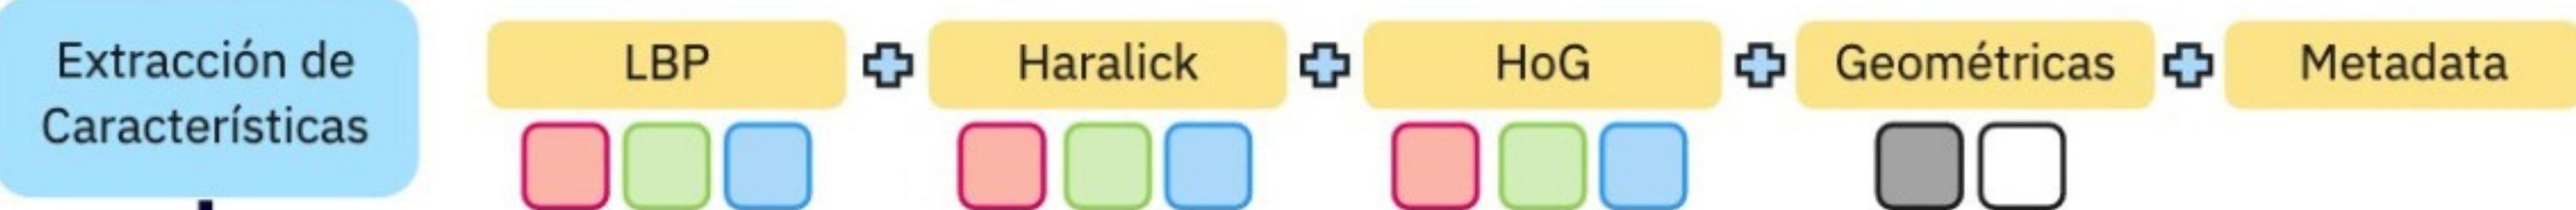




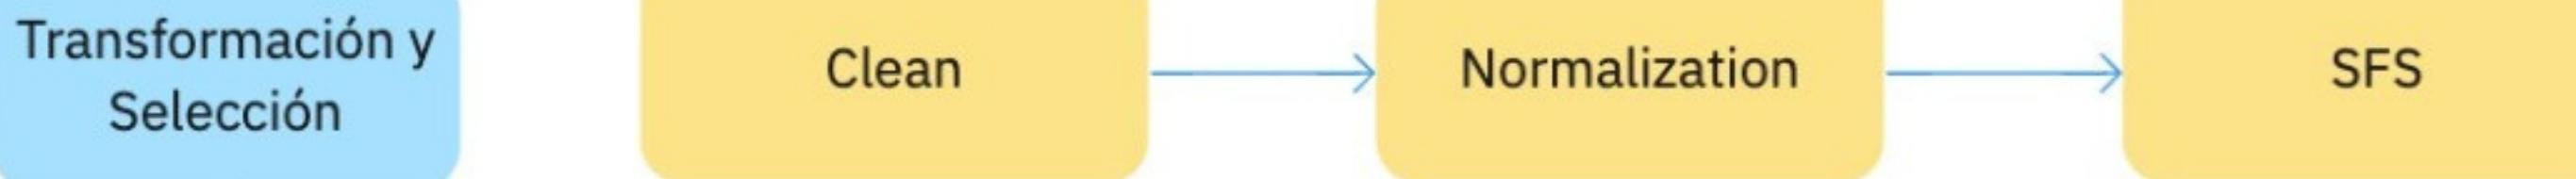
Estrategias

Utilizadas

Bloque 1



Bloque 2



Bloque 3



Mejor

Estrategia

Trabajo Futuro

1

Extracción de nuevas características utilizando imágenes segmentadas.

2

Reforzamiento de los mejores flujos y creación de nuevas estrategias.

3

Probar ensamblajes.

4

Ablation Study.



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Presentación de Avance

Proyecto SLC: Skin Lesion Classification
Curso de Reconocimiento de Patrones

K-TEAM

Ignacio Astorga

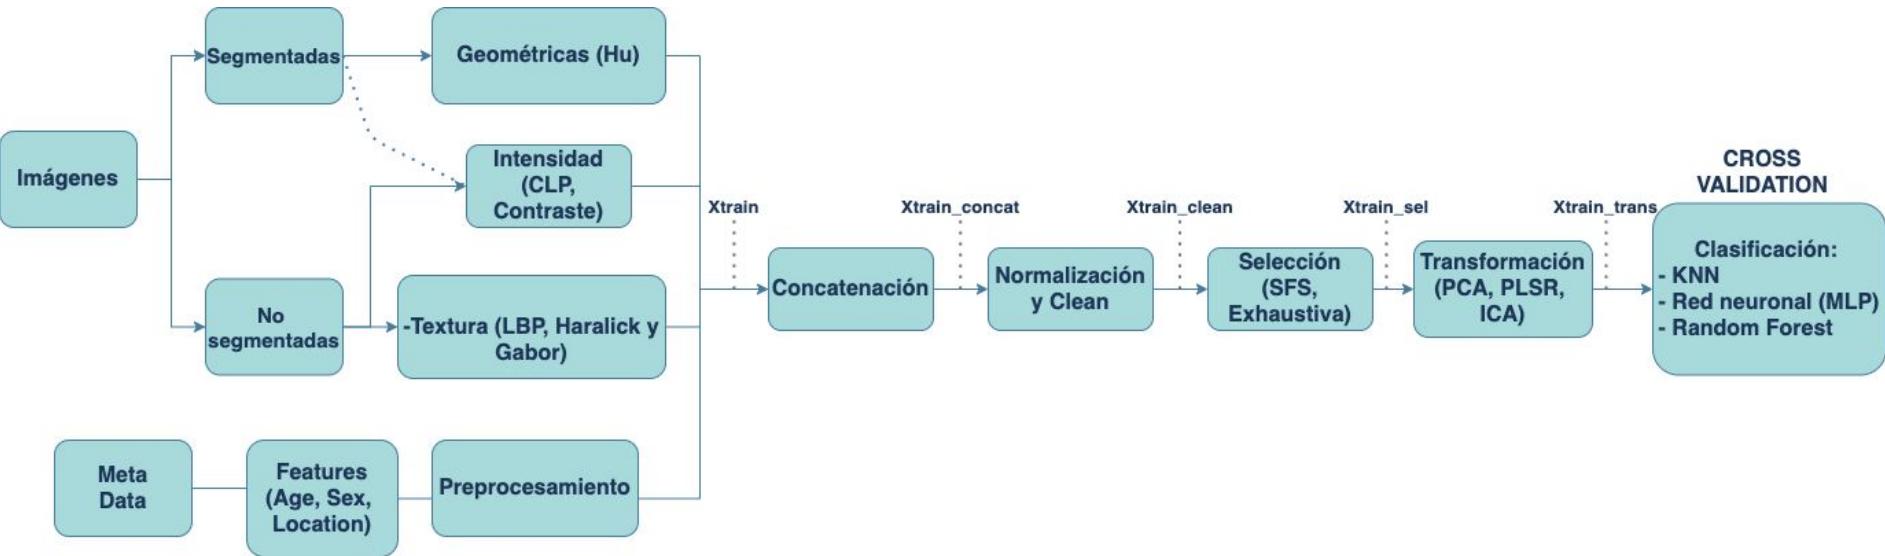
Javiera Inostroza

Martín Ocqueteau

Camila Vera

Samuel Zúñiga

Diagrama de trabajo



Resultados obtenidos

Estrategia	Características	Selector	Transformación	Clasificador	Accuracy
1	LBP[6x6] + Gabor[6x6]	Sin selector	Normalización	Random forest max_depth=10	Train: 100% Test: 41.4%
2	CLP + LBP[4x4]	Clean	Normalización + PCA	KNN con k=8 Red Neuronal (13,5)	Train: 40.29% Test: 40.86%
3	Gabor[4x4] + LBP[6x6] + Metadata (2146)	Clean (2129) + SFS (90)	Normalización + PLSR (43)	MLP Red neuronal 2 capas	Train: 52.90% Test: 48.00%
4	Haralick + LBP[4x4]	Clean	Normalización + PCA	Árbol de decisión con profundidad 7	Train: 49.52% Test: 38%

Trabajos futuros



Extracción de características

- Generar **nuevas combinaciones** de características incluyendo las de **contraste**.
- Generar una **matriz densa** con todas las características de **textura**: LBP, HARALICK y GABOR
- Extraer características **HoG**

Modelamiento

- Probar **nuevos modelos** y otros **ajustes** de hiper parámetros
 - Random forest
 - Multi-class classification con SVM
 - QDA
- Usar cross validation en todas las iteraciones de modelos

Grupo: **PATREC**

Camilo Berrios

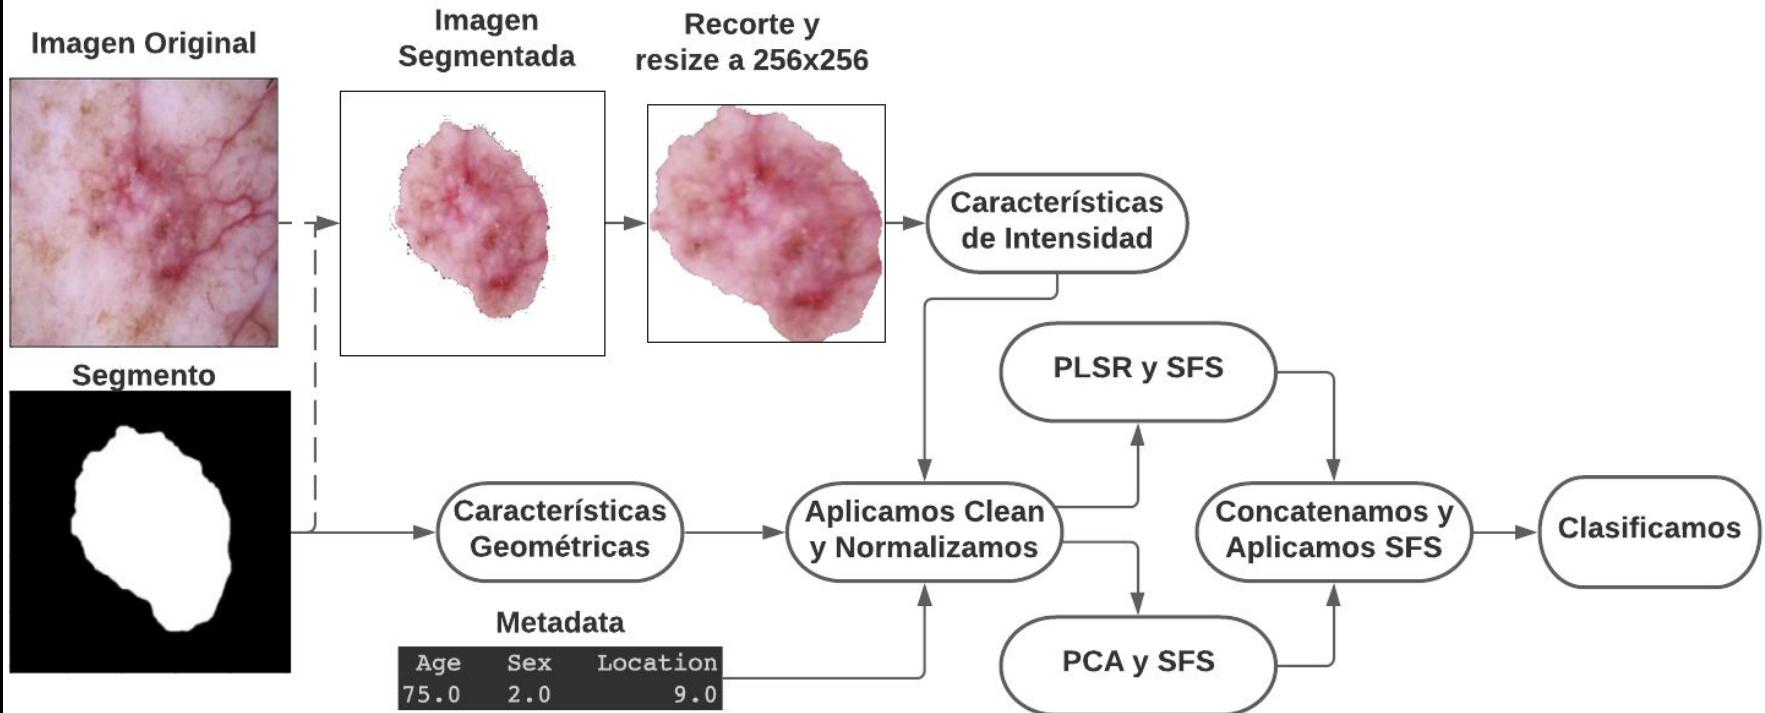
Jaime Middleton

Roshad Alipanah

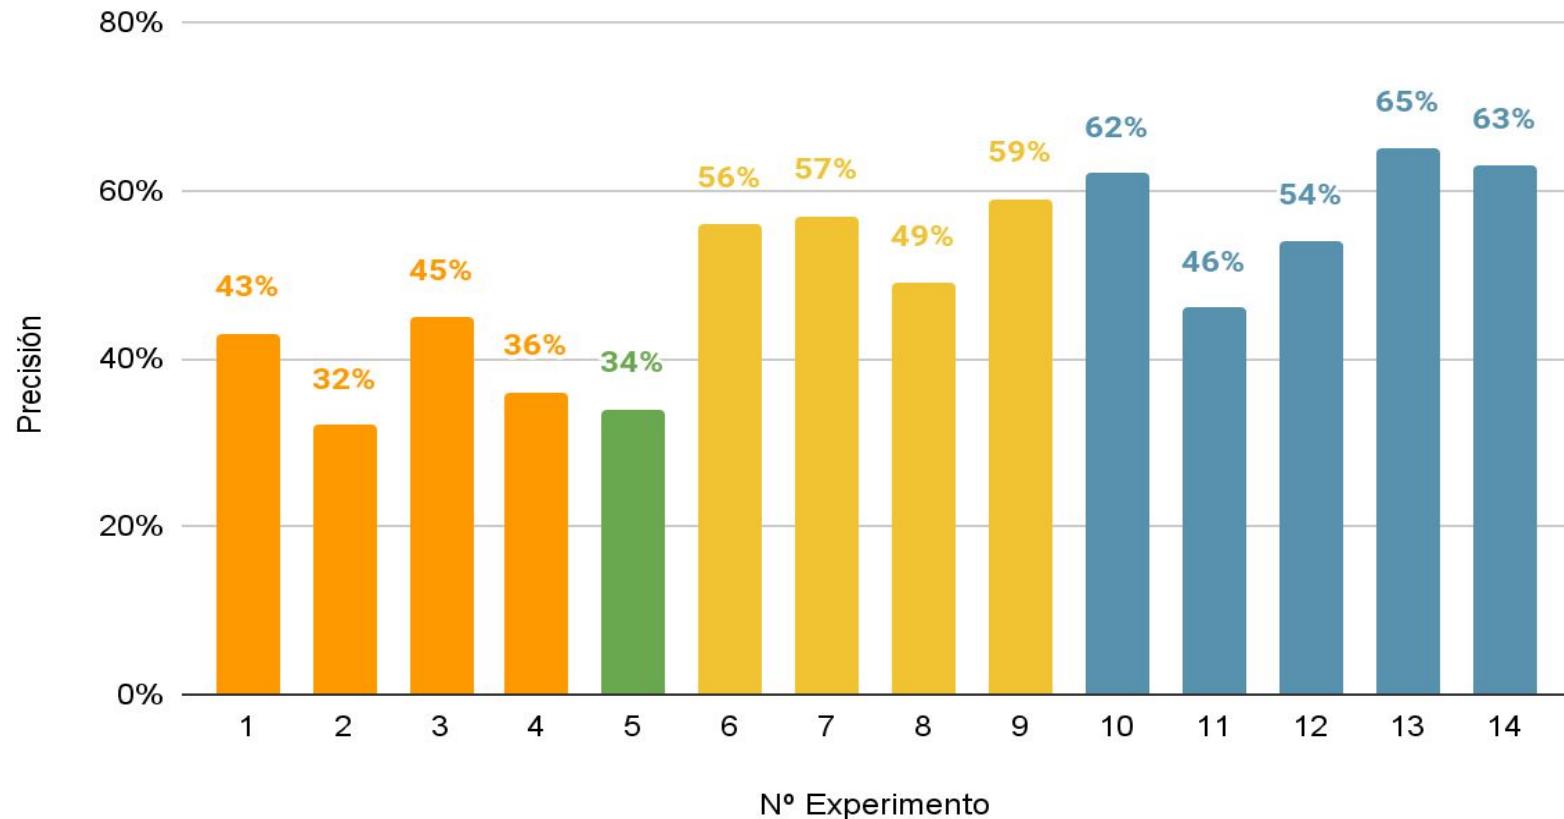
Tomás García



Estrategia Utilizada



Resultados Obtenidos



Trabajo Futuro

01

Aplicar Filtro

Aplicar algún filtro antes
de extraer
características

02

Estado del Arte

Profundizar estudio
sobre estado del arte

03

Otras estrategias

Con distintos bloques

04

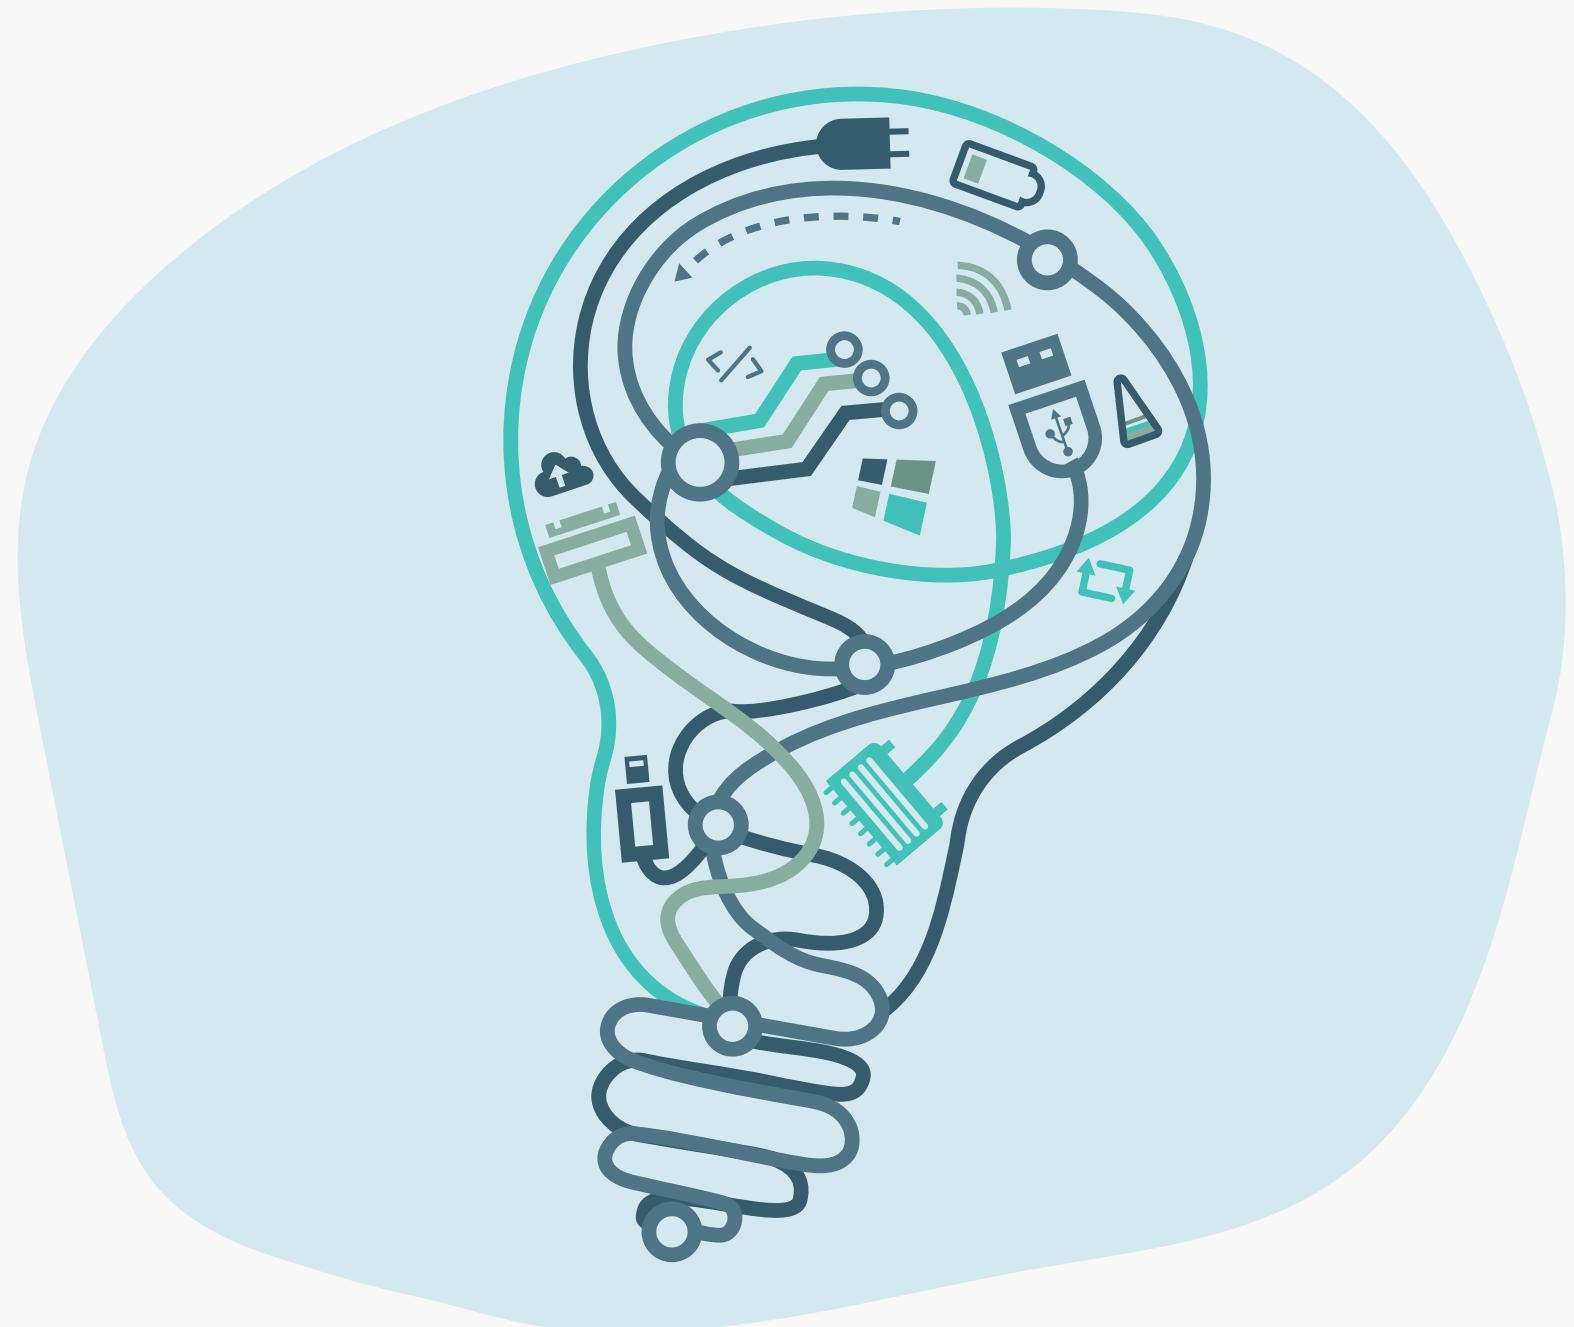
Más Clasificadores

Variando los diversos
hiperparametros



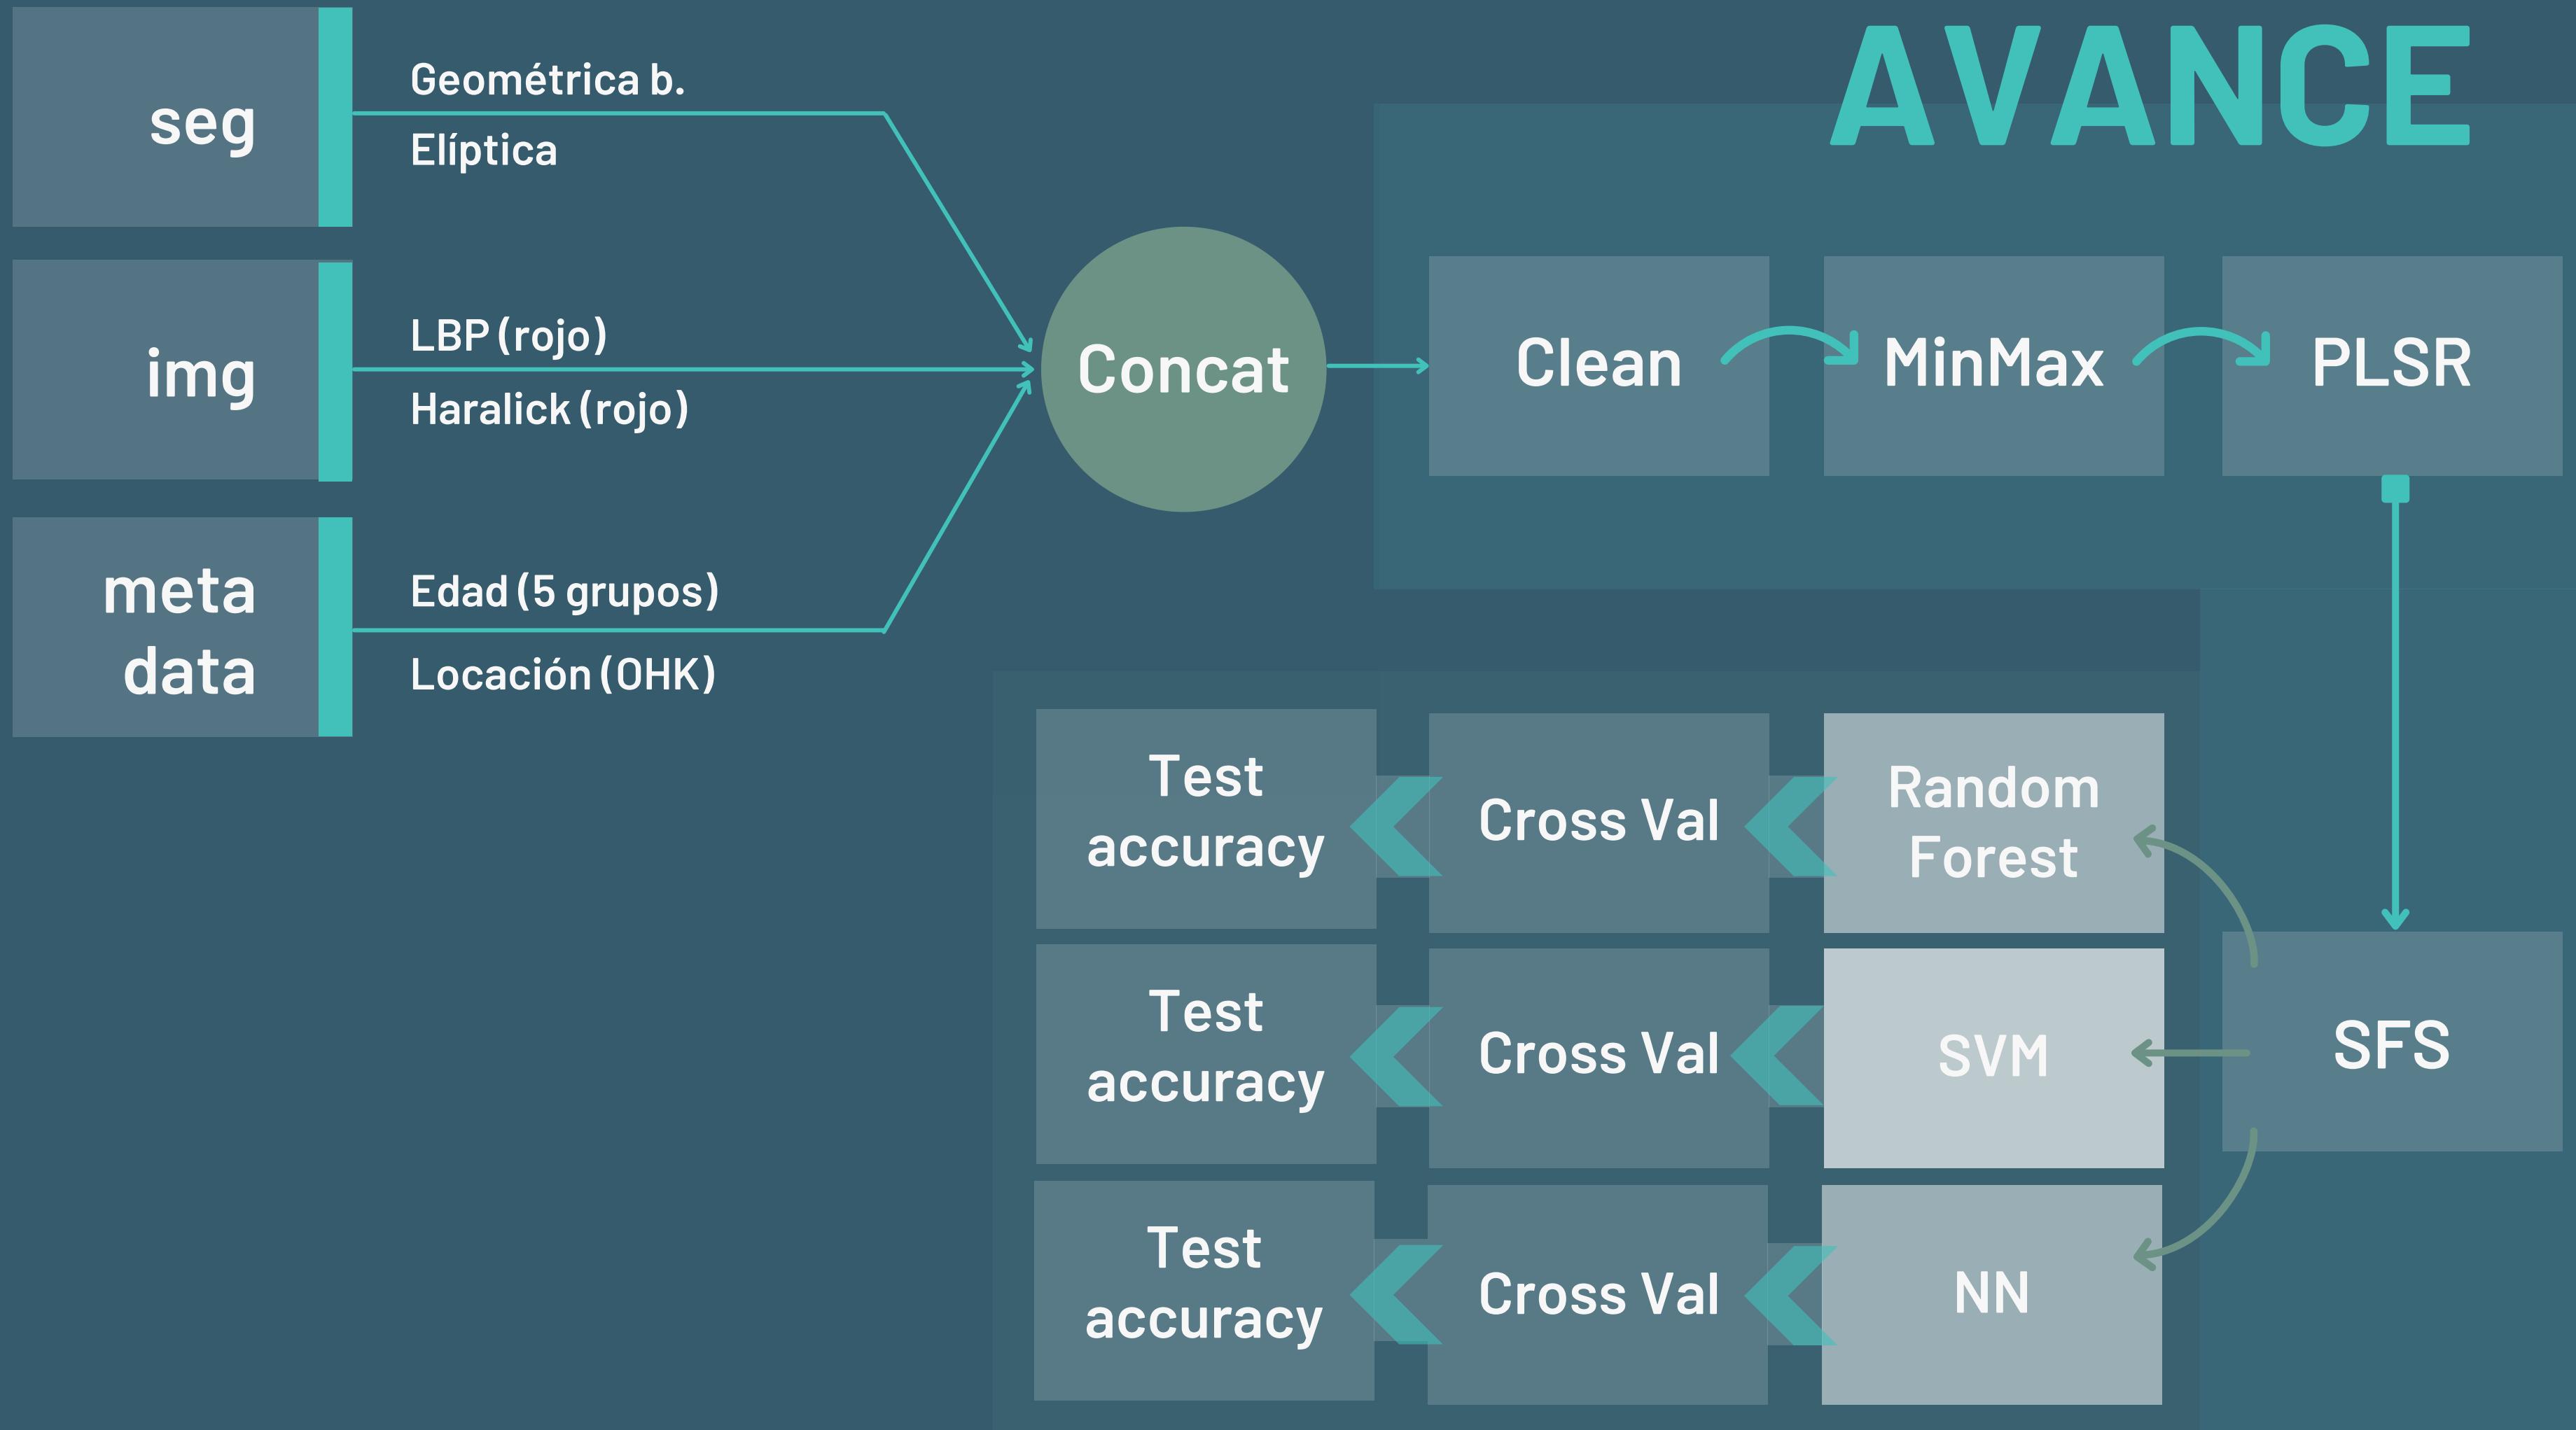
PFGANG

Reconocimiento de Patrones



Raul Díaz - Tomás González - Vicente Reyes - Javiera Saavedra

AVANCE



RESULTADOS

Modelo Accuracy CV Accuracy Test

RF	51.3%	31.4%
SVM	57.7%	30.5%
NN	61.2%	28.5%

Clasificación
lunares benignos
y malignos.

	B	M
B	99	101
M	40	110

24	11	9	0	5	1	0
6	22	10	0	7	5	0
6	14	11	0	11	8	0
7	9	13	0	12	9	0
2	9	6	0	19	14	0
0	2	3	0	12	32	1
0	10	3	0	8	27	2

Random
Forest

19	17	10	0	4	0	0
5	26	8	0	9	2	0
2	19	16	0	7	6	0
2	8	28	0	10	2	0
2	10	8	0	23	6	0
1	3	9	1	12	20	4
0	12	9	0	14	12	3

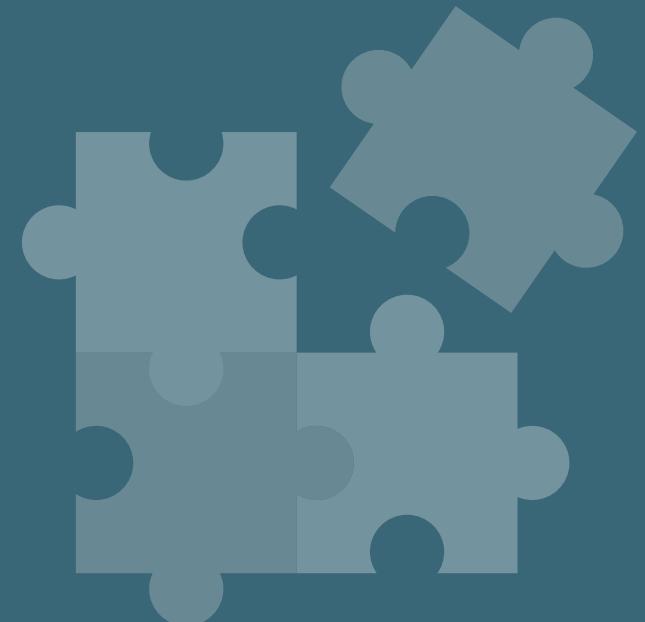
SVM

17	13	10	1	8	1	0
7	16	12	2	11	2	0
9	13	10	4	8	6	0
5	8	12	8	12	5	0
7	5	9	0	20	8	1
1	4	9	2	5	25	4
1	6	13	3	9	14	4

Redes
Neuronales

TRABAJO FUTURO

Combinación selección
de características



Búsqueda de nuevas
características



Ensamble de
clasicadores





PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

PROYECTO

SEGMENTACIÓN DE LUALES

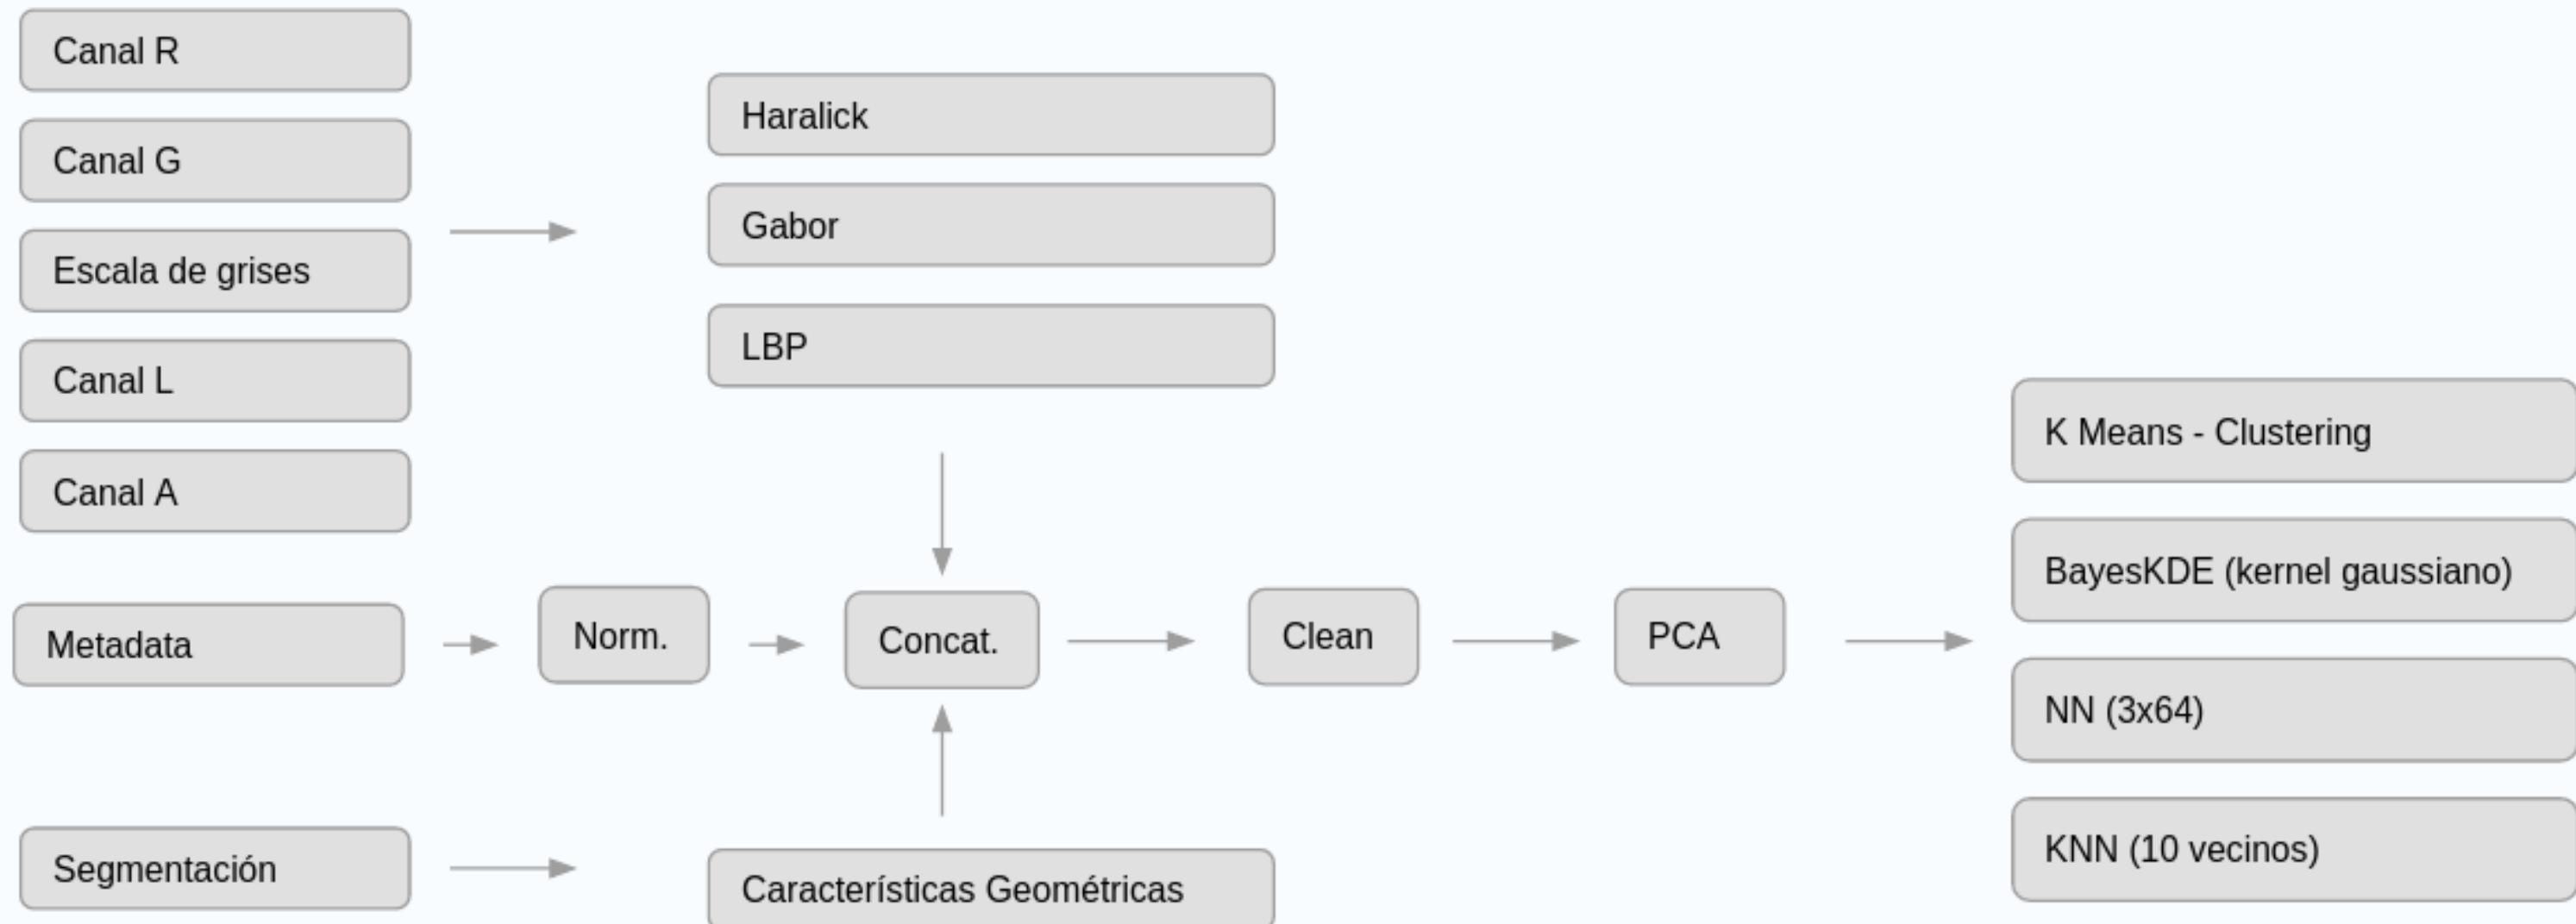
IIC2714-Procesamiento de Imágenes

Francisco Hernández
Joaquín Hofmann
Cristian Nova

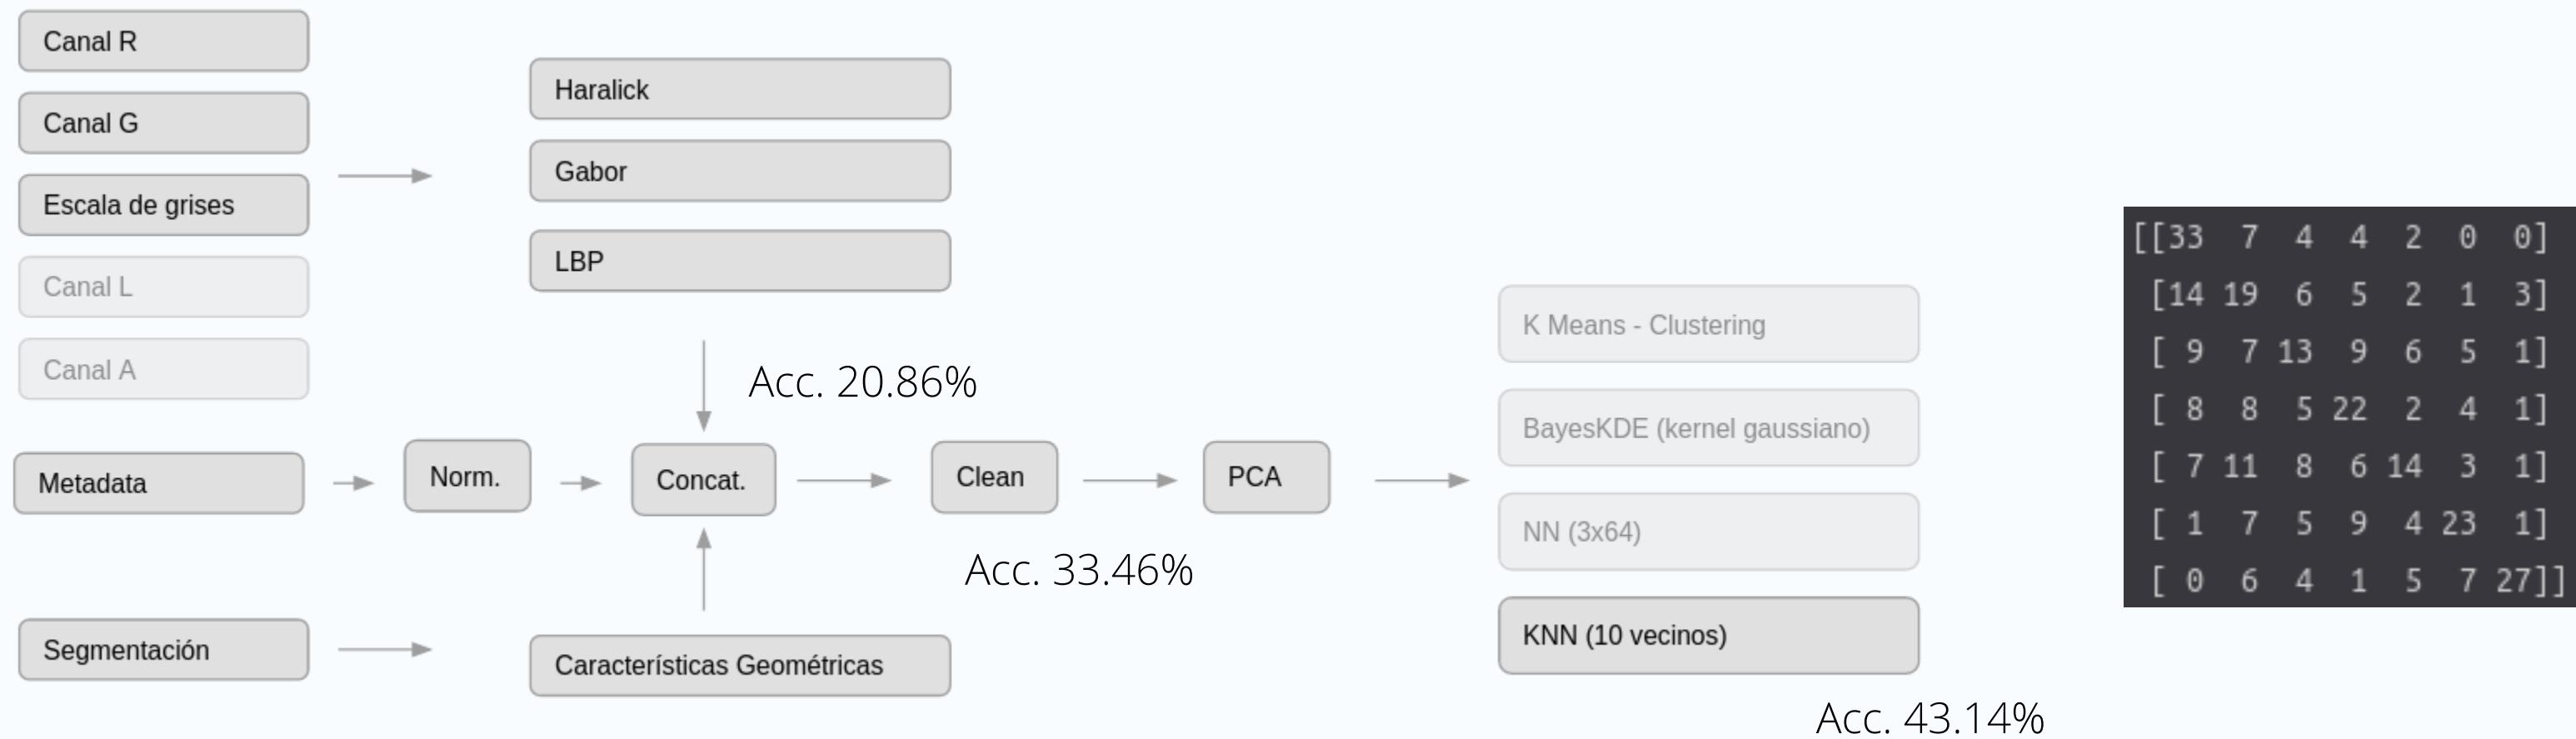
Grupo 3



METODOS PROPUESTOS:



METODOS APLICADOS Y RESULTADOS:



CONCLUSIONES

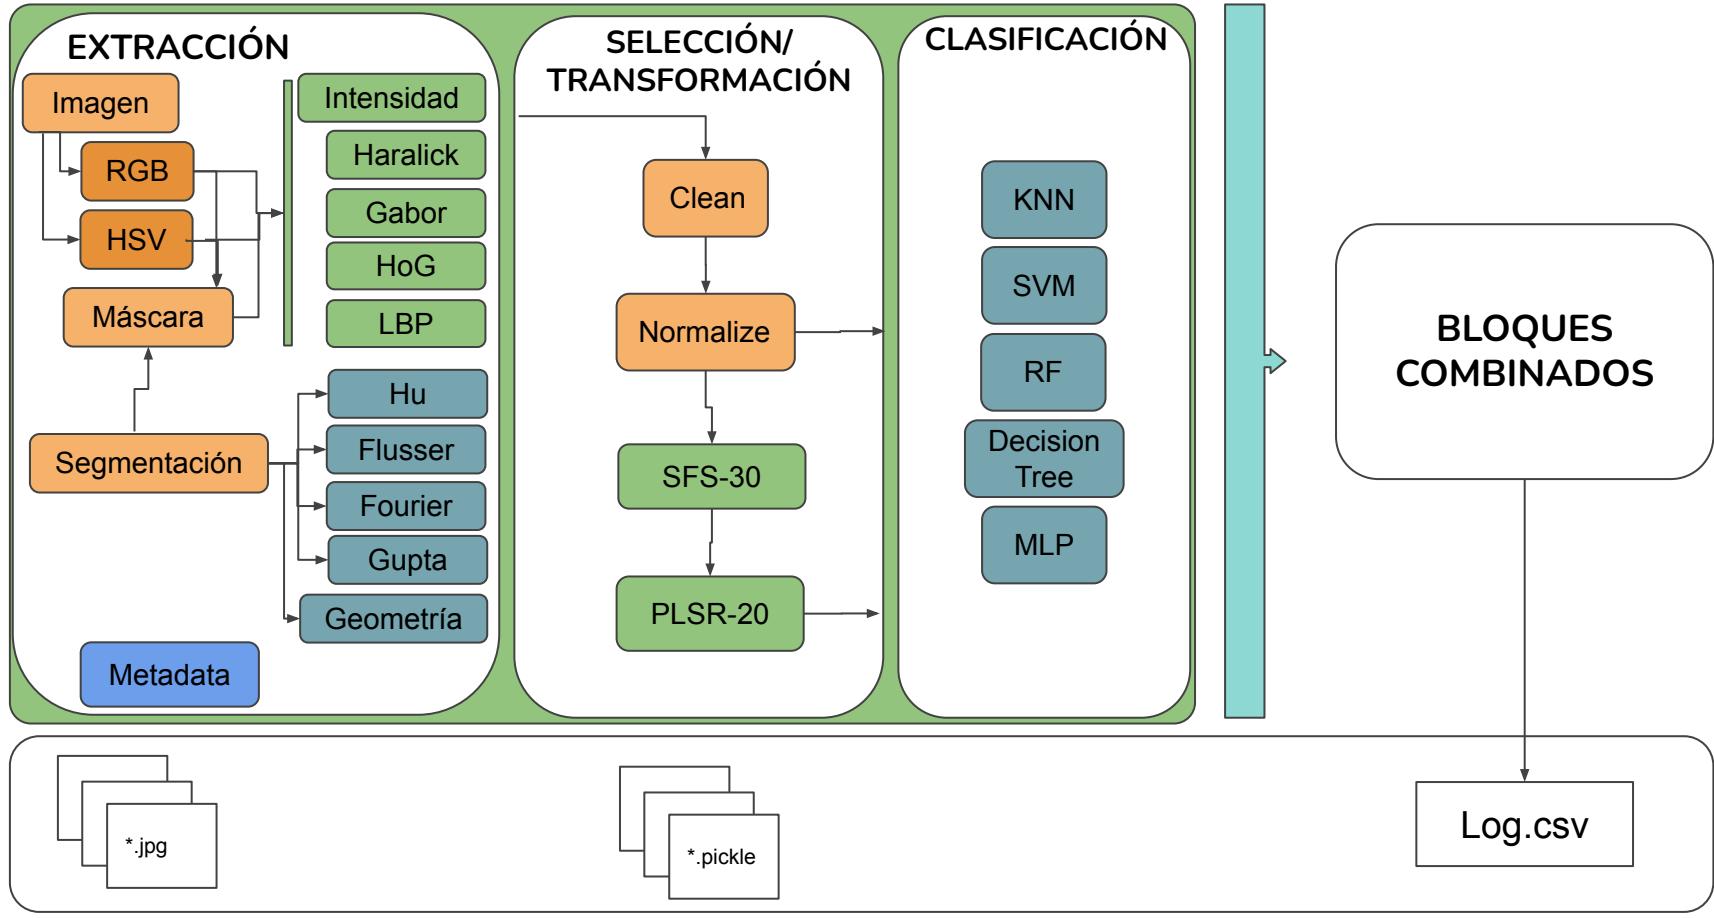
En conclusión, estamos lejos de un desempeño considerable, sin embargo hay muchas mejoras por hacer por lo que se espera llegar a un buen desempeño en el corto plazo.

Estado de avance NEURONALES

Integrantes:
Nicolás Mc Intyre
Jorge Díaz
Felipe Munizaga
Agustín Pérez



Que se ha realizado



Resultados obtenidos

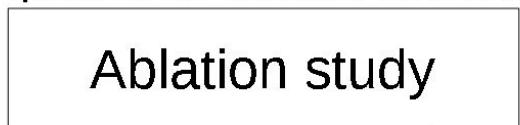
Features	Selec/Transf	Classifier	Best Accuracy Test
All	Clean-Normalize-sfs(30)-pls(20)	KNN K[1,2,...,12] 12 models	66.86% , K= 12
All	Clean-Normalize-sfs(30)-pls(20)	Decision Tree Depth[1,2,...,12] 12 models	58.0% , Depth= 7
All	Clean-Normalize-sfs(30)-pls(20)	Random Forest Depth[1,2,...,20] 20 models	68.29% , Depth=18
All	Clean-Normalize-sfs(30)-pls(20)	SVM Gamma[0.1, 0.2,...,1.0] C[0.1,0.2,...,1.0] 30 models	71.43% , Gamma=0.1 C=0.7
All - Bottom 5 at Ablation Study	Clean-Normalize	MLP h1[10,20,...,100] h2[10,20,...,100] 112 models	82.57% , h1= 13 h2=16

- 47 features + MetaData
- Buenos resultados con MLP.
- Ablation study

M_RGB3_LBP-1-1	--> 2.119
R_RGB2_Gabor-8-8	--> 1.976
METADATA	--> 1.643
M_RGB2_Gabor-8-8	--> 1.595
S_NO_Fourier	--> 1.452
M_RGB2_Haralick-5	--> 1.190
M_RGB3_Haralick-5	--> 1.167
M_RGB3_Gabor-8-8	--> 1.071
R_RGB1_Haralick-5	--> 0.929
R_RGB3_LBP-1-1	--> 0.738
S_NO_Gupta	--> 0.690
R_RGB3_Gabor-8-8	--> 0.667
M_HSV1_BasicInt	--> 0.667
M_RGB3_HoG-2-2-16	--> 0.619
M_HSV2_BasicInt	--> 0.548
M_RGB2_BasicInt	--> 0.381
S_NO_Shape	--> 0.357
M_RGB2_LBP-1-1	--> 0.333
M_RGB1_Haralick-5	--> 0.310
M_RGB1_LBP-1-1	--> 0.262
R_RGB2_Haralick-5	--> 0.262
M_RGB1_HoG-2-2-16	--> 0.238
R_RGB1_Gabor-8-8	--> 0.238
R_RGB2_LBP-1-1	--> 0.214
R_RGB3_Haralick-5	--> 0.167
M_RGB2_HoG-2-2-16	--> 0.071
M_RGB1_LBP-3-3	--> 0.048
S_NO_Flusser	--> 0.000
M_HSV3_BasicInt	--> 0.000
M_RGB3_BasicInt	--> -0.000
M_RGB1_Gabor-8-8	--> -0.262
R_RGB2_HoG-2-2-16	--> -0.357
R_RGB3_HoG-2-2-16	--> -0.429
R_RGB1_LBP-1-1	--> -0.452
S_NO_Hu	--> -0.524
R_RGB1_HoG-2-2-16	--> -0.643
M_RGB2_Haralick-3	--> -0.690
M_RGB1_BasicInt	--> -0.690
M_RGB2_LBP-3-3	--> -0.714
M_HSV1_LBP-3-3	--> -0.714
M_HSV2_LBP-3-3	--> -0.714
M_RGB3_Haralick-3	--> -0.714
M_HSV1_Haralick-3	--> -0.714
M_HSV2_Haralick-3	--> -0.714
M_HSV3_Haralick-3	--> -0.714
M_RGB1_Haralick-3	--> -0.738
M_HSV3_LBP-3-3	--> -1.143

Trabajos futuros

Optimizar las variables en estudio



↑ Accuracy

Parameter sweep

Optimizar la configuración del clasificador

PATRONES

2021-1



MOLETEAM



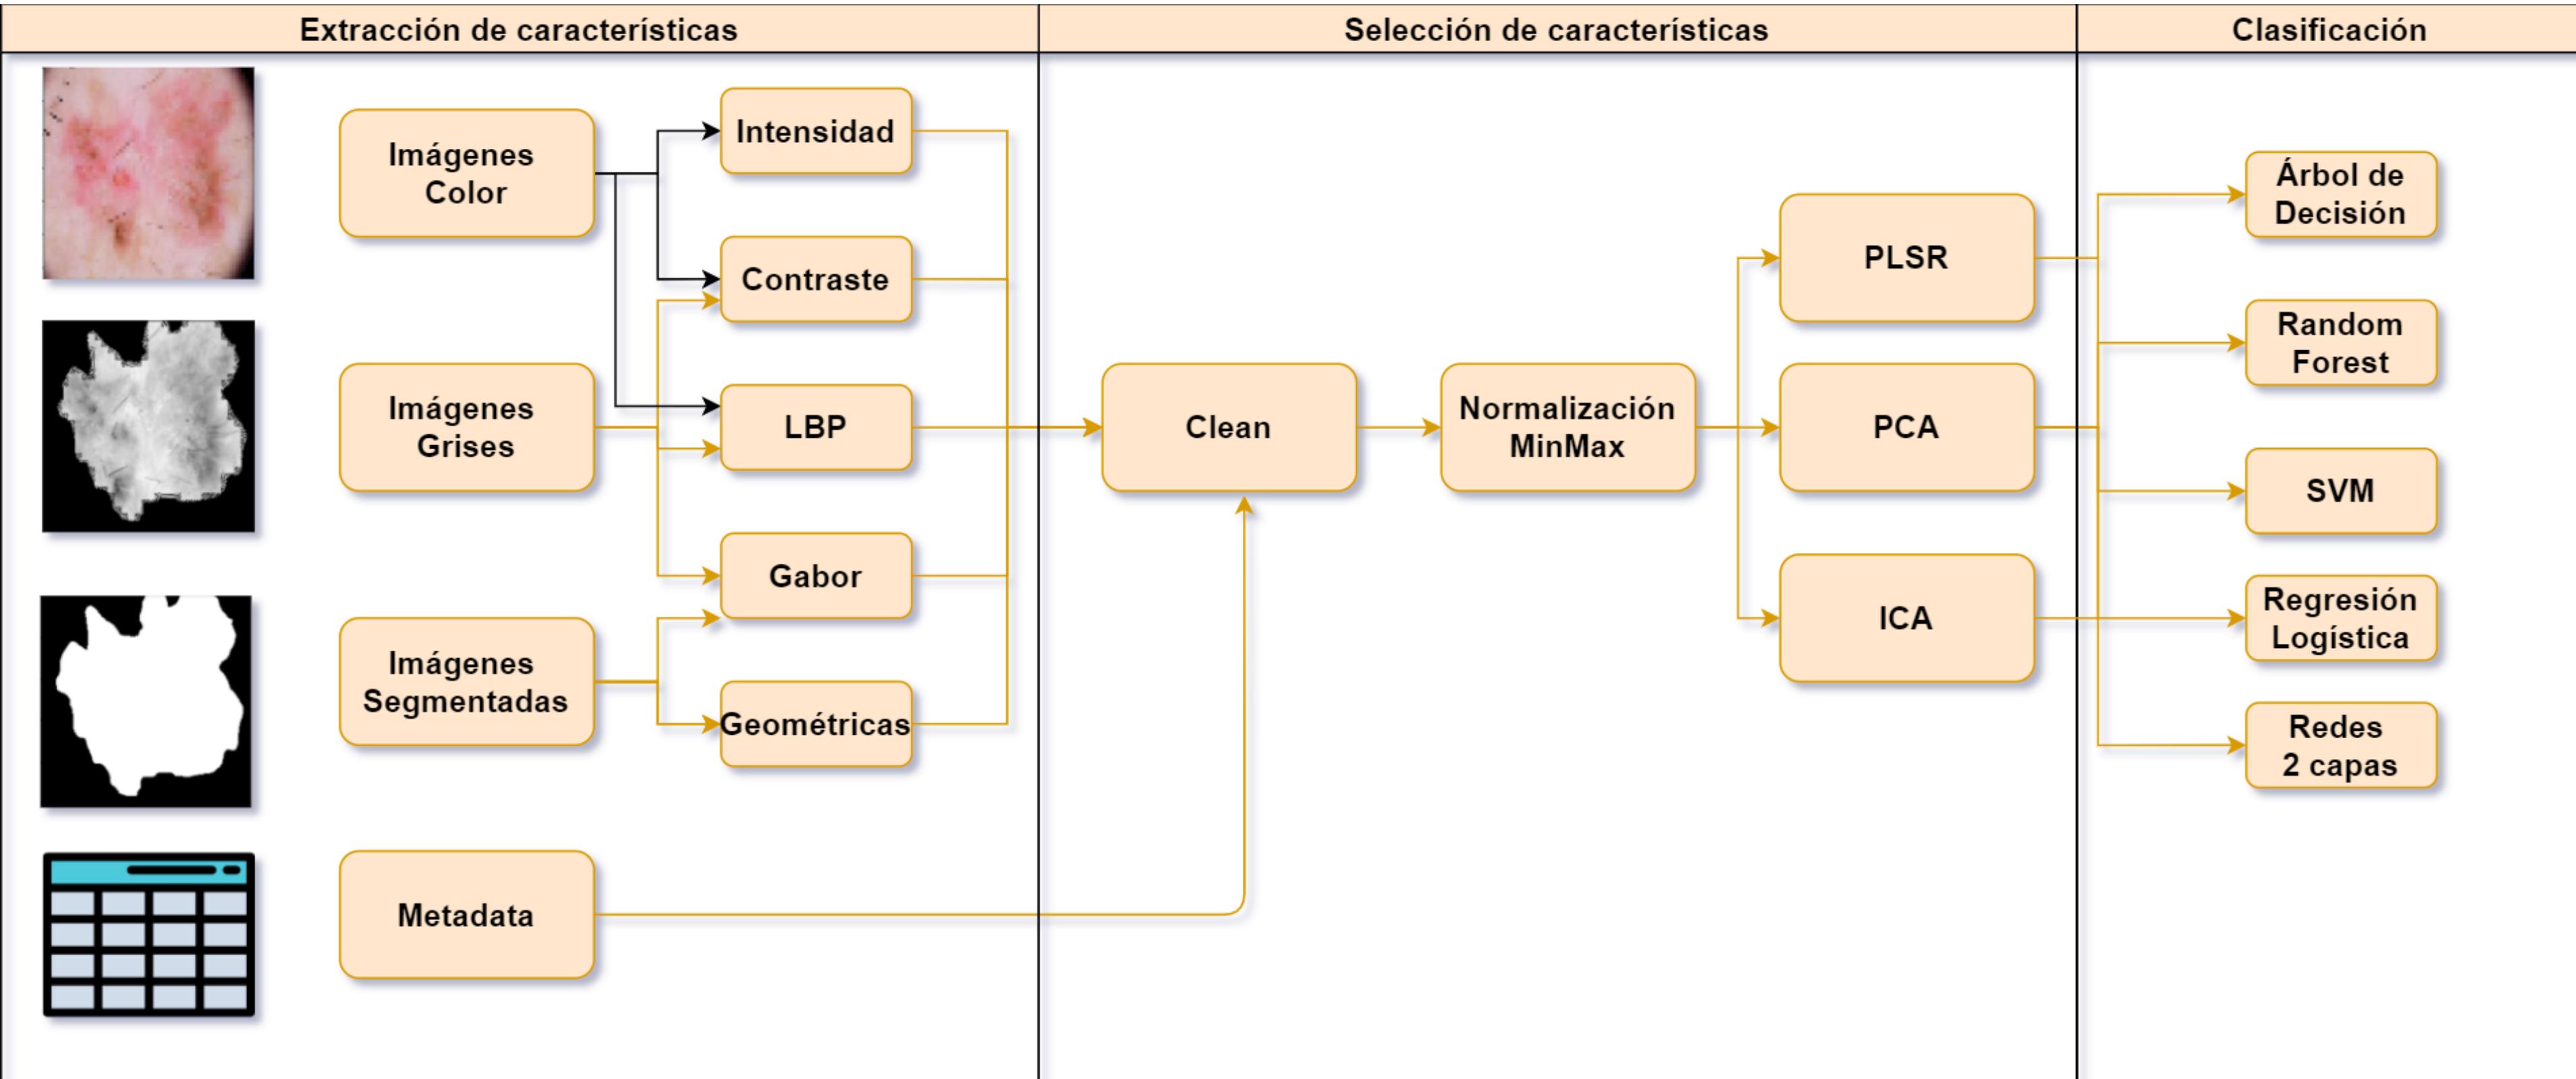
Rafael Abusleme

Sergio Lecaros

Maximiliano Narea

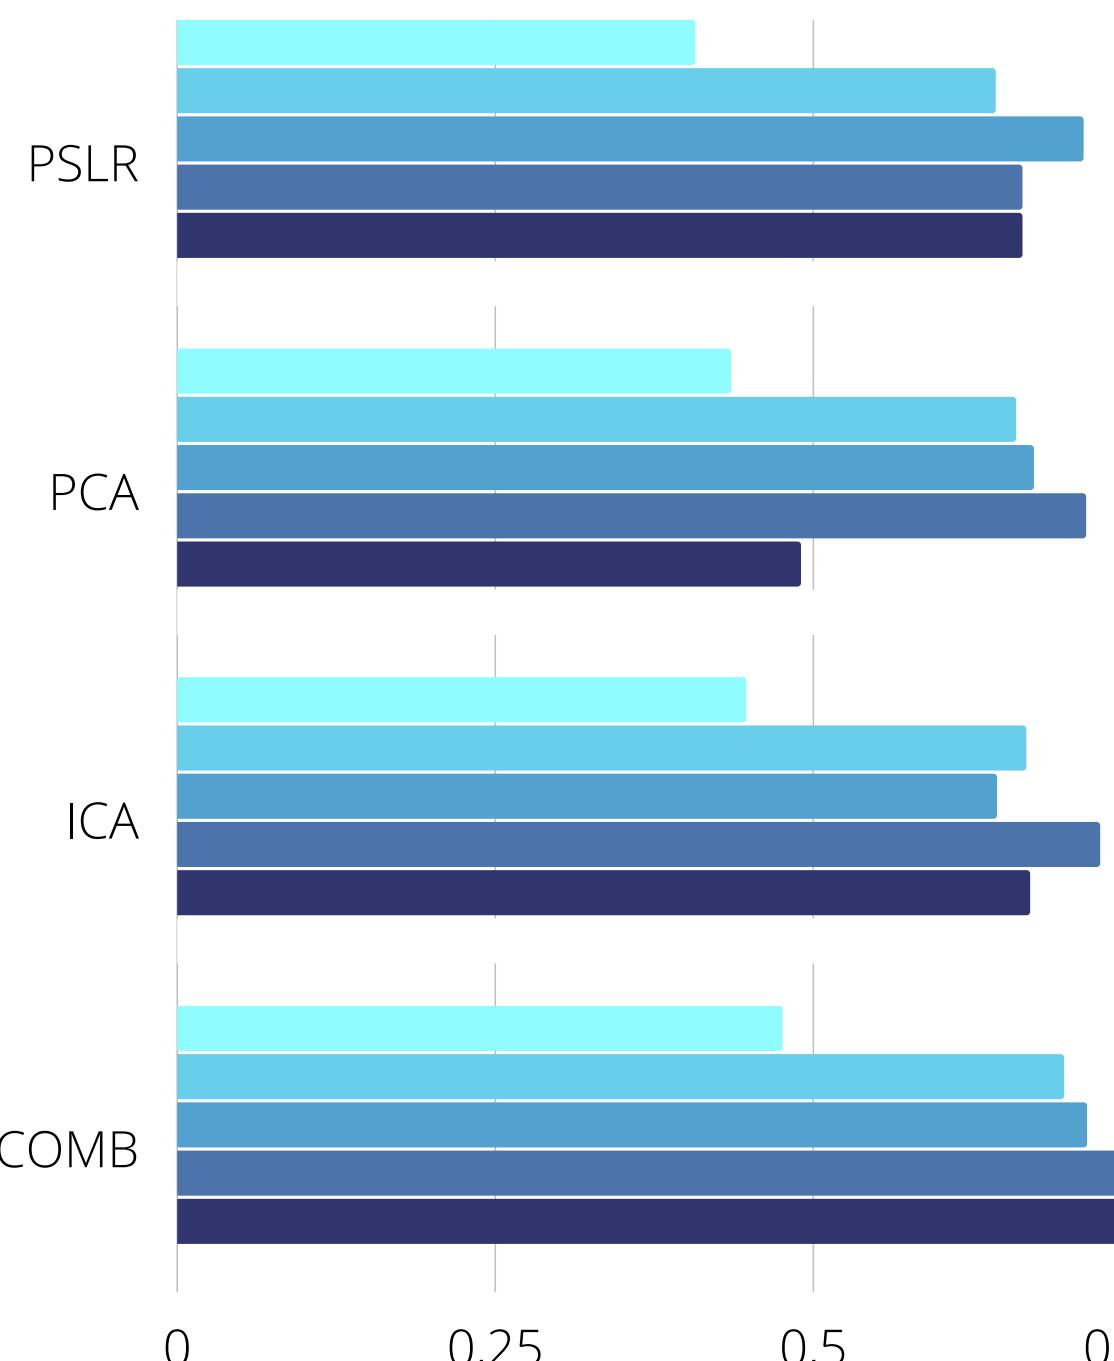
Lucas Van Sint Jan

Mathias Valdebenito



RESULTADOS

Cross-validation

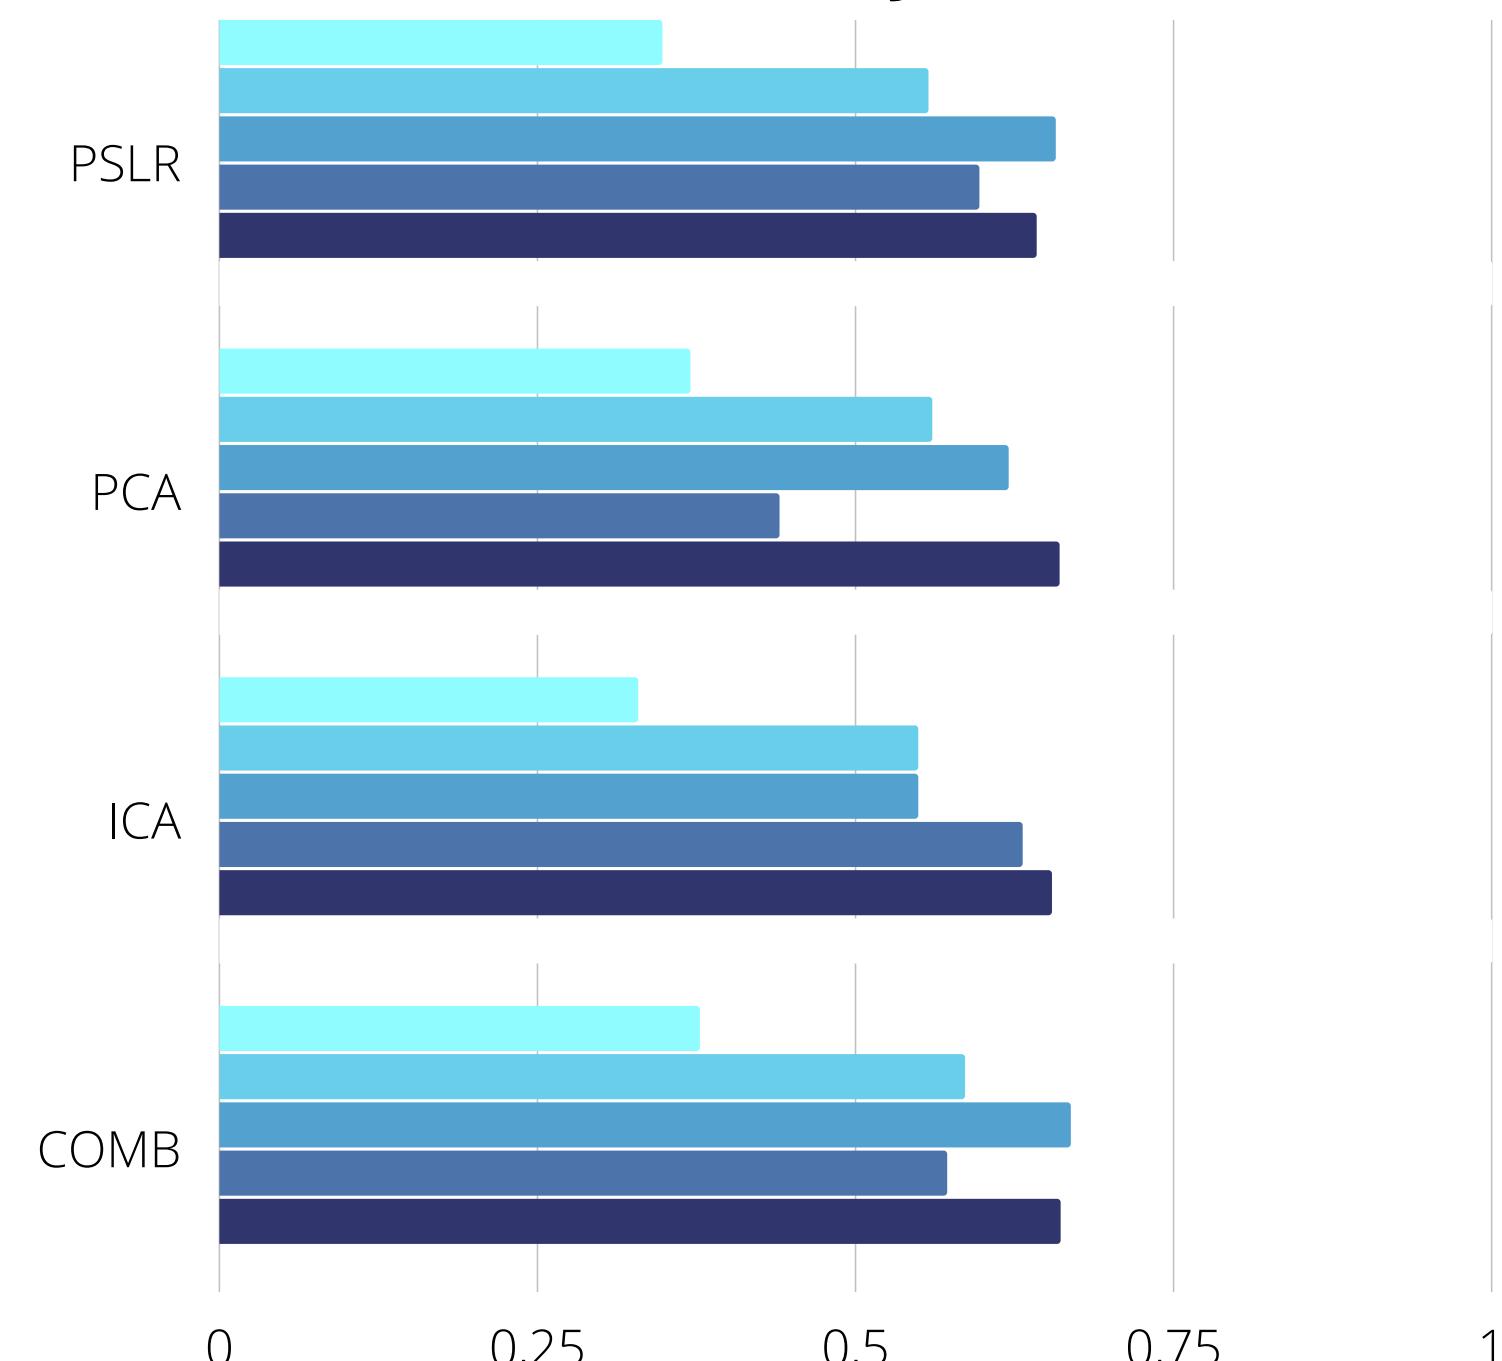


Mejor cross-val:
COMB: RegLog = 0.742

Mejor Testing:
COMB: SVM= 0.668

- Árbol de decisión
- Random Forest
- SVM
- Regresión Logística
- Red Neuronal

Testing



TRABAJO A FUTURO

- Nuevo preprocessamiento de imágenes.
- Extracción de características ABC.
- Incorporar selectores de características (SFS, RFE, etc.)
- Implementar el mejor clasificador a Adaboost.



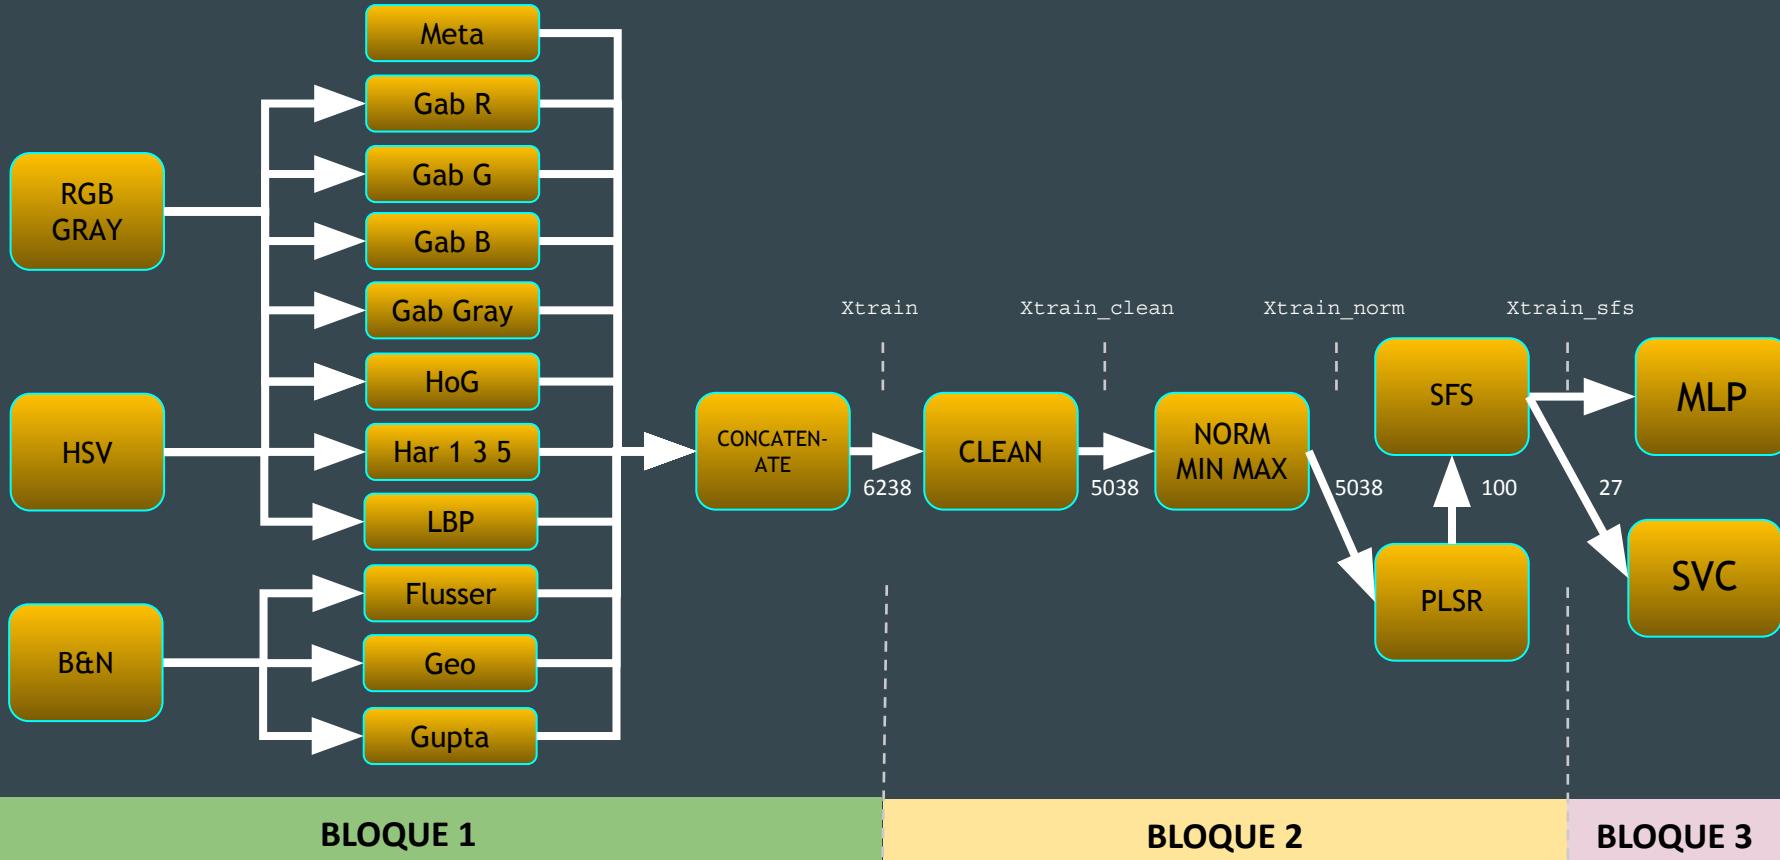
Reconocimiento de Patrones
IIC3724 2021-1
Domingo Mery

Avance Grupo Patrones Del Mal

• • •

- Sebastián Pulgar
- Jorge Toro
- Mauricio Berrios
- Cristóbal Matute
- J. Miguel Cathalifaud

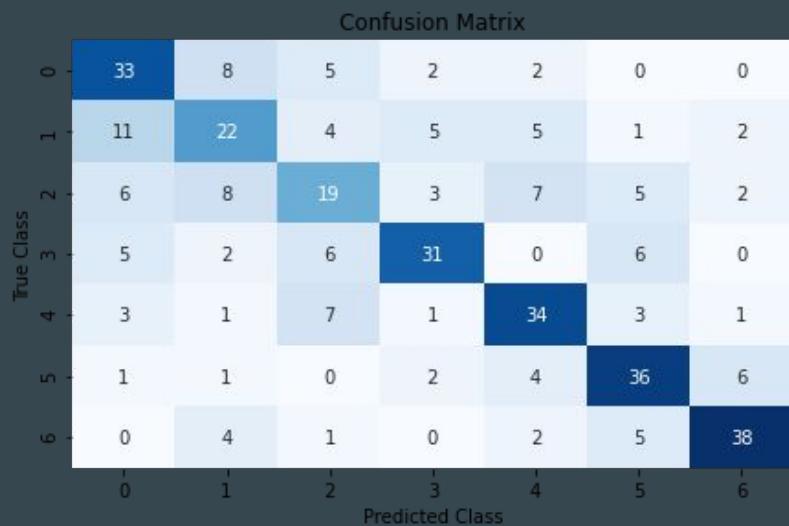
Qué se ha hecho



Resultados obtenidos

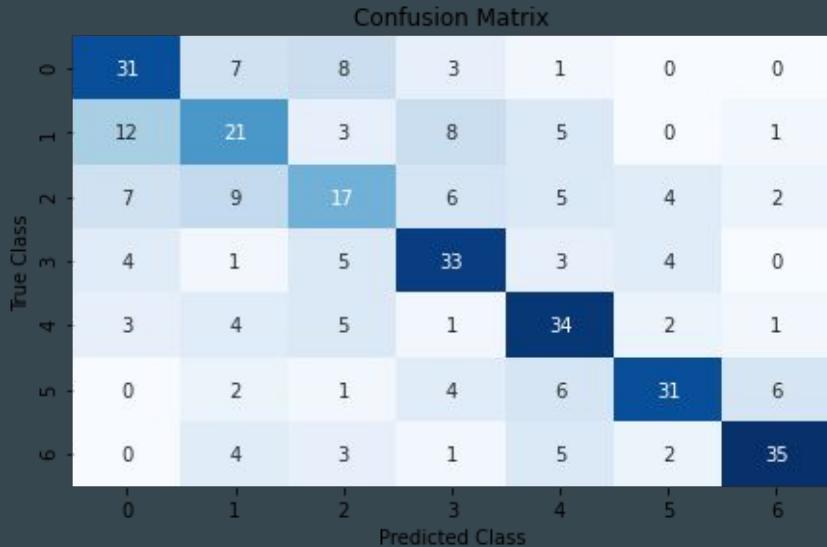
Estrategia 1 :

- PLSR + SFS + MLP
- Crossval (training): 60.81%
- MLP (testing): 60.86%



Estrategia 2 :

- PLSR + SFS + SVC
- Crossval (training): 58.45%
- SVC (testing): 57.71%



Trabajo futuro

- Sobre el Bloque 1 : **Extracción**
 - ◆ Realizar pruebas sobre lunar segmentado + preprocessamiento
 - ◆ Agregar BoW desde LBP y SIFT : nueva característica*
 - ◆ Buscar características más efectivas sobre las clases con mayor confusión mutua
- Sobre el Bloque 2 : **Acondicionamiento**
 - ◆ Agregar opciones de transformación
 - ◆ Agregar opciones de selectores
- Sobre el Bloque 3 : **Clasificación**
 - ◆ Ajustar parámetros de clasificador MLP (NN)
 - ◆ Ajustar parámetros de clasificador SVC (SVM)
 - ◆ Investigar sobre Bagging y Boosting